



Análisis de Metadatos I: Unidad 2 - Parte 1

Lenguaje de Programación en R

Jair Pallares Castellon, MSc.

Unidad II: Exploración de datos - Parte 1

Preparación de los datos

Para la preparación de los datos, existen paquetes en R

- Algunos ya están incluidos desde su instalación
- CRAN (Comprehensive R Archive Network)
- Funciones `library()` o `require()`.

Además, R viene con una colección de conjuntos de datos “**datasets**”

- Ejemplo: `lynx`, es el número de lince calculados en Canadá.

Algunos paquetes deben ser cargados usando `library()` para que puedan ser usados. Además, `data()` muestra todos los conjuntos de datos del paquete cargado.

```
R Console
> lynx
Time Series:
Start = 1821
End = 1934
Frequency = 1
[1] 269 321 585 871 1475 2821 3928 5943 4950 2577 523 0
[16] 2285 2685 3409 1824 409 151 45 68 213 546 1033 210
[31] 377 225 360 731 1638 2725 2871 2119 684 299 236 20
[46] 6721 4254 687 255 473 358 784 1594 1676 2251 1426 70
[61] 469 736 2042 2811 4431 2511 389 73 39 49 59 10
[76] 3495 587 105 153 387 758 1307 3465 6991 6313 3794 180
[91] 1388 2713 3800 3091 2985 3790 674 81 80 108 229 30
[106] 2935 1537 529 485 662 1000 1590 2657 3396
> library()
> library(MASS)
> data(survey)
> survey
```

	Sex	Wr.Hnd	NW.Hnd	W.Hnd	Fold	Pulse	Clap	Exer	Smoke?
1	Female	18.5	18.0	Right	R on L	92	Left	Some	Never?
2	Male	19.5	20.5	Left	R on L	104	Left	None	Regul?

```
R Console
> data(survey, package="MASS")
> survey
```

	Sex	Wr.Hnd	NW.Hnd	W.Hnd	Fold	Pulse	Clap	Ex
1	Female	18.5	18.0	Right	R on L	92	Left	So\$
2	Male	19.5	20.5	Left	R on L	104	Left	No\$
3	Male	18.0	13.3	Right	L on R	87	Neither	No\$
4	Male	18.8	18.9	Right	R on L	NA	Neither	No\$
5	Male	20.0	20.0	Right	Neither	35	Right	So\$
6	Female	18.0	17.7	Right	L on R	64	Right	So\$
7	Male	17.7	17.7	Right	L on R	83	Right	Fr\$

Preparación de los datos

Acceso a variables en un conjunto de datos: Un conjunto de datos pueden ser almacenados en una variable (lynx) o múltiples variables (survey que está dentro del paquete MASS).

- Múltiples variables son almacenados en “data frames” (marcos de datos)
- Las variables poseen nombres y estos deben ser incluidos: la sintaxis **\$** es usada para esto.
- Para que los nombres de las columnas sean visibles/invisibles usamos **attach()** y **detach()**.
- Por otro lado, con la la función **with()** realizamos las funciones de **attach()** y **detach()** de una vez.

`with(data.frame, command)`

```
R Console
> library(MASS)
> names(geyser)
[1] "waiting" "duration"
> geyser$waiting
[1] 80 71 57 80 75 77 60 86 77 56 81 50 89
[14] 54 90 73 60 83 65 82 84 54 85 58 79 57
[27] 88 68 76 78 74 85 75 65 76 58 91 50 87
[40] 48 93 54 86 53 78 52 83 60 87 49 80 60
[53] 92 43 89 60 84 69 74 71 108 50 77 57 80
```

```
R Console
> library(MASS)
> data(Sitka)
> names(Sitka)
[1] "size" "Time" "tree" "treat"
> with(Sitka, range(tree))
[1] 1 79
> length(Sitka$tree)
[1] 395
> attach(Sitka)
> summary(tree)
  Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
     1      20      40      40      60      79
> detach(Sitka)
> |
```

Preparación de los datos

Ejercicios de práctica:

1. El conjunto de datos **islands** contiene el tamaño de las masas de tierra del planeta que superan 10000 millas cuadradas. Use **sort()** con el argumento **decreasing=TRUE** para encontrar las 7 masas de tierra más grandes.
2. Para el conjunto de datos **treering**, el cual contiene los anchos, sin dimensiones, de los anillos de los árboles, use una función en R para responder a lo siguiente:
 - a. ¿Cuántas observaciones hay allí?
 - b. Encuentre la observación más pequeña
 - c. Encuentre la observación más grande
 - d. ¿Cuántas son mayores que 1.5?

Análisis exploratorios de datos

Datos categóricos es resumido por tablas o gráficos (Barras, de puntos, circulares).

Tablas: Son usadas para resumir los datos. En R la función para esto es **table()**. Esta función encuentra todos los valores únicos de un vector de datos entonces contabiliza las frecuencia de su ocurrencia.

Ejemplo 1: El servicio del clima en USA reúne una gran cantidad de datos en la base de datos denominada `central.park.cloud`. El clima de cada día es categorizado por “clear”, “cloudy” o “partly cloudy”. Instalar el paquete `UsingR` y usarlo para obtener las frecuencias de cada una de esas categoría.

```
R Console
> colores = c("azul", "verde", "azul", "verde", "verde", "verde")
> table(colores)
colores
 azul verde
    2     4
> |
```

```
R Console
> library(UsingR)
> central.park.cloud
[1] partly.cloudy partly.cloudy partly.cloudy clear
[5] partly.cloudy partly.cloudy clear cloudy
[9] partly.cloudy clear cloudy partly.cloudy
[13] cloudy cloudy clear partly.cloudy
[17] partly.cloudy clear clear clear
[21] clear cloudy cloudy cloudy
[25] cloudy cloudy clear partly.cloudy
[29] clear clear partly.cloudy
Levels: clear partly.cloudy cloudy
> table(central.park.cloud)
central.park.cloud
 clear partly.cloudy cloudy
    11         11         9
> |
```



Análisis exploratorios de datos

Los datos categóricos permite organizar la información en niveles, mostrando la frecuencias de las variables. En R usamos la función **barplot()**, para construir gráficos de barras.

Ejemplo 2: 25 estudiantes son consultados acerca de sus preferencias en los tipos de cervezas. Las categorías a elegir, a partir de códigos, son: (1) local, (2) nacional, (3) artesanal y (4) importada. Los datos sin procesar son: 3 4 1 1 3 4 3 3 1 3 2 1 2 1 2 3 2 3 1 1 1 1 4 3 1. Construir un gráfico de barras.

Podemos usar estos datos en **c()**, pero es mucho más sencillo usar **scan()**, porque no necesitamos separar por comas todos los datos que tenemos, solo basta con copiarlos y pegarlos en R Console.

```
R Console
> cervezas = scan()
1: 3 4 1 1 3 4 3 3 1 3 2 1 2 1 2 3 2 3 1 1 1 1 4 3 1
26:
Read 25 items
> barplot(cervezas)
> barplot(table(cervezas),
+ xlab="cervezas", ylab="frecuencias")
> barplot(table(cervezas)/length(cervezas),
+ xlab="cervezas", ylab="proporciones")
> |
```




Análisis exploratorios de datos

Ejemplo 3: Gráficos de barras engañosos.

Cuando las personas visualizan un gráfico de barra, asumen con mucha frecuencia que estos comienzan en una escala cero. Un diseñador gráfico de forma deliberada puede no especificar esta escala, esto comúnmente se conoce como gráficos de barras engañosos y a menudo aparecen en los medios.


Como podemos observar, en el argumento de la función `barplot` hemos usado el comando `ylim` para modificar los límites del eje y. De forma análoga se puede hacer con el eje x, usando el comando `xlim`. El comando `xpd` es usado para imprimir estos límites.



Análisis exploratorios de datos

Ejemplo 4: Los gráficos de barra son frecuentemente usados para ilustrar series de tiempo. Una serie de tiempo es una medida de los mismo objetos, en algunos instantes de tiempo. Por ejemplo, la alta temperatura en mayo de 2003 en Central Park la cual está almacenada en la variable MAX de central.park en el conjunto de datos (UsingR)

El comando `names.arg=` permite cambiar los nombres. Es útil experimentar con los comandos: El comando `horizontal=TRUE`; `col=` agrega color a las barras.



```
R Console

> library(UsingR)
loading required package: MASS
loading required package: HistData
loading required package: Hmisc
loading required package: lattice
loading required package: survival
loading required package: Formula
loading required package: ggplot2

attaching package: 'Hmisc'

The following objects are masked from 'package:base':
  format.pval, units

attaching package: 'UsingR'

The following object is masked from 'package:surv':
  cancer

> central.park
  DY MAX MIN AVG DEP HDD CDD WTR SNW DPTH SPD
1  1  72  51  62   4   3  0 0.04  0   0  5.8
2  2  75  52  64   6   1  0 0.29  0   0  7.0
3  3  65  50  58   0   7  0 0.00  0   0  8.5
4  4  63  48  56  -3   9  0 0.00  0   0  2.8
5  5  59  45  52  -7  13  0 0.05  0   0  4.6
6  6  61  45  53  -7  12  0 0.00  0   M  4.5
7  7  79  54  67   7   0  2 0.16  0   M  5.3
8  8  60  53  57  -3   8  0 0.19  0   0  8.0
```

```
R Console

> barplot(central.park$MAX,
+ names.arg=1:31,
+ xlab="dia", ylab="Temperatura maxima")
> |
```

Análisis exploratorios de datos


Gráficos circulares: Estos gráficos de torta son para mostrar proporciones de una variable categórica. La función para esto es `pie()`

Usamos los datos de la variable `ventas` usado en el ejemplo 3. `title()` y `main` se pueden usar para agregar un título al gráfico.


Los gráficos circulares son una mala opción para mostrar información. La razón es que los ojos juzgan muy bien medidas lineales y muy mal áreas relativas (observa el gráfico y lo entenderás!).

Gráficos de puntos llamados también como gráficos de puntos Cleveland. Los datos son mostrados como puntos donde los valores máximos y mínimos son evidentes. La función para esto es `dotchart()`. Podemos usar `xlim=`, colores (`color=`, `gcolor=`, `lcolor=`) y caracteres de gráfico (`pch=`, `gpch=`).

```
R Console
ventas
Juan Javier Susy
45 44 46
pie(ventas, main="Ventas")
```




```
R Console
> dotchart(ventas,
+ xlab="Cantidad de Ventas")
> |
```



Análisis exploratorios de datos

Factores: ¿De donde viene el orden de las categorías en los ejemplos sobre la creación de tablas? Los datos en **table()** son interpretados como un “factor”. R usa factores para almacenar datos categóricos. La función para crear factores es **factor()** o **as.factor()** y tienen un conjunto de valores específicos llamados niveles, **levels()**.

Los factores no son vectores de datos aunque así lo parezcan. El orden inicial en un factor es determinado con la función **sort()**. Para retornar un carácter vectorial usamos **letters**. Y las letras en mayúscula están en **LETTERS**.



```
R Console
> 1:5
[1] 1 2 3 4 5
> factor(1:5)
[1] 1 2 3 4 5
Levels: 1 2 3 4 5
> mean(factor(1:5))
[1] NA
Warning message:
In mean.default(factor(1:5)) :
  argument is not numeric or logical: returning NA
> letters[1:5]
[1] "a" "b" "c" "d" "e"
> LETTERS[1:5]
[1] "A" "B" "C" "D" "E"
> factor(letters[1:5])
[1] a b c d e
Levels: a b c d e
> |
```

Análisis exploratorios de datos

Ejercicios de práctica:

1. Cargue y adjunte el conjunto de datos de central.park (UsingR). La variable WX contiene una lista de números que representan el mal tiempo (por ejemplo: 1 para la niebla, 3 para truenos, 8 para humo o neblina). NA se utiliza para cuando no se ha producido ninguno de los tipos, haga una tabla de los datos, luego haga una tabla adicional con el argumento exclude=FALSE. ¿Por qué es mejor la segunda tabla?
2. Realice un gráfico de puntos de la variable mpg en el conjunto de datos mtcars. Especifique el argumento labels= usando el comando rownames(mtcars), el cual retorna los nombres de cada uno de las filas de un marco de datos.
3. El conjunto de datos npdb (UsingR) contiene información sobre premios de malas prácticas en los Estados Unidos. Adjunta el conjunto de datos y haz una tabla de la variable state. ¿Cual estado tuvo la mayoría de premios? (Es útil usar sort() en tu tabla).