

Análisis de Metadatos I: Unidad 3 - Parte 1

Lenguaje de Programación en R

Jair Pallares Castellon, MSc.



Unidad III: Métodos inferenciales en R - Parte 1

Intervalos de confianza

Para comprender de qué se trata los intervalos de confianza, vamos a considerar un ejemplo de una muestra (encuesta sencilla).

Hay una **población** de 10000 personas, cada una tiene una fuerte **opinión** o alguna **proposición**. Deseamos conocer la verdadera proporción de la población que está por la proposición.

No podemos consultar a las 10000 personas, pero podemos tomar una **muestra** aleatoria de 100 personas.

Si la proporción de muestra es llamada de $\hat{p}$, y la proporción verdadera p , ¿Qué podemos concluir de p desconocida basados en $\hat{p}$? Algunas veces, podemos cambiar la pregunta a una relacionada a objetos simples.


En este caso, imagine 10000 bolas dentro de una caja con una cierta proporción p , etiquetadas con un “1” y las restantes etiquetadas con un “0”.

Seleccionamos 100 de estas bolas aleatoriamente y contamos las “1”. Suponga que la proporción verdadera para la población es $p = 0.56$. Significa que 5600 son para la **proposición** y 4400 están **en contra**.


Intervalos de confianza

Usamos la función **sample()** para obtener una muestra. R genera observaciones de una variable discreta con la función **sample()**, si un vector de datos **k** con los valores de la muestra y **P(Probabilidad)** las probabilidades de cada valor sea seleccionado, entonces el comando sería **sample(k, size=1, prob=P)**. La función **rep()**

```
R Console
> propocion = rep(0:1, c(10000 - 5600, 5600))
> phat = mean(sample(propocion, 100))
> phat
[1] 0.6
> res = c()
> for(i in 1:1000) res[i] = mean(sample(propocion, 100))
> quantile(res, c(0.1, 0.9))
10% 90%
0.50 0.62
> quantile(res, c(0.05, 0.95))
5% 95%
0.47 0.64
> quantile(res, c(0.025, 0.975))
2.5% 97.5%
0.46 0.66
> hist(res, probability=TRUE)
> hist(res, breaks="scott", probability=TRUE)
> hist(res, breaks="scott", probability=TRUE, main="Histograma de resultados guardados")
> |
```



La función **mean()** usada anteriormente nos permite encontrar la proporción. Si simulamos esta muestra 1000 veces podemos entender la distribución de la muestra (**phat**) $\hat{p}$. Almacenamos los resultados en un vector de datos llamado **res**.



Intervalos de confianza

Usamos los datos almacenados en **res** y observamos los intervalos de confianza en donde **phat** estaría.

Usamos también la función **quantile()**, para obtener los intervalos para 80%, 90% y 95%.

Construimos un histograma con la función **hist()** para observar gráficamente los intervalos de confianza (los valores ilustrados en el histograma fueron agregados usando un editor de imágenes).

El análisis realizado sugiere las siguientes probabilidades:

$$P(0.50 \leq \hat{p} \leq 0.62) = 0.80$$

$$P(0.47 \leq \hat{p} \leq 0.64) = 0.90$$

$$P(0.46 \leq \hat{p} \leq 0.66) = 0.95$$

En este ejemplo, sabemos que

$$p = 0.56$$

podemos reescribir esto como

$$0.50 = p - 0.06$$

entonces la anterior probabilidad quedaría de la siguiente manera:

$$P(p - 0.06 \leq \hat{p} \leq p + 0.06) = 0.80$$

$$P(-0.06 \leq \hat{p} - p \leq 0.06) = 0.80$$

$$P(\hat{p} - 0.06 \leq p \leq \hat{p} + 0.06) = 0.80$$

Este intervalo es llamado de **intervalo de confianza**, el cual muestra una cierta confianza de que el parámetro, p , está en este intervalo aleatorio.

Intervalos de confianza

Para poder usar una aproximación normal necesitaremos usar algunas asunciones sobre nuestro muestreo.

1. El tamaño de la **muestra** es mucho menor que el tamaño de la **población** de donde se extrae la muestra.
2. np y $n(1 - p)$ son ambos mayores que 5, a pesar de que p no es conocido.

Asumamos que el modelo binomial funciona, entonces la media de $\hat{p}$ es p y la desviación estándar (SD($\hat{p}$)) es

$$\sqrt{p(1 - p)/n}$$

si $1 - \alpha$ es nuestra probabilidad de confianza, entonces podemos encontrar la distribución de un correspondiente z^* por el cual

$$P(-z^* \leq Z \leq z^*) = 1 - \alpha$$

Intervalos de confianza

Como asumimos que $\hat{p}$ es aproximadamente normal, entonces

$$P \left(-z^* \leq \frac{\hat{p} - p}{SD(\hat{p})} \leq z^* \right) \approx 1 - \alpha$$

de aquí podemos notar que p está en el intervalo

$$(\hat{p} - z^* SD(\hat{p}), \hat{p} + z^* SD(\hat{p}))$$

con probabilidad $1 - \alpha$.

Hagamos otra suposición,

$$SD(\hat{p}) = \sqrt{p(1-p)/n} \approx SE(\hat{p}) = \sqrt{\hat{p}(1-\hat{p})/n}$$

En el límite central,

$$P \left(-z^* \leq \frac{\hat{p} - p}{SE(\hat{p})} \leq z^* \right) \approx 1 - \alpha$$

donde $SE(\hat{p})$ es llamado de **error estándar** de $\hat{p}$. Aquí asumimos que n es grande. Entonces el símbolo $\approx$ reemplazamos por $=$. El **intervalo de confianza**

$$(\hat{p} - z^* SE(\hat{p}), \hat{p} + z^* SE(\hat{p}))$$

La probabilidad es llamada de **nivel de confianza** y los valores $z^* SE(\hat{p})$ son el **margen de error**.

En R podemos usar la función **prop.test()** para calcular los intervalos de confianza de las proposiciones.

Intervalos de confianza

En algunos textos la probabilidad de un intervalo de confianza que anteriormente escribimos como

$$P(-z^* \leq Z \leq z^*) = 1 - \alpha$$

puede ser escrito de otra manera, donde z^* es llamado de $z_{\alpha/2}$

entonces podemos encontrar z^* a partir de α . En particular

$$\alpha/2 = P(Z \leq -z^*)$$

$$1 - \alpha/2 = P(Z \leq z^*)$$

En R estas expresiones se pueden escribir con los siguientes comandos

`zstar = -qnorm(alpha)`

`zstar = qnorm(1 - alpha)`

y la relación inversa puede ser encontrada de la siguiente forma

$$\alpha = 2 * pnorm(-zstar)$$

Usamos la función `qnorm( )` para especificar el área que queremos.

La **media** y la **desviación estándar** son tomados entre 0 y 1 que son valores por defecto. Por otro lado, la función `pnorm( )` es la inversa de la función `qnorm( )`.

Intervalos de confianza

Ejemplo #1: Desempeño del trabajo presidencial. Una encuesta de **Zogby América** involucró a 1,013 votantes probables seleccionados al azar de los 48 estados contiguos de los Estados Unidos utilizando números de teléfono residenciales listados. Los encuestadores encontraron que 466 votantes calificaron el desempeño laboral del presidente como "bueno" o "excelente". Encuentre un intervalo de confianza del 95% para la verdadera proporción.

Este tipo de encuesta es lo más cercano a una muestra aleatoria, aunque hay varias fuentes de posible sesgo a considerar. Por ejemplo, no todos tienen un número de teléfono residencial. Además, la falta de respuesta puede ser muy alta en tales encuestas. Para simplificar, supondremos que la muestra es una muestra aleatoria de la población de votantes probables y que $n = 1013$ es lo suficientemente grande para que se aplique la aproximación normal.

```
R Console
> n = 1013
> phat = 466/n
> SE = sqrt(phat*(1-phat)/n)
> alpha = 0.05
> zstar = -qnorm(alpha/2)
> zstar
[1] 1.959964
> c(phat - zstar * SE, phat + zstar * SE)
[1] 0.4293281 0.4907114
> phat + c(-1, 1)*zstar * SE
[1] 0.4293281 0.4907114
> |
```

Intervalo de confianza no incluye $p = 0.5$

Intervalos de confianza

Ejemplo #2: El nivel de confianza que falta. En los periódicos de los Estados Unidos los resultados de una encuesta a menudo se imprimen con la **proporción de la muestra**, el **tamaño de la muestra** y un **margen de error**. Casi siempre falta el nivel de confianza, pero se puede inferir de los tres datos. Si una encuesta tiene

$$\hat{p} = 0.57$$

$n = 1000$ y un margen de error de 3 puntos porcentuales, (3%) ¿qué es α ?

Suponiendo que la encuesta se realiza con una muestra aleatoria, tenemos que

$$z^* SE(\hat{p}) = 0.03$$

$$SE(\hat{p}) = \sqrt{0.57(1 - 0.57)/1000}$$

Resuelva para z^* y luego $1 - \alpha$ como sigue:

```
R Console
> ## aplicamos la formula para encontrar zstar
> zstar = 0.03 / sqrt(0.57 * (1-0.57)/1000)
> zstar
[1] 1.916239
> alpha = 2 * pnorm(- zstar)
> alpha
[1] 0.05533472
> 1 - alpha
[1] 0.9446653
> ## Existe un nivel de confianza del 95%
```

Intervalos de confianza


Usando `prop.test( )` para encontrar intervalos de confianza.

Los ejemplos anteriores se hicieron de manera difícil. Pero R proporciona una función integrada. `prop.test( )`, para calcular intervalos de confianza de proporciones. Una plantilla para el uso es

`prop.test(x, n, conf.level=0.95, conf.int=TRUE)`

La **frecuencia**, dada por **x**; el **tamaño de la muestra**, dado por **n**; y un **nivel de confianza**, establecido con `conf.level=`, debe especificarse. El nivel de confianza predeterminado es 0,95, y por defecto, se devolverá un intervalo de confianza.

En el ejemplo #1, $n = 1013$, $x = n \cdot \hat{p} = 466$, y $1 - \alpha = 0.95$.



```
> ## El intervalo de confianza es encontrado con
> prop.test(466, 1013, conf.level=0.95)

      1-sample proportions test with continuity correction

data:  466 out of 1013, null probability 0.5
X-squared = 6.3179, df = 1, p-value = 0.01195
alternative hypothesis: true p is not equal to 0.5
95 percent confidence interval:
 0.4290475 0.4912989
sample estimates:
             p 
0.4600197 

> ##La salida contiene mas información de la que necesitamos.
```

La función `bnom.test( )` puede usarse también para encontrar el intervalo de confianza, en este caso se usa una distribución binomial en lugar de una aproximación normal.

Ejercicios

Poniendo en práctica lo aprendido hasta el momento. Usar *R Console*:

1. Encuentre intervalos de confianza de 80% y 90% para una encuesta con $n = 100$ y $\hat{p} = 0.45$.
2. Un estudiante desea encontrar la proporción de personas zurdas. Ella encuesta 100 compañeros de estudios y descubre que sólo 5 son zurdos. Tiene un 95% de intervalo de confianza que contiene el valor de $p = 1/10$?
3. Un artículo del New York Times del 9 de octubre de 2003 contiene esta explicación sobre una encuesta de salida para una elección revocatoria de California:

En teoría, en 19 casos de 20, los resultados de dichas encuestas deberían diferir en no más o menos dos puntos porcentuales de lo que se habría obtenido buscando entrevistar a todos los que votaron en la elección de revocatoria.

Suponga una muestra aleatoria simple y $\hat{p} = 0.54$. ¿Qué tan grande fue n ?

4. Un antiguo comercial afirmaba que "Cuatro de cada cinco dentistas encuestados recomendarían Trident para sus pacientes que mascan chicle". Suponga que los resultados se basaron en una muestra aleatoria de la población de todos los dentistas. Encuentre un intervalo de confianza del 90% para la verdadera proporción si el tamaño de la muestra fuera $n = 5$. Repita con $n = 100$ y $n = 1000$.