

Fundamentos de la Ciencia de Datos

David Menoyo Ros
Eva García López
Antonio García Cabot

Fundamentos de la Ciencia de Datos

El contenido de este libro no podrá ser reproducido,
ni total ni parcialmente, sin el previo permiso escrito del editor.
Todos los derechos reservados.

© Editorial Universidad de Alcalá, 2021
Plaza de San Diego, s/n
28801 Alcalá de Henares
www.uah.es

I.S.B.N.:978-84-18254-94-9

Composición: Solana e Hijos, A. G., S.A.U.
Impresión y encuadernación: Solana e Hijos, A.G., S.A.U.
Impreso en España

Fundamentos de la Ciencia de Datos

David Menoyo Ros
Eva García López
Antonio García Cabot



Universidad
de Alcalá

EDITORIAL
UNIVERSIDAD DE ALCALÁ

ÍNDICE

1. RESUMEN	13
1.1. Español.....	13
1.2. English.....	13
2. CONCEPTOS	15
2.1. ¿Qué es el modelado estadístico o un modelo predictivo?	15
2.2. Paramétrico vs no paramétrico.	16
2.3. Suposición de independencia.....	16
2.4. Colinealidad.....	18
2.5. Normalidad. Estudio de la distribución de probabilidad	19
2.5.1. Histograma	21
2.5.2. Función de densidad (función de densidad de probabi- lidad).....	22
2.5.3. Función de distribución acumulada	24
2.5.4. Q-Q plots.....	28
2.5.5. Tukey mean-difference Q-Q plot	37
2.5.6. Test de Goodness-of-fit	39
2.5.6.1. Test de normalidad univariable	40
2.5.6.2. Test de normalidad multivariable.....	52
2.6. Homocedasticidad y heterocedasticidad	56
3. ESTADÍSTICA DESCRIPTIVA	65
3.1. Medidas de centralización	66
3.1.1. Media aritmética	66
3.1.2. Media geométrica	66
3.1.3. Media armónica.....	67
3.1.4. Mediana.....	68
3.1.5. Moda	68
3.1.6. Resumen	69

3.2.	Medidas de dispersión (<i>Measures of Variability</i>) o de calidad de las medidas de centralización.	71
3.2.1.	Suma de cuadrados (<i>Sum of squares</i>)	72
3.2.2.	Varianza sesgada (<i>Biased variance</i>)	73
3.2.3.	Covarianza (<i>Covariance</i>)	73
3.2.4.	Varianza no sesgada o imparcial (<i>Unbiased variance</i>) ...	73
3.2.5.	Desviación típica o estándar (<i>Standard deviation</i>)	74
3.2.6.	Desviación media (<i>Average absolute deviation o Mean absolute deviation (MAD)</i>)	74
3.2.7.	Coefficiente de variación (<i>Coefficient of variation o Relative standard deviation (RSD)</i>)	75
3.2.8.	Error estándar (<i>Standard error</i>)	75
3.2.9.	Límites de confianza (<i>Confidence interval o Confidence limits</i>)	83
3.2.10.	Resumen	94
4.	EVALUACIÓN DEL ERROR EN REGRESIÓN	99
4.1.	MSE (Error Medio Cuadrado o <i>Mean Squared Error/Deviation (MSD)</i>)	107
4.2.	RMSE (Error Cuadrático Medio o <i>Root Mean Squared Error/Deviation (RMSD)</i>)	108
4.3.	MAE (Error Absoluto Medio o Mean Absolute Error)	108
4.4.	R^2 (R-cuadrado, Coeficiente de determinación o coeficiente de correlación)	109
4.4.1.	Conceptos importantes	109
4.4.2.	Definición intuitiva de R^2	110
4.4.3.	Definición formal de R^2	117
4.4.4.	Inconvenientes de R^2	118
4.5.	R^2 ajustado	118
4.6.	Resumen.	119
5.	EVALUACIÓN DEL ERROR EN CLASIFICACIÓN	121
5.1.	Exactitud (Accuracy)	124
5.2.	Precisión (Precision)	126
5.3.	Sensibilidad (Recall)	127
5.4.	Especificidad (Specificity)	128
5.5.	Puntaje de F1 (F1 score)	129
5.6.	Resumen.	130
6.	TEST DE HIPÓTESIS	131
6.1.	Idea intuitiva sencilla del test de hipótesis.	131
6.2.	Idea intuitiva más avanzada del test de hipótesis.	132
6.3.	Idea intuitiva de hipótesis nula e hipótesis alternativa.	135

6.3.1.	Ejemplo de un dispensador de bebida.	136
6.3.2.	Ejemplo de las horas de estudio en adolescentes	136
6.3.3.	Ejemplo de tiempo en entregar comida china.	137
6.3.4.	Ejemplo de cara o cruz	137
6.4.	Nivel de significancia.	138
6.5.	Compromiso entre falsos positivos y falsos negativos	139
6.6.	P-values	139
6.6.1.	Ejemplo discreto. Lanzar dos veces una moneda	140
6.6.2.	Ejemplo continuo. Altura	145
6.7.	One-tailed vs two-tailed p-values	153
6.7.1.	Two-tailed	155
6.7.2.	One-tailed de tipo Lower	156
6.7.3.	One-tailed de tipo Upper.	158
6.8.	Resumen del test de hipótesis	161
7.	PROCESO DE MACHINE LEARNING. CONCEPTOS Y TÉCNICAS.	163
7.1.	Introducción. IA y los datos.	163
7.2.	Generalización	166
8.	ALGORITMOS IMPORTANTES DE APRENDIZAJE AUTOMÁTICO	169
8.1.	Máquinas Vector Soporte (SVM).	169
8.1.1.	Características	169
8.1.2.	Hiperplano y Maximal Margin Classifier	170
8.1.3.	Support Vector Classifier - Soft Margin SVM	175
8.1.4.	Modelo de clasificación vs regresión	177
8.1.5.	Kernels. Aumento de la dimensión	185
8.1.6.	Ejemplo sencillo de SVM.	189
8.1.7.	Algoritmos comunes para SVM de dos clases o más	197
8.1.7.1.	SVM para más de dos clases. Ejemplo con algoritmos one-versus-one	198
8.1.7.2.	Coste computacional de un SVM.	201
8.2.	Random Forest.	201
8.2.1.	Ventajas y Desventajas	202
8.2.2.	Compensación Bias-Varianza	203
8.2.3.	Operaciones típicas en la confección de un árbol.	205
8.2.3.1.	Greedy Splitting - Crecimiento del árbol	205
8.2.3.2.	Controlar el tamaño del árbol - Condición de parada	205
8.2.3.3.	Pruning - Podado del árbol.	206
8.2.4.	Métodos de ensemble - Métodos de combinación	206
8.2.4.1.	Bagging.	207
8.2.4.2.	Random Forest	207

8.2.4.3.	Boosting	209
8.2.5.	Ejemplo completo	209
8.3.	Redes Neuronales.....	223
8.3.1.	Introducción	223
8.3.2.	Ejemplo 1	226
8.3.3.	Ejemplo 2	228
8.3.4.	Ejemplo 3	232
9.	TRANSFORMACIÓN DE LOS DATOS (DATA TRANSFORMATION).	237
9.1.	Mantener los datos en la misma escala o unidad de medición ...	237
9.2.	Transformar los valores numéricos en una escala normalizada, generalmente entre 0 y 1	238
9.3.	Transformar los valores numéricos a una escala estandarizada en media 0 y desviación típica 1.....	239
9.4.	Transformar la distribución de los datos	240
9.4.1.	Transformación logarítmica	241
9.4.2.	Transformación raíz cuadrada.....	242
9.4.3.	Transformación arcoseno	242
9.5.	Resumen.....	242
10.	IMPUTACIÓN DE VALORES VACÍOS.	247
10.1.	Tipos de valores faltantes.....	248
10.2.	Teoría sobre la imputación.....	249
10.3.	Técnicas generales	250
10.3.1.	Introducción	250
10.3.2.	MICE.....	250
10.3.3.	Amelia.....	278
10.3.4.	MissForest.....	287
10.3.5.	Hmisc	292
11.	Reducción de dimensionalidad	299
11.1.	Introducción a la reducción de dimensionalidad	299
11.2.	Beneficios de la reducción de dimensionalidad.....	300
11.3.	Inconvenientes de la reducción de dimensionalidad	301
11.4.	Selección de características	301
11.4.1.	Valores vacíos	301
11.4.2.	Baja varianza.....	301
11.4.2.1.	Ejemplo.....	302
11.4.3.	Alta correlación	303
11.4.3.1.	Ejemplo.....	303
11.4.4.	Random Forest	305
11.4.4.1.	Selección de variables	306
11.4.4.2.	Ordenación de variables según su importancia	308

11.5. Reducción de dimensionalidad. PCA.	309
11.5.1. Introducción fundamentos.	309
11.5.2. Proceso matemático PCA	314
11.5.3. Conclusiones de PCA	340
11.5.4. Probando PCA para crear modelo de regresión con Random Forest	342
12. DETECCIÓN DE VALORES ATÍPICOS	359
12.1. Introducción.	359
12.1.1. Outliers y ruido	360
12.1.2. Tipos de outliers	361
12.1.3. Métodos de detección de outliers	362
12.1.4. ¿Qué hacer con los outliers?	363
12.2. Diagrama de caja y bigotes	363
12.3. Desviación típica. Dispersión	368
12.4. Error estándar de residuos. Regresión	370
12.5. K-vecinos.	378
12.6. Isolation Forest.	385
12.7. DBSCAN	389
13. CONCLUSIONES	399
14. BIBLIOGRAFÍA	403

1. RESUMEN

1.1. ESPAÑOL

El presente libro explicará los conceptos más importantes de la ciencia de los datos, empezando por diversos fundamentos teóricos y estadísticos imprescindibles, para después abordar con garantías diversas técnicas avanzadas. Los fundamentos teóricos abarcan desde el apartado **Conceptos** hasta **Test de Hipótesis**. Después, en los siguientes dos apartados se explican aspectos muy importantes del aprendizaje automático. Y para finalizar, se explican las técnicas más propias de la ciencia de los datos que mejoran el rendimiento de los algoritmos de aprendizaje automático, ya sea en términos de rendimiento o en términos de optimización de tiempos y costes computacionales.

Palabras clave: Ciencia de los datos, inteligencia artificial, máquinas vector soporte, random forest, fundamentos estadísticos, transformación de los datos, reducción de dimensionalidad, PCA, selección de características, imputación de valores vacíos, detección de valores atípicos.

1.2. ENGLISH

This paper will explain the most important concepts in data science, starting with various essential theoretical and statistical foundations, to later address various advanced techniques with guarantees. The theoretical foundations range from the section **Concepts** to **Hypothesis Test**. Then, in the next two sections, very important aspects of automatic learning are explained. And finally, the most typical techniques of data science that improve the performance of machine learning algorithms are explained, either in terms of performance or in terms of optimization of computational times and costs.

Keywords: Data science, machine learning, support vector machines, random forest, statistical fundamentals, data transformation, dimensionality reduction, PCA, feature selection, missing data imputation, outlier detection.

2. CONCEPTOS¹

2.1. ¿QUÉ ES EL MODELADO ESTADÍSTICO O UN MODELO PREDICTIVO?

Exponemos diversas definiciones:

Según **Wikipedia**:

El análisis predictivo agrupa una variedad de técnicas estadísticas de modelización, aprendizaje automático y minería de datos que analiza los datos actuales e históricos para hacer predicciones acerca del futuro o de acontecimientos no conocidos.

Según **XLSTAT**:

En términos sencillos, el modelado estadístico es una forma simplificada y matemáticamente formalizada de aproximarse a la realidad (i.e., la que genera los datos) y, opcionalmente, hacer predicciones a partir de dicha aproximación. Veamos un ejemplo básico: Supongamos que deseamos informar sobre el peso de una variedad de patatas. Podemos considerar una forma difícil y otra fácil de hacerlo. La difícil consiste en emplear años midiendo el peso de cada patata de esta variedad a lo largo del mundo, y trasladar los datos a una hoja Excel interminable. La fácil, consiste en seleccionar 30 patatas ampliamente representativas de la variedad que nos interesa, calcular su media y su desviación estándar, e informar únicamente sobre esas magnitudes como una descripción aproximada del peso. Representar una cantidad por una media y una desviación estándar es una forma muy simple de modelado estadístico.

Otro ejemplo es intentar representar la altura de las plantas en función del agua del suelo mediante una línea recta caracterizada por una pendiente y una inter-

¹ Algunos de los recursos consultados en esta sección se corresponden con: [1], [2], [3], [4], [5], [6], [7], [8], [9], [10], [11], [12], [13], [14], [15], [16], [17], [18], [19], [20], [21], [22] y [23].

cepción, trazada después de realizar un experimento sobre una muestra de plantas sometidas a una humedad del suelo creciente. Este modelo particular se denomina regresión lineal simple.

Según **MicroStrategy**:

El modelado predictivo es un sistema que emplea datos y estadísticas para predecir resultados a partir de unos modelos de datos. Estos modelos se pueden utilizar para predicciones de todo tipo; desde resultados deportivos y audiencias televisivas hasta avances tecnológicos y ganancias empresariales.

2.2. PARAMÉTRICO VS NO PARAMÉTRICO

Muchas técnicas y algoritmos estipulan que para funcionar bien, necesitan que los datos cumplan algunas determinadas propiedades, mientras que otras técnicas no asumen ni necesitan ninguna propiedad en los datos que van a manejar. De esta manera, definimos:

- **Paramétrico:** Se corresponde con las técnicas que asumen o requieren que los datos manejados cumplan unas determinadas condiciones. Por ejemplo, podría requerirse que los datos de las variables tengan que seguir una distribución normal. De esta manera, como la técnica asume la premisa anterior como cierta, toma ventaja de esa propiedad e internamente aplica las matemáticas adecuadas para realizar su cometido correctamente. En este caso concreto, como se asume que la distribución es normal, la técnica utilizará internamente los parámetros de la media y la varianza sin ningún miedo, ya que dichos parámetros describen con precisión toda distribución normal, cuya fórmula es:

$$\Phi_{\mu,\sigma^2}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

donde μ es la media y σ^2 es la varianza.

- **No paramétrico:** Se corresponde con las técnicas que no asumen ni requieren que los datos manejados cumplan ninguna determinada condición. En definitiva, es justamente lo opuesto a una técnica paramétrica, es más, podríamos llamar a las técnicas no paramétricas como técnicas de tipo *distribution-free*, ya que no exigen que se cumpla ninguna distribución en especial.

2.3. SUPOSICIÓN DE INDEPENDENCIA

Muchos tests estadísticos asumen que las observaciones son independientes entre sí. Si esto no se cumple, los resultados obtenidos de los tests serán erróneos o estarán

fuertemente sesgados (*biased*), lo cual no es para nada deseable, sobre todo si se pretende obtener un resultado que, desde una muestra concreta, se pretenda generalizar a toda una población o universo. Además, se corre el riesgo de obtener con más facilidad los indeseados falsos positivos en los tests.

Una relación de dependencia refleja que existe una conexión o dependencia entre los datos, por ejemplo: El dinero que ganas depende de las horas que trabajas, esto es una relación de dependencia; en cambio, el dinero que ganas no está conectado con la música que escuchas en casa, por lo que esto es una relación de independencia, o por lo menos lo será en nuestro modelo concreto del problema.

La suposición de independencia asume lo siguiente:

- **Las observaciones entre grupos deben de ser independientes**, lo que en definitiva significa que los grupos se tienen que formar por individuos diferentes, no puede aparecer el mismo individuo en ambos grupos.
- **Las observaciones que hay dentro de cada grupo tienen que ser independientes**, es decir, no puede haber ninguna condición o sesgo que por ejemplo esté haciendo que los individuos de un grupo compartan alguna condición en concreto. Por ejemplo, que todos los individuos vengan del mismo padre, o que todas las mediciones se realicen en la misma franja horaria pueden ser claros sesgos que no garantizan la independencia entre los individuos u observaciones.

Algunos ejemplos de observaciones que no son independientes:

- Queremos saber si los gatos siberianos tienen un peso promedio diferente respecto a los gatos himalayos. Conseguimos 5 gatos de cada raza y los pesamos para después realizar algún test con los resultados. El problema es que los 5 gatos de raza siberiana provienen de la misma camada, y los 5 gatos de raza himalaya provienen de otra segunda camada, por lo tanto, las mediciones no son independientes puesto que el peso de los gatos dependerá mucho de sus padres, ya que hay padres que generan hijos con menor o mayor peso. De esta manera, si los 5 gatos siberianos se llaman Pepe, Rodolfo, Peter, Paca y Marta, y calculamos que Pepe tiene un peso bajo, al tener gatos que no son muestras independientes de Pepe (puesto que son hermanos y provienen de la misma camada), es muy probable que Rodolfo, Peter, Paca y Marta tengan también un peso bajo, generando en definitiva un resultado extremadamente sesgado y poco independiente, en donde no sería correcto generalizar el resultado a toda una raza.
- Queremos medir un cierto valor sobre el comportamiento de las personas, y lo hacemos durante unos cuantos meses, pero siempre de 8:00 hasta las 10:00. Esto puede ser un tremendo error, ya que a esas horas es muy probable que alguna actividad (desayuno, sueño, menor temperatura ambiental, trabajo, etc.) esté sesgando nuestros resultados, en cambio, si las mediciones las reali-

zármanos a más horas, por ejemplo de 9:00 a 11:00, de 2:00 a 5:00 y de 7:30 a 22:00, es mucho más probable que se introduzcan menos sesgos y consigamos en definitiva unas medidas más independientes entre sí.

- Queremos saber si la clase de matemáticas es más aburrida que la de física mediante la medición de cuántos alumnos bostezan. De esta manera, colocamos una cámara y contabilizamos que en clase de matemáticas 32 alumnos bostezan y 8 no; mientras que en clase de física 7 bostezan y 33 no. Parece evidente que la clase de matemáticas es más aburrida que la de física, pero es posible que sea pura casualidad, ya que sabemos que el bostezo es muy contagioso, por tanto en la clase de matemáticas se propagó con más fuerza que en la de física por simplemente una cuestión de que los alumnos se estaban mirando o no.

En definitiva, **¿cómo evitamos violar la suposición de independencia?**

La clave para respetar la suposición de independencia se basa en comprobar que los datos que estemos recolectando sean independientes **durante la recolección de esos datos**, por lo tanto se necesita de un muy buen conocimiento del dominio del problema. Enfatizamos: **durante la recolección de los datos**, puesto que una vez recogidos, es muy probable que se nos escapen razones del dominio que nos impidan ver con claridad las faltas de independencias generadas en el proceso de recolección, sobre todo si no somos conocedores del proceso que se llevó a cabo en la obtención de los datos de los individuos.

Por ejemplo, en el caso de los gatos, un biólogo sabría que la camada condiciona mucho el tamaño de los hijos, por lo que para evitar esa dependencia, el experimento utilizaría gatitos de diferentes camadas. En el ejemplo de los bostezos, simplemente habría que tener en cuenta la posible propagación del bostezo con la mera mirada, por lo que habría que establecer medidas para que los alumnos no se pudieran mirar entre sí mediante el uso de algún sistema de paredes.

2.4. COLINEALIDAD

En la misma línea que la **suposición de independencia**, tenemos la **colinealidad** o multicolinealidad.

La colinealidad es un fenómeno en el cual dos variables están correlacionadas. Concretamente, se dice que dicha correlación se produce entre las variables independientes (también llamadas variables explicativas, aquellas que usamos para explicar/predecir las variables dependientes). Si el fenómeno afecta a más de dos variables, se denomina multicolinealidad.

En definitiva, es indeseable que las variables independientes de nuestro modelo se encuentren fuertemente correlacionadas, puesto que implica una serie de dificul-

tades a nivel matemático y estadístico que dificultan la creación de modelos predictivos correctos.

No obstante, la no correlación solo se obtiene en entornos de laboratorio, por lo que en entornos prácticos siempre habrá algún grado de colinealidad entre las variables, pero a ser posible, tiene que ser mínimo.

Algunos problemas que puede producir la multicolinealidad:

- Las varianzas de los estimadores de los coeficientes de regresión se vuelven muy grandes
- Los coeficientes estimados serán muy sensibles ante pequeñas variaciones en los datos respecto a los datos empleados para realizar la regresión.
- Funcionamiento impreciso de los test de hipótesis

2.5. NORMALIDAD. ESTUDIO DE LA DISTRIBUCIÓN DE PROBABILIDAD

Una distribución de probabilidad se encarga de especificar la probabilidad de obtener una observación en un rango concreto de valores. De esta manera, una distribución normalmente distribuida nos dice que tenemos una alta probabilidad de obtener valores cercanos al centro, mientras que tenemos una baja probabilidad de obtener valores que se alejen del centro.


Muchas técnicas asumen o requieren que los datos que se manejan estén normalmente distribuidos, por ello, saber explorar los datos para detectar si cumplen una distribución normal resulta crucial.

Una distribución normalmente distribuida queda perfectamente definida por la desviación típica (o varianza, según se mire) y la media. Recordemos que la fórmula de una distribución normal (también conocida como campana de gauss) es:

$$\Phi_{\mu,\sigma^2}(x) = \frac{1}{\sigma\sqrt{2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

donde μ es la media y σ^2 es la varianza. Su función de densidad de probabilidad es:

**Función de densidad de una
distribución normal
con media 0 y desviación típica 1**



Las técnicas más empleadas para estudiar la normalidad (o cualquier otra distribución) son:

- Histogramas (*histograms*)
- Diagramas de densidad (*density plots*)
- Funciones de distribución acumulada (*comulative distribution function (cdf)*)
- Q-Q plots (*Quantile-Quantile plots* o gráficas Cuantil-Cuantil en español)
- Tukey mean-difference Q-Q plot
- Test de Goodness-of-fit

Veremos cada una de las anteriores técnicas con especial aplicación en la distribución normal, pero para tener una visión más amplia, también veremos a la vez