



Análisis de Metadatos I:

Unidad 2 - Parte 2

Lenguaje de Programación en R

Jair Pallares Castellon, MSc.

Unidad II: Exploración de datos - Parte 2

Análisis exploratorios de datos

Gráficos de tallo (stem) y hoja: Los datos pueden ser organizados de una mejor forma para que estos sean más claros. Un camino para esto, es usar la función **stem()**, donde los dígitos son las hojas y el tallo (stem) es el valor del dato a su izquierda, por ejemplo: 23, el (2) es el tallo y el (3) es la hoja. Estos son escritos en *R Console* como **2 | 3**. Los gráficos de tallo y hoja nos brindan un buen entendimiento de el conjunto de datos, podemos observar los valores máximos y mínimos.

Ejemplo: consideremos el número de puntos de cada integrante de un equipo de basquetbol:

2 3 16 23 14 12 4 13 2 0 0 0 6 28 31 14 4 8 2 5

```
R Console

> x = scan()
1: 2 3 16 23 14 12 4 13 2 0 0 0 6 28 31 14 4 8 2 5
21:
Read 20 items
> stem(x)

The decimal point is 1 digit(s) to the right of the |

0 | 000222344568
1 | 23446
2 | 38
3 | 1

> stem(x, scale=2)


The decimal point is 1 digit(s) to the right of the |

0 | 000222344
0 | 568
1 | 2344
1 | 6
2 | 3
2 | 8
3 | 1
```

Análisis exploratorios de datos

Gráficos de línea (strip): Este gráfico ilustra cada valor como un punto a lo largo de una línea (strip) y es creado con la función `stripchart()`. el argumento extra `methods="stack"` crea una pila de lazos. De lo contrario, múltiples valores son mostrados como un único gráfico.

Ejemplo: Consideremos los datos relacionados al peso de los niños de 4 años localizados en el conjunto de datos `kid.weights` en (UsingR). Usamos también algunos comandos para mejorar la visualización del gráfico, como es el caso de `cex=` que cambia el tamaño de los caracteres del gráfico y `offset=` que separa los puntos. Otra forma de visualizar este gráfico es usando la función `DOTplot()` disponible en (UsingR).



Estadística descriptiva

El centro: media, mediana y moda:

Aquí vamos a comprender de qué se trata la tendencia central. La noción más familiar del centro de un conjunto de datos es el valor promedio de los números. Esto en estadística es llamado **media aritmética** (`mean()`)

$$\bar{x} = \frac{x_1 + x_2 + \dots + x_n}{n}$$

Existen argumentos especiales que pueden ser agregados a la función `mean()`, los cuales son: **trim=** que realiza un recorte en la media y **na.rm=** que remueve datos perdidos. Grandes valores pueden sesgar el promedio. Por otro lado, la **mediana** (`median()`) es el valor medio de los valores ordenados y es bastante útil cuando la media falla,

$$m = \begin{cases} x_{k+1} & n = 2k + 1 (\text{impar}) \\ \frac{1}{2}(x_k + x_{k+1}) & n = 2k (\text{par}) \end{cases}$$


```
R Console
> x = scan()
1: 2 3 16 23 14 12 4 13 2 0 0 0 6 28 31 14 4 8 2 5
21:
Read 20 items
> sum(x)/length(x)
[1] 9.35
> mean(x)
[1] 9.35
> |
```

```
R Console
> bar = c(50, 60, 100, 75, 200)
> bar.with.gates = c(bar, 50000)
> mean(bar)
[1] 97
> mean(bar.with.gates)
[1] 8414.167
> median(bar)
[1] 75
> median(bar.with.gates)
[1] 87.5
> |
```

Estadística descriptiva

El centro: media, mediana y moda:

Cuando en un conjunto de datos un valor se repite varias veces, este valor es conocido como **moda**, en R no hay una función que te permita obtener la moda de un conjunto de datos. La moda no es un buen resumen de un conjunto de datos. Para encontrar la moda podemos usar un conjunto de comandos. Ejemplo. Consideremos los datos: **72 75 84 84 98 94 55 62**. Observando estos datos podemos ver que la moda es 84, ya que es el valor que más se repite. La función **which.max()** determina la posición del máximo en el vector de datos, para encontrar este valor usamos **which.max(table(x))**. El **rango medio** puede ser obtenido usando la función **mean(range(x))**.



```
R Console
> x = scan()
1: 72 75 84 84 98 94 55 62
9:
Read 8 items
> which(table(x) == max(table(x)))
84
5
> which.max(table(x))
84
5
> mean(range(x))
[1] 76.5
> |
```


Estadística descriptiva

Variación: La varianza, desviación estándar.

Rango de la muestra: Un camino para medir la dispersión de n datos es usando la función `range()`. Esta función se refiere a la distancia entre valores muy pequeños y muy grandes. La diferencia entre estos valores es calculada con `diff(range(x))`, siendo x un conjunto de datos. El término *distancia* es el valor absoluto de diferencia de dos puntos, es decir siempre es positivo. La *diferencia* entre dos puntos puede ser negativa. A esto le llamamos *desviación*.

Varianza de la muestra (`var()`): Es la variación en torno al valor medio (mean) y la variación de un único dato puede ser obtenido por $(x_i - \text{valor medio})$.

$$s^2 = \frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2$$

Y la **desviación estándar de la muestra (`sd()`)**:

$$s = \sqrt{\frac{1}{n-1} \sum_{i=1}^n (x_i - \bar{x})^2}$$

Grandes valores de s indican más dispersión.


```
R Console
> test.scores = c(80, 85, 75, 77, 87, 82, 88)
> test.scores.b = c(100, 90, 50, 57, 82, 100, 86)
> mean(test.scores)
[1] 82
> mean(test.scores.b)
[1] 80.71429
> n = length(test.scores)
> (1/(n-1))*sum((test.scores - mean(test.scores))**2)
[1] 24.66667
> var(test.scores)
[1] 24.66667
> var(test.scores.b)
[1] 394.2381
> sd(test.scores)
[1] 4.966555
> |
```

Estadística descriptiva

Cuantiles, quintiles, percentiles y más: Los cuantiles generalizan el concepto de mediana, estos suelen usarse por grupos que dividen la distribución en partes iguales.

- Los **percentiles** dividen la distribución en 100 partes.
- Los **cuartiles** en 4 partes, (0, 25, 50, 75, 100).
- Los **quintiles** en 5 partes, (0, 20, 40, 60, 80, 100).

La función **quantile()** devuelve los cuantiles. Esta función es llamada con los vectores de datos uno o vario valores del cuantil. Cuando no se indica el cuantil, entonces por defecto dá los cuartiles.



```
R Console
> x = 0:5
> length(x)
[1] 6
> sum(sort(x)[3:4])/2
[1] 2.5
> median(x)
[1] 2.5
> quantile(x, .25)
25%
1.25
> quantile(x, c(0.25, 0.5, 0.75))
25% 50% 75%
1.25 2.50 3.75
> quantile(x)
0% 25% 50% 75% 100%
0.00 1.25 2.50 3.75 5.00
> |
```


Estadística descriptiva

Ejemplo: Use el conjunto de datos `exec.pay` contenido en el paquete `UsingR` el cual contiene datos sobre la compensación de los CEO de 199 compañías de Estados Unidos en el año 2000 en unidades de \$10,000. Los datos no están simétricamente distribuidos, como un gráfico de tallo y hoja mostraría. vamos a usar la función `quantile()` para mirar los datos.

```
R Console
> sum(exec.pay > 100)/length(exec.pay)
[1] 0.09045226
> quantile(exec.pay, 0.9)
90%
91.4
> quantile(exec.pay, 0.99)
99%
906.62
> sum(exec.pay <= 10)/length(exec.pay)
[1] 0.1457286
> quantile(exec.pay, 0.10)
10%
9
> |
```

R Console								
exec.pay								
[1]	136	74	8	38	46	43	9	9
[9]	12	11	20	9	95	34	7	14
[17]	39	12	29	21	60	35	17	36
[25]	29	162	88	31	6	135	13	20
[33]	9	14	28	42	10	35	2	16
[41]	28	42	142	33	134	23	34	16
[49]	13	167	9	22	39	28	30	22
[57]	14	9	25	106	32	30	89	89
[65]	47	17	26	1231	6	103	48	24
[73]	11	19	13	29	20	45	3	33
[81]	41	7	11	10	22	36	7	19
[89]	41	40	10	15	93	67	29	25
[97]	91	38	2510	5	32	65	0	13
[105]	27	16	21	6	0	28	8	13
[113]	71	36	11	106	37	41	13	900
[121]	38	24	15	27	12	12	22	40
[129]	49	22	118	48	10	1	36	155
[137]	9	34	29	12	0	28	21	32
[145]	18	52	29	13	199	40	11	51
[153]	45	43	31	5	18	15	25	9
[161]	18	13	58	22	40	34	16	31
[169]	27	15	23	49	60	28	74	42
[177]	24	17	9	61	20	23	26	31
[185]	167	19	14	13	146	283	12	53

Estadística descriptiva

Ejercicios de práctica:

1. Lea este gráfico de tallo y hoja. Primero encuentre la mediana a mano (calcule a lápiz y papel). Entonces introduzca los datos y encuentre la mediana usando `median()`.

El punto decimal es de 1 dígito a la derecha de |

8 | 028

9 | 115578

10 | 1669

11 | 01

2. El conjunto de datos `pi2000` (UsingR) contiene los primeros 2000 dígitos de π . ¿Cuál es el porcentaje de dígitos que son menores o iguales a 3? ¿cuál es el porcentaje de dígitos que son mayores o iguales a 5?