



Análisis de Metadatos I:

Unidad 2 - Parte 3

Lenguaje de Programación en R

Jair Pallares Castellon, MSc.

Unidad II: Exploración de datos - Parte 3

Pruebas de normalidad

Para establecer y entender la **normalidad de un conjunto de datos**, existe una gran cantidad de modelos y procedimientos. Algunas de ellos son:

- **Histograma y/o densidad**
- **Gráficos de cuartil (QQplot)**
- **Pruebas de Hipótesis** (Unidad 3)

En un **histograma y/o densidad** para la variable de interés se puede evaluar la **simetría** de la distribución de datos. Si se observa una **asimetría** (sesgo de algún dato) esto indicará que la muestra no proviene de una población normal.

Por otro lado, si se observa una simetría en los datos, esto no garantiza que la muestra proviene de una población normal. Por lo tanto, se requiere recurrir a otras herramientas. El **Histograma** y el **gráfico de densidad** nos permiten observar la distribución, la simetría, el sesgo, la variabilidad, la moda, la mediana y observaciones atípicas de un conjunto de datos.


Para explorar la normalidad de un conjunto de datos, lo que se busca es un patrón más o menos simétrico en un histograma o gráfico de densidad.

Primero observemos cómo construir un histograma y gráficos de densidad en R.

Pruebas de normalidad

Un **Histograma** es una distribución gráfica de un conjunto de datos. Nos permite visualizar dónde están los mayores datos y dónde están los menores datos. El histograma que observamos a la derecha está relacionado a la variable **waiting** del conjunto de datos **faithful**, relacionado al tiempo de espera entre erupciones del “Viejo Fiel”, géiser de Yellowstone en USA. El histograma es creado con la función **hist()**. Este usa barras para mostrar frecuencias y proporciones.

```
R Console
> attach(faithful)
> hist(waiting)
> |
```






Pruebas de normalidad

El argumento **breaks**= dentro de la función **hist()**, nos permite asignar un nombre de un algoritmo, el número de rupturas deseadas o la localización de la ruptura.

```
R Console
> hist(waiting, breaks=10)
> hist(waiting, breaks=seq(43, 108, length=10))
> hist(waiting, breaks="scott")
> |
```

Para dibujar un histograma de frecuencias o proporciones debemos usar el argumento **probability**=. Por defecto se usa FALSE, pero se recomienda usar TRUE.


```
R Console
> hist(waiting)
> hist(waiting, probability=TRUE)
> |
```



Pruebas de normalidad

Ejemplo: Porcentaje de bases en Béisbol. Los resúmenes estadísticos son una base importante en el béisbol. Una estadística común es el “**porcentaje en base**” (OBP), el cual indica que tan efectivo es el jugador como bateador. Este “**porcentaje**” es usualmente dado como una “**proporción**” o un número entre 0 y 1. El conjunto de datos (UsingR) contienen OBP del año 2002, de acuerdo con el conjunto de datos de Sam Lahman (<http://www.baseball1.com>).

```
R Console
> hist(OBP, breaks="Scott", probability=TRUE, col=gray(0.9))
> |
```



Claramente el gráfico considerado aquí es unimodal y simétrico


Pruebas de normalidad

Estimando la densidad: Con la función `density( )` encontraremos la densidad estimada a partir de los datos. Para usar esto, es necesario usar la función `plot( )` o la función `lines( )` que nos permite usar un vector de datos y, opcionalmente, un argumento asociado al algoritmo usado.

```
R Console
> attach(faithful)
> hist(waiting, breaks="scott", probability=TRUE, main="", ylab="")
> lines(density(waiting))
> detach(faithful)
> |
```

Cada pico en una densidad estimada está asociado a un **Modo**. El gráfico de la derecha es de tipo **Bimodal**.

Claramente el gráfico considerado aquí es asimétrico



Pruebas de normalidad

Pruebas de normalidad: Una forma alternativa para explorar la normalidad de un conjunto de datos es a través de la pruebas de normalidad. Las hipótesis (Nula y Alternativa) para pruebas son:

H_0 : La muestra proviene de una población normal.

H_A : La muestra NO proviene de una población normal

En la literatura se reportan varias pruebas estadísticas de este tipo, algunas de ellas se listan a continuación.

1. Prueba **Shapiro-Wilk** con la función **shapiro.test**.
2. Prueba **Anderson-Darling** con la función **ad.test** del paquete **nortest**.
3. Prueba **Cramer-von Mises** con la función **cvm.test** del paquete **nortest**.
4. Prueba **Lilliefors (Kolmogorov-Smirnov)** con la función **lillie.test** del paquete **nortest**.
5. Prueba **Pearson chi-square** con la función **pearson.test** del paquete **nortest**.
6. Prueba **Shapiro-Francia** con la función **sf.test** del paquete **nortest**.

Pruebas de normalidad

Prueba Pearson chi-square o chi-cuadrado:

La prueba chi-cuadrado de Pearson contrasta si las diferencias observadas entre los dos grupos son atribuibles al azar. $H_0 = \text{Sí hay independencia entre las variables}$ ($p > 0,05$) $H_1 = \text{No hay independencia entre las variables}$ ($p < 0,05$), o bien las variables son dependientes. Esta prueba es implementada por la función `chisq.test(x, p=...)` los datos son dados en una forma tabulada `x`: la hipótesis nula es especificada con el argumento `p=` como un vector de probabilidades.

Ejemplo: Fumadores jóvenes. El conjunto de datos `samhda` (UsingR) contiene información acerca del comportamiento de la salud de los niños en edad escolar. **Por ejemplo:** la variable `amt.smoke` mide qué tan frecuente un niño fumó el mes anterior. Hay 7 niveles: 1 indica que él fumó todos los días y 7 indica ninguna vez. Valores 98 y 99 indican datos perdidos. Ver `?samhda` para una descripción. Investigaremos si o no la proporción de la muestra está de acuerdo con las probabilidades:

$p_1 = .15, p_2 = .05, p_3 = .05, p_4 = .05, p_5 = .10, p_6 = .20, p_7 = .40,$

```
R Console
> library(UsingR)
> attach(samhda)
> y = table(amt.smoke[amt.smoke < 96])
> y
  1  2  3  4  5  6  7
32  7 13 10 14 43 105
> p = c(.15, .05, .05, .05, .10, .20, .40)
> chisq.test(y, p = p)

      Chi-squared test for given probabilities

data:  y
X-squared = 7.9382, df = 6, p-value = 0.2427

> detach(samhda)
> |
```


El valor de $p = 0.2427$ no es significativo

Pruebas de normalidad

Prueba Shapiro-Wilk:

La prueba de Shapiro-Wilk permite analizar la normalidad de un conjunto de datos. Esta prueba estadística está basada en las ideas relacionadas a gráficos de cuantiles, los cuales pueden usarse para medir la normalidad. Su definición es algo complicada, pero su uso en R es directa. En R la función `shapiro.test(x)` realizará la prueba, where `x` is vector que contiene la muestra de los datos.

En un ejemplo anterior, analizamos la distribución del porcentaje sobre la base de la temporada 2002 mostrada por la liga de beisbol. Observamos una campana. ¿Estos datos vienen de una distribución de población normalizada?



```
R Console

> shapiro.test(OBP)

      Shapiro-Wilk normality test

data:  OBP
W = 0.97092, p-value = 1.206e-07

> shapiro.test(OBP[OBP < .5])

      Shapiro-Wilk normality test

data:  OBP[OBP < 0.5]
W = 0.99049, p-value = 0.006404

> |
```

La conclusión es la misma: los datos no son normalmente distribuidas.

Estadística descriptiva

Ejercicios de práctica:

1. Para el conjunto de datos **bumpers** (UsingR), **firstchi** (UsingR) y **math** (UsingR), haga los histogramas. Intente predecir la media, mediana y la desviación estándar. Revisa tus predicciones usando los comandos de R apropiados.
2. Ajuste una densidad estimada al conjunto de datos **pi2000** (UsingR). Compara con el histograma apropiado. ¿Por qué querías agregar un argumento tipo **breaks= 0:10-0.5** al **hist()**?
3. El conjunto de datos **pi2000** (UsingR) contiene los primeros 2000 dígitos de π . Realice la prueba de chi-cuadrado para ver si los dígitos aparecen con igual probabilidad.
4. Realizar una prueba de Shapiro-Wilk para la altura, **ht**, y peso, **wt**, de la mamá en el conjunto de datos **babies** (UsingR). Recuerde excluir los casos cuando **ht == 99** y **wt == 999**. ¿Están los conjuntos de datos normalmente distribuidos?