

Análisis de Metadatos I: Unidad 3 - Parte 2

Lenguaje de Programación en R

Jair Pallares Castellon, MSc.



Unidad III: Métodos inferenciales en R - Parte 2

Intervalos de confianza

Intervalos de confianza para la media. Sea $X_1, X_2, \dots, X_n$, una muestra aleatoria de una población con **media** μ y **varianza** σ^2 . Sea $\bar{X}$ la **media muestral** y $SE(\bar{X}) = s/\sqrt{n}$

Si n es pequeño y la población es **Normal**(μ, σ), entonces un **intervalo de confianza** del $(1 - \alpha)100\%$ para μ viene dado por

$$\bar{X} \pm t^* SE(\bar{X})$$

donde t^* está relacionado con la distribución t^* con $n-1$ grados de libertad por

$$P(-t^* \leq T_{n-1} \leq t^*) = 1 - \alpha$$

Para datos no resumidos, la función **t.test()** calculará los intervalos de confianza. Una plantilla para su uso es

t.test(x, conf.level=0.95)

Los datos se almacenan en un vector de datos (denominado x) y el nivel de confianza se especifica con **conf.level=**.

Si n es lo suficientemente grande para que el teorema del límite central se aplique a la distribución muestral de T , entonces un intervalo de confianza del $(1 - \alpha)100\%$ para μ viene dado por

$$\bar{X} \pm z^* SE(\bar{X})$$

donde z^* está relacionado con α por

$$P(-z^* \leq Z \leq z^*) = 1 - \alpha$$

Intervalos de confianza

Hallar t^* con R. Calcular el valor de t^* (también llamado $t_{\alpha/2, k}$) para un α dado y viceversa se hace de manera similar a encontrar z^* , excepto que se usa una densidad diferente. Como R es un lenguaje consistente, cambiar a una nueva densidad no requiere más que usar el nombre de familia adecuado, **t**, para la distribución-**t** y **norm** para la normal y especificación de los valores de los parámetros. En particular, si n es el tamaño de la muestra, entonces los dos están relacionados de la siguiente manera:

```
> tstar = qt(1 - alpha/2, df = n - 1)
```

```
> alpha = 2 * pt(-tstar, df = n - 1)
```

Por el contrario, para z^* los comandos correspondientes son:

```
> zstar = qnorm(1 - alpha/2)
```

```
> alpha = 2 * pnorm(-zstar)
```

Ejemplo #3: Estatura promedio. Los estudiantes en una clase de 30 tienen una altura promedio de 66 pulgadas, con una **desviación estándar** de 4 pulgadas. Suponga que estas alturas se **distribuyen normalmente** y que la clase puede considerarse una muestra aleatoria de toda la población universitaria. ¿Cuál es un intervalo de confianza del 80% para la altura media de todos los estudiantes universitarios?

Nuestras suposiciones nos permiten aplicar el **intervalo de confianza para la media**, por lo que la respuesta es
$$X \pm t^* SE(X)$$

```
R Console
> ## Datos que tenemos:
> xbar = 66; s = 4; n = 30
> alpha = 0.2
> tstar = qt(1-alpha/2, df = n - 1)
> tstar
[1] 1.311434
> SE = s/sqrt(n)
> c(xbar - tstar * SE, xbar + tstar * SE)
[1] 65.04226 66.95774
> |
```

Intervalos de confianza

Ejemplo #4: Preparación de café. Se ha capacitado a un barista en "t-test espresso" para configurar el molinillo de granos de modo que un trago de espresso de 25 segundos resulte en 2 onzas de espresso. Sabiendo que las variaciones son la norma, sirve ocho tragos y mide las cantidades en **1,95, 1,80, 2,10, 1,82, 1,75, 2,01, 1,83 y 1,90** onzas. Encuentre un **intervalo de confianza del 90%** para el tamaño medio de disparo. Incluye 2.0? Como tenemos los datos, podemos usar **t.test()** directamente. Ingresamos los datos, verificamos la normalidad (con un gráfico **cuantil-cuantil**) y luego usamos **t.test()**:


```
R Console

> onzas = c(1.95, 1.80, 2.10, 1.82, 1.75, 2.01, 1.83, 1.90)
> qqnorm(onzas)          ## Aproximadamente lineal
> t.test(onzas, conf.level = 0.80)

One Sample t-test

data:  onzas
t = 45.253, df = 7, p-value = 6.724e-10
alternative hypothesis: true mean is not equal to 0
80 percent confidence interval:
 1.835749 1.954251
sample estimates:
mean of x
 1.895

> ## El barista observa que 2.0 no esta en el intervalo.
```



La estadística T es robusta. El intervalo de confianza para la media se basa en el hecho de que la distribución muestral de

$$T = (\bar{X} - \mu) / SE(X)$$

Es la distribución t con $n-1$ grados de libertad. Esto es cierto cuando las X_i son independientes e idénticamente distribuidas (i.i.d.) normal. ¿Y si las X_i no son normales?

Si n es pequeño, podemos hacer simulaciones para ver que la distribución de T sigue siendo aproximadamente la distribución t si la distribución principal de X_i no está demasiado lejos de lo normal.

Es decir, las colas no pueden ser demasiado largas o el sesgo no puede ser demasiado grande.

Intervalos de confianza

Cuando es grande, se aplica el teorema del límite central. Una estadística cuya distribución de muestreo no cambia drásticamente por cambios moderados en la distribución de la población se denomina **estadística robusta**.

Poniendo en práctica lo aprendido hasta el momento.

Usar *R Console*:

1. El conjunto de datos `stud.recs` (UsingR) que contiene los puntajes de matemática SAT en la variable `sat.m`. Encontrar un intervalo de confianza del 90% para el valor medio de los puntajes de matemática SAT para estos datos.
2. Para el conjunto de datos `homedata` (UsingR) encontrar el intervalo de confianza del 90% para ambas variables **y1970** e **y2000**. Use `t.test()`, pero primero discuta si es apropiado.

Intervalos de confianza para la mediana.

Los intervalos de confianza para la mediana se basan en el hecho de que la distribución de la estadística

$$T = \frac{\bar{X} - \mu}{SE(\bar{X})}$$

es conocida. Esto es cierto cuando la muestra es una i.i.d. muestra de una población normal o cercana a lo normal. Sin embargo, muchos conjuntos de datos, especialmente los sesgados de cola larga, no son así.

Para estas situaciones, se prefieren los métodos **no paramétricos**. Es decir, no se realizan supuestos paramétricos sobre la distribución de la población para la muestra, aunque se pueden aplicar supuestos sobre su forma.

Intervalos de confianza

Intervalos de confianza basados en la binomial.

La **distribución binomial** se puede utilizar para encontrar un intervalo de confianza para la mediana de cualquier población original continua.

La clave es observar si un punto de datos es mayor o menor que la mediana. Como la mediana divide el área por la mitad, la probabilidad de que un punto de datos sea mayor que la mediana es exactamente 1/2.

(Necesitamos una distribución continua con densidad positiva sobre su rango para decir "exactamente" aquí.) Deje que **T** cuente el número de puntos de datos más que la mediana en una muestra de tamaño **n**. **T** es una variable aleatoria **Binomial(n, 1/2)**.

Intervalos de confianza

Sea $X_{(1)}, X_{(2)}, \dots, X_{(n)}$ la muestra después de ordenar de menor a mayor. Se construye un intervalo de confianza del $(1-\alpha)100\%$ encontrando el mayor $j \geq 1$ tal que

$$P(X_{(j)} \leq M \leq X_{(n+1-j)}) \geq 1 - \alpha$$

En términos de T , este se convierte en el j más grande, de modo que

$$P(j \leq T \leq n - j) \geq 1 - \alpha$$

que a su vez se convierte en una búsqueda del j más grande con

$$P(T < j) < \alpha/2$$

Podemos encontrar esto en los datos después de ordenarlos. Un ejemplo concreto puede aclarar.

Ejemplo #5: Compensación del director ejecutivo (CEO) en 2000 Los siguientes datos son una compensación en \$10.000 de una muestra aleatoria de los 200 principales directores ejecutivos de Estados Unidos para el año 2000:

110 12 2.5 98 1017 540 54 4.3 150 432

Encuentre un intervalo de confianza del 90% para la mediana con base en la prueba de signos.

```
R Console
> x = c(110, 12, 2.5, 98, 1017, 540, 54, 4.3, 150, 432)
> n = length(x)
> pbinom(0:n, n, 1/2) ## P(T <= k) no P(T < k)
[1] 0.0009765625 0.0107421875 0.0546875000 0.1718750000 0.3769531250 0.6230468750 0.8281250000
[8] 0.9453125000 0.9892578125 0.9990234375 1.0000000000
> ## para un intervalo de confianza del 90% alpha/2 = 0.05, entonces j es 2, como P(T < 2)=0.0107422
> ## pero P(T < 3) = 0.0546875
> ## podemos clasificar los datos con la función sort()
> sort(x)
[1] 2.5 4.3 12.0 54.0 98.0 110.0 150.0 432.0 540.0 1017.0
> j = qbinom(0.05, n, 1/2)
> sort(x)[c(j, n + 1 - j)]
[1] 4.3 540.0
> ## El intervalo de confianza del 90% esta entre estos valores.
```


Intervalos de confianza basados en la estadística de rango con signo.

La estadística de rango con signo de **Wilcoxon** permite mejorar el intervalo de confianza dado al contar el número de puntos de datos por encima de la mediana. Su uso es válido cuando se supone que las X_i son simétricas con respecto a su mediana. Si esto es así, es igualmente probable que un punto de datos esté a la izquierda o a la derecha de la mediana.

Si conocemos la mediana, podemos clasificar los datos por distancia a la mediana. Sume los rangos de los valores donde los datos son mayores que la mediana. La distribución de esta estadística, bajo la suposición, se puede calcular y utilizar para dar intervalos de confianza.

Intervalos de confianza


Está disponible en R sobre la familia **signrank**.

En particular, **qsignrank()** devolverá los cuantiles.

Este procedimiento se implementa en la función **wilcox.test()**.

A diferencia de **prop.test()** y **t.test()**, para devolver un intervalo de confianza cuando usamos **wilcox.test()** necesitamos especificar que se desea un intervalo de confianza con el argumento **conf.int=TRUE**.

Ejemplo #6: Intervalo de confianza del CEO. Los datos sobre el CEOs están demasiado sesgados para aplicar esta prueba, pero después de tomar una transformación de registro, veremos un conjunto de datos simétricos conjunto (ver Figura).



Intervalos de confianza

```
R Console

> x = c(110, 12, 2.5, 98, 1017, 540, 54, 4.3, 150, 432)
> boxplot(list(scale(x), scale(log(x))), names=c("CEO", "log.CEO"))
> title("Boxplot of CEO data and its Logarithm")
> ## la función scale() hace que un conjunto de datos tenga
> ## mediana 0 y varianza 1.
> wilcox.test(log(x), conf.int=TRUE, conf.level=0.9)

Wilcoxon signed rank exact test

data: log(x)
V = 55, p-value = 0.001953
alternative hypothesis: true location is not equal to 0
90 percent confidence interval:
 2.963463 5.539530
sample estimates:
(pseudo)median
 4.344732

> exp(c(2.963463, 5.539530)) ## inversa del logaritmo
[1] 19.36492 254.55833
> ## compare los intervalos con los encontrados en el ejemplo anterior
```

Intervalos de confianza basados en la estadística de suma de rangos.

La prueba t para comparar muestras es resistente a la no normalidad en la distribución principal, pero aún no es apropiada cuando las distribuciones subyacentes son decididamente no normales. Sin embargo, si las dos distribuciones son iguales hasta un posible cambio del centro, entonces se puede dar un intervalo de confianza basado en una estadística **no paramétrica**.

Sea $f(x)$ una densidad para una distribución de media cero, supongamos que tenemos dos muestras aleatorias independientes: la primera, $X_1, X_2, \dots, X_n$, de una población con densidad $f(x - \mu_x)$, y la segunda, $Y_1, Y_2, \dots, Y_n$, de una población con densidad $f(x - \mu_y)$.

Intervalos de confianza

La estadística básica, llamada **estadística de suma de rangos**, analiza todas las posibles pares de datos y cuenta el número de veces que el valor X es mayor que o igual al valor de Y . Si la media poblacional de los valores de X es mayor que la media de la población para los valores de Y , esta estadística probablemente será grande.

Si la media es más pequeña, entonces la estadística probablemente será pequeña.

La distribución de esta estadística viene dada en R con la familia de **wilcox** y se utiliza para dar un intervalo de confianza para la diferencia de medias.


El comando **wilcox.test(x, y, conf.int=TRUE)**. La función encontrará un intervalo de confianza para la diferencia en las medianas de los dos conjuntos de datos.

Ejemplo #7: Pago del director ejecutivo en 2002.

En el ejemplo #6, se proporcionó la compensación de una muestra de los 200 mejores directores ejecutivos en el año 2000. Para el año 2002 se realizó un muestreo similar y dio este dato:

312 316 175 200 92 201 428 51 289 1126 822

A partir de estas dos muestras, ¿podemos decir si hay una diferencia en el centro de la distribución de la paga del director general?



Intervalos de confianza

```
R Console
> pago.02 = c(312, 316, 175, 200, 92, 201, 428, 51, 289, 1126, 822)
> pago.00 = c(10, 12, 2.5, 98, 1017, 540, 54, 4.3, 150, 432)
> plot(density(pago.02), main="densities of y2000, y2002")
> lines(density(pago.00), lty=2)
> wilcox.test(pago.02, pago.00, conf.int=TRUE, conf.level=0.9)

Wilcoxon rank sum exact test

data: pago.02 and pago.00
W = 77, p-value = 0.1321
alternative hypothesis: true location shift is not equal to 0
90 percent confidence interval:
 -4.0 286.5
sample estimates:
difference in location
      164

> ## el intervalo de confianza del 90% esta en [-4.0, 286.5] y
> ## contiene un valor de 0.
```

Ejercicios

Poniendo en práctica lo aprendido hasta el momento. Usar *R Console*:

1. El viajero revisitado: el viajero registra 20 tiempos de viaje para medir su tiempo medio de viaje. Los datos tienen una mediana muestral de 24 y se resumen en este diagrama de tallo y hojas:

```
> stem(commutes)
```

```
2 | 1112233444444
```

```
2 | 15569
```

```
3 | 1113
```

Si los datos son apropiados para **t.test()**, úselo para dar un intervalo de confianza del 90% para la media. De lo contrario, use **wilcox.test()** (quizás después de una transformación) para dar un intervalo de confianza para la mediana.

2. El conjunto de datos **cabinet** (UsingR) contiene información sobre la cantidad de dinero que ahorró cada miembro del gabinete del presidente Bush debido a la aprobación de una ley de impuestos de 2003. Esto se almacena en la variable llamada **est.tax.savings**. Encuentre un intervalo de confianza para la cantidad mediana.