

COLECCIÓN

SISTEMAS DE INFORMACIÓN

1

UMET
UNIVERSIDAD
METROPOLITANA

MODELACIÓN DE DATOS

UN ENFOQUE SISTÉMICO

CARLOS ERNESTO GARCÍA GONZÁLEZ
LUISA MANUELA GONZÁLEZ GONZÁLEZ
ABEL RODRÍGUEZ MORFFI
BEATRIZ EUGENIA LÓPEZ PORRERO

Copyright © 2017. Editorial Universo Sur. All rights reserved

Rodríguez Morffi, A. García González, C. E. & González González, L. M. (2017). *Modelación de datos: un enfoque sistémico*: (ed.). Editorial Universo Sur. <https://elibro.net/es/ereader/unisimon/120860?page=1>

MODELACIÓN DE DATOS

UN ENFOQUE SISTÉMICO

CARLOS ERNESTO GARCÍA GONZÁLEZ
LUISA MANUELA GONZÁLEZ GONZÁLEZ
ABEL RODRÍGUEZ MORFFI
BEATRIZ EUGENIA LÓPEZ PORRERO

SISTEMAS DE INFORMACIÓN

Con el auspicio de la Fundación Metropolitana



Proyecto Observatorio Metropolitano de Inteligencia Competitiva, Ciencia, Tecnología, Innovación y Saberes. Red UMET - UCf- UCLV

Rodríguez Morffi, A. García González, C. E. & González González, L. M. (2017). *Modelación de datos: un enfoque sistémico*: (ed.). Editorial Universo Sur. <https://elibro.net/es/ereader/unisimon/120860?page=1>

MODELACIÓN DE DATOS

UN ENFOQUE SISTÉMICO

CARLOS ERNESTO GARCÍA GONZÁLEZ
LUISA MANUELA GONZÁLEZ GONZÁLEZ
ABEL RODRÍGUEZ MORFFI
BEATRIZ EUGENIA LÓPEZ PORRERO

Diseño de carátula: D. I. Yunisley Bruno Díaz

Composición de textos: D. I. Yunisley Bruno Díaz

Corrección: MSc. Alicia Martínez León

Dirección editorial: Dr. C. Jorge Luis León González

Sobre la presente edición:

© Editorial Universo Sur, 2017

© Universidad Metropolitana de Ecuador, 2017

ISBN: 978-959-257-499-1

Podrá reproducirse, de forma parcial o total, siempre que se haga de forma literal y se mencione la fuente.



Editorial: "Universo Sur".

Universidad de Cienfuegos. Carretera a Rodas,
Km 3 ½.

Cuatro Caminos. Cienfuegos. Cuba.

CP: 59430

E-mail: eus@ucf.edu.cu

Introducción

La primera aproximación para describir la estructura de los datos para ser manipulada por un Sistema de Gestión de Bases de Datos (SGBD) se conduce con la ayuda de algún modelo conceptual, que deben ser naturales o al menos comprensibles para los usuarios del universo de discurso, término usado con mucha frecuencia para delimitar un área del mundo real que es objeto de modelación.

Estos modelos deben ofrecer una variedad de conceptos de modelación con énfasis en las interrelaciones lógicas entre los datos. El objetivo de tal modelación es encontrar los conceptos esenciales presentes en la fase de análisis de requerimientos. Esta tarea no es trivial pues a veces los usuarios describen un mismo concepto con términos diferentes (sinónimos) o usan un mismo término para conceptos diferentes (homónimos) (García & Montes de Oca, 2015). El resultado del diseño conceptual es el *esquema conceptual* de la base de datos, el cual es una descripción de alto nivel de la estructura de la base de datos, que es un conjunto estático de representaciones lingüísticas y gráficas, invariables en el tiempo, que describen la estructura de los datos (Batini, Ceri & Navathe, 2011).

Relación (ER, del inglés Entity Relationship)¹ (Chen, 1976). Los conceptos que le sirven de base a este modelo son los de entidad e interrelación. La decisión de si un concepto del universo de discurso debe ser una entidad, una interrelación, o simplemente una propiedad de cualquiera de ellos, no siempre es obvia y en efecto, puede existir más de una descripción conceptual que refleje los requerimientos de los usuarios.

A partir del modelo ER original presentado por Chen (1976) muchos investigadores han propuesto numerosas extensiones con el objetivo de aumentar su poder de expresión (Teorey, Yang & Fry, 1986; Chen, 2006; Murthy, Delcambre & Maier, 2006; Combi, Degan & Jensen, 2008; Elmasri, Weeldrey & Hevner, 2012). Estas

¹ Se asume una ligera imprecisión en su denominación en español (Entidad-Interrelación) para conservar la sigla ER tan frecuentemente citada.

extensiones se han ido incorporando a un supuesto modelo ER abstracto, que no siempre es el modelo original de Chen; no es una tarea sencilla unificar todas estas extensiones en un solo modelo, genéricamente denominado modelo Entidad Relación Extendido (EER, acrónimo del inglés Extended Entity Relationship).

Varias de las extensiones del modelo ER original persiguen mayor riqueza semántica en la descripción del universo de discurso. Detrás de las diferencias sintácticas de estas extensiones está el enriquecimiento semántico de las construcciones. Muchos de los cambios sintácticos propuestos están relacionados con la abstracción de generalización y en menor grado, con la inclusión de nuevas construcciones. También existen diferencias en cuanto a las notaciones empleadas por diferentes autores en la representación gráfica utilizada en los diagramas (Song, Evan, & Park, 1995; Hay, 1999), para lo cual la notación de Elmasri & Navathe (2012) se considera un referente adecuado.

Un concepto tratado con poca formalidad, con un alcance no bien definido, y con enfoques acotados por cada autor, es el de dependencia de existencia. Este concepto se ha asociado intuitivamente a un comportamiento, se ha considerado que existe dependencia de existencia entre dos entidades cuando la eliminación de una entidad dominante conlleva a la eliminación de la entidad subordinada. Este comportamiento es inherente a otras construcciones; algunas de ellas tratadas de manera sutil o informal en la literatura, pero en otros casos, como es su presencia en algunos tipos de interrelaciones de asociación, no ha sido abordado en las extensiones al modelo ER, y sin embargo, su consideración ayuda a modelar muchos hechos asociados con su inmutabilidad en el tiempo.

Es bien conocido que el modelo ER al ser un modelo semántico tiene por objetivo la descripción de un universo de discurso mediante la distinción de hechos cada vez más singulares. Ello se logra con sutilezas en construcciones que describan la mayor diversidad posible de tipos de hechos, que si bien desde el punto de vista formal pueden tener comportamientos similares,

desde el punto de vista de la descripción del universo de discurso puedan expresar dicha singularidad semántica.

En este libro se reconoce la necesidad de una sistematización de construcciones, notaciones, conceptos y del comportamiento embebido en los mismos, con atención especial a las diferentes variantes de dependencia de existencia, todo lo cual ha motivado su inclusión en una herramienta de ayuda al diseño de bases de datos.

Por otra parte, se ha desarrollado un número creciente de herramientas CASE (acrónimo del inglés Computer Aided Software Engineering) con el objetivo de apoyar a los diseñadores en el proceso de diseño de base de datos. Estas herramientas se caracterizan por una interfaz de usuario que da soporte al modelo conceptual y por un diccionario de datos donde se almacenan los esquemas resultantes. Entre sus beneficios están automatizar el proceso de obtención de un esquema de base de datos; minimizar los costos y el tiempo de implementación; utilizar metodologías y modelos de datos consolidados; contribuir a eliminar errores que el diseñador pueda cometer en las distintas fases del diseño, entre otros aspectos.

Una brecha identificada está relacionada con las capacidades de validación de esquemas de estas herramientas, que en opinión de Piattini & Díaz (2012a), es la más poderosa ayuda que las herramientas CASE deben proveer, ya que tienen un impacto directo en la calidad de los esquemas obtenidos durante el proceso de diseño.

Idealmente, el proceso de creación de un esquema ER mediante una herramienta CASE, requiere de un soporte mínimo en términos de la validación de los diferentes esquemas, que comprende la validación de la sintaxis, la estructura y la semántica del esquema conceptual, así como la verificación de posibles inconsistencias en el esquema lógico.

La validación estructural debe comprobar que el conjunto de restricciones de cardinalidad asociado a un esquema conceptual

pueda ser satisfecho de manera total, en cuyo caso el esquema se considera consistente. La validación semántica determina si los tipos de entidades y tipos de interrelaciones del esquema conceptual representan exactamente los conceptos del dominio que se esté modelando (Kolapalli & Dullea, 2012; Dullea, Song & Lamprou, 2003).

Con relación a la detección de inconsistencias en esquemas lógicos como parte integrada al proceso de modelación conceptual, no se encontraron referencias en la literatura consultada. Tradicionalmente la detección de anomalías en esquemas lógicos ha sido abordada con un enfoque bottom-up, que comprueba las propiedades de cada esquema por separado, conocido como Teoría de la Normalización, y que fue tratado incluso, previo al surgimiento del modelo ER (Codd, 1970; Ullman, 1988; Maier, 2011).

En este trabajo se valoró un grupo amplio de herramientas CASE comerciales para comprobar sus capacidades de validación. Como resultado del estudio se pudo constatar que todas las herramientas realizan de una manera u otra la validación sintáctica del esquema ER; sin embargo, un número reducido herramientas ofrece de forma parcial capacidades de validación estructural; todas carecen de soporte de validación semántica y lógica.

El libro ha sido estructurado de la siguiente manera:

En el primer capítulo se realiza una evaluación del marco teórico relacionado con la modelación conceptual de bases de datos y se analiza cada una de las construcciones del modelo ER y sus extensiones, haciendo notar cómo se manifiesta la dependencia de existencia en estas construcciones. También se efectúa un análisis crítico de los métodos de validación de esquemas conceptuales, así como de las herramientas de ayuda al diseño de bases de datos.

En el segundo capítulo se hace una sistematización del concepto de dependencia de existencia, se establece el comportamiento correspondiente de las entidades con dependencia de



existencia en cada una de las construcciones del modelo EER. Como resultado del análisis de la semántica de las interrelaciones de asociación con dependencia de existencia se propone una nueva construcción.

En el tercer capítulo se propone un algoritmo para detectar y corregir un tipo de inconsistencia que puede manifestarse en el esquema lógico de una base de datos, lo cual contribuye a eliminar errores en la fase de implementación. En el cuarto, se elabora una descripción de la arquitectura de la herramienta ERECASE, se destacan las principales funcionalidades que la distinguen del resto de las herramientas CASE evaluadas.

Capítulo I. Modelación de datos con Entidad Relación

1.1 Modelación de datos

Paralelo al avance de la tecnología de bases de datos relacionales se han desarrollado metodologías y técnicas para su diseño. Todas ellas tienen en común la descomposición del proceso en fases, con objetivos bien definidos y técnicas establecidas para conseguir estos objetivos.

La modelación conceptual es la etapa en que se crea un esquema conceptual que describe de manera concisa, los requerimientos de información desde el punto de vista de los usuarios (Bienemann, Schewe & Thalheim, 2013). Los datos se expresan mediante conceptos de un modelo de alto nivel que son independientes de un SGBD.

Un modelo de datos es una colección de conceptos y notaciones para describir datos, sus interrelaciones, su semántica, restricciones de integridad y operaciones sobre los mismos (Brodie, Mylopoulos & Schmidt, 2012; Ullman & Widom, 2013; Silberschatz, Korth, & Sudarshan, 2014). Un modelo de datos ofrece una manera de describir una base de datos para un determinado nivel de abstracción.

La representación de los datos a través de conceptos que no incluyen detalles de su almacenamiento o implementación suelen estar cercanos al lenguaje natural, y son fáciles de entender, de modo que pueden utilizarse para la comunicación con usuarios no especialistas. De esa manera, el esquema se utiliza como referencia para garantizar que se satisfagan los requerimientos de los usuarios y que no existan contradicciones entre dichos requerimientos. Utilizando este enfoque, los diseñadores de bases de datos solo deben concentrarse en especificar las propiedades de los datos, sin tener en cuenta detalles de implementación y almacenamiento.

1.2 El modelo Entidad Relación

El modelo ER es de datos semántico que se ha convertido en uno de los más populares desde su presentación por Chen (1976). Es extensamente usado durante el análisis de requisitos para la modelación conceptual de la base de datos, parte de su popularidad se debe a la claridad y simplicidad de su notación gráfica en forma de diagramas, lo que unido a una semántica bien definida, lo convierte en una excelente herramienta de comunicación entre analistas de sistemas, diseñadores y usuarios finales (Batini, Barone, Garasi & Viscusi, 2012).

Los modelos más comunes para bases de datos tienen un formato de representación para entidades, sus atributos y para interrelaciones entre entidades. La comunidad de especialistas en base de datos reconoce el concepto de entidad como el más importante en la modelación, denominado indistintamente entidad u objeto. El modelo para una entidad es construido a partir de un conjunto relativamente pequeño de primitivas de modelación.

Aunque la modelación orientada a objetos se ha hecho popular, en la actualidad el modelo ER no ha perdido su vigencia. Algunos estudios han demostrado (Davies, Green, Rosemann, & Gallo, 2004; Davies, Green, Rosemann, Indulska, & Gallo, 2006) que el modelo ER sigue siendo el modelo conceptual de datos más utilizado; la continuidad de una conferencia internacional sobre el modelo ER (International Conference on Conceptual Modeling), la edición de libros y artículos sobre la temática en años recientes, es un testimonio de la actualidad de este modelo que justifica su utilización.

1.2.1. El modelo ER original

Las construcciones del modelo ER que se presentan Chen (1976), son las entidades, interrelaciones y atributos. Una entidad es algo que puede ser perfectamente identificado y es descrita por sus atributos. Las entidades que poseen los mismos atributos se clasifican en conjuntos de entidad o tipos de entidad.









Una interrelación, en el modelo original es una asociación entre entidades, lo que indica que solo existían interrelaciones de asociación. Según su grado estas podían ser recursivas, binarias o ternarias. Al conjunto de interrelaciones existentes entre dos o más conjuntos de entidades se le denomina conjunto de interrelación o tipo de interrelación. En el modelo original solo era posible establecer restricciones de cardinalidad máxima en las interrelaciones de asociación, lo que limitaba su capacidad de expresividad.

Las entidades y las interrelaciones se describen a través de conjuntos de pares (atributo, valor) que representan sus propiedades o características relevantes. Se reconoce la necesidad del empleo de atributos para identificar de manera única a cada entidad de un conjunto de entidad. En determinadas ocasiones una entidad puede depender de entidades de otros conjuntos de entidades para su existencia, debido a que no posee suficientes atributos propios para identificarse; Chen (1976), denominó entidades débiles a las entidades con estas características. De acuerdo con lo anterior, si la interrelación se utiliza para identificar un conjunto de entidad débil, entonces se denomina interrelación de entidad débil, en caso contrario, interrelación de entidad regular o fuerte. Del mismo modo, propone dos formas de clasificar las entidades en regulares y débiles. No se hace una diferenciación entre atributos simples o compuestos y monovaluados o multivaluados.

Para expresar un esquema ER en forma de un diagrama se utiliza un rectángulo y un rombo para representar a los conjuntos de entidad y conjuntos de interrelación, respectivamente. Los conjuntos de entidad interrelacionados están conectados al rombo por líneas rectas. Cada línea es marcada con un "1", "N" o "M" para indicar interrelaciones del tipo 1:1, 1:N o M:N. Un conjunto de entidad débil es encerrado dentro de un rectángulo de doble línea y es identificado por otro conjunto de entidad por una flecha que parte del rombo hacia el conjunto de entidad dependiente. En el resto del informe se utilizarán los términos tipo de entidad por conjunto de entidad y tipo de interrelación por conjunto de interrelación. En la tabla 1.1 se muestra la notación original del modelo ER.



Tabla 1.1. Notación original propuesta por Chen para los diagramas ER.

Símbolo	Significado
	Tipo de entidad E.
	Tipo de entidad débil W.
	Tipo de interrelación R.
	Cardinalidad 1:1 para E1:E2 en R.
	Cardinalidad 1:N para E1:E2 en R.
	Cardinalidad N:M para E1:E2 en R.
	Tipo de entidad W identificada por un tipo de entidad regular E a través del tipo de interrelación débil R.
	Tipo de interrelación recursiva R.
	Tipo de interrelación ternaria R.

En el modelo básico no existían reglas para transformar el esquema conceptual en esquemas lógicos, sino que el diagrama ER era traducido hacia un diagrama de estructura de datos, que era una representación a nivel de registros. Desde la década de 1980 se ha producido un rápido incremento en el desarrollo de sistemas de bases de datos que motivó a muchos investigadores (Teorey, et al., 1986; Chen, 2006; Hartmann & Link, 2007) a introducir conceptos adicionales que ayuden a captar cada vez más la semántica de un universo del discurso, este esfuerzo para extender el modelo básico se conoce de manera simbólica como modelo Entidad Relación Extendido.

1.2.2. Extensiones al modelo Entidad Relación

Según Ullman & Widom (2013), el modelo ER es muy simple y sus conceptos básicos son entidades e interrelaciones. Las entidades ya fueron abordadas en el modelo original y por tanto, las extensiones se refieren fundamentalmente a las interrelaciones y a las reglas de transformación hacia el modelo lógico. Aunque el modelo básico solo hace referencia a estos dos conceptos, también incluye otros como el de dependencia de existencia, para entidades débiles.

El concepto de *cardinalidad* del modelo ER original fue extendido con la introducción de las restricciones de cardinalidad mínima², por Webre (1981). Estas restricciones expresan si las entidades tienen una participación opcional u obligatoria en una interrelación de asociación. De esta manera, la cardinalidad de un tipo de entidad es el número mínimo y máximo de entidades del tipo de interrelación en las que puede intervenir una de sus entidades. Típicamente la cota inferior es 0 o 1 y la superior 1 o N (muchos); esta forma de indicar la cardinalidad se denota con el par (mín, máx). La participación obligatoria de una entidad en una interrelación de asociación expresa una dependencia de existencia, que hasta el momento solo se había reconocido en las entidades débiles.

² También conocidas como restricciones de participación o de membresía.

En las diversas notaciones del modelo EER, los valores de las restricciones de cardinalidad son mostrados en los diagramas ER sobre las líneas que relacionan a cada uno de los tipos de entidades con el tipo de interrelación de asociación. La ubicación de la cardinalidad en el diagrama ER es conocido en la literatura como convenio *look across* y *look here*³, términos utilizados por primera vez en Ferg (1991). La comprensión del tipo de convenio utilizado para expresar las restricciones de cardinalidad posibilita una interpretación correcta de la semántica de las interrelaciones. Sin embargo, en la literatura se observa que estos términos no se utilizan de manera uniforme, lo que puede generar confusiones a lectores y a usuarios de herramientas CASE al interpretar las restricciones de cardinalidad de una notación determinada del modelo EER. En la tabla 1.2 se puede observar cómo quedan representadas, para algunas notaciones del modelo ER, las restricciones de cardinalidad que modelan los siguientes hechos: en un departamento trabajan de uno a varios empleados y un empleado puede trabajar para un solo departamento. De acuerdo con esta especificación de requisitos, y utilizando las definiciones de cardinalidad mínima (min-card) y cardinalidad máxima (max-card) enunciadas por Batini, et al. (2011), las restricciones de cardinalidad de los tipos de entidad EMPLEADO y DEPARTAMENTO en el tipo de interrelación TRABAJA_EN son:

$\text{min-card (EMPLEADO, TRABAJA_EN)} = 0$

$\text{max-card (EMPLEADO, TRABAJA_EN)} = 1$

$\text{min-card (DEPARTAMENTO, TRABAJA_EN)} = 1$

$\text{max-card (DEPARTAMENTO, TRABAJA_EN)} = N$

3 Se prefiere utilizar intencionalmente los términos en inglés ya que su traducción al español no es muy conocida.

Tabla 1.2. Convenio para representar las restricciones de cardinalidad en algunas notaciones del modelo ER.

Diagrama ER	Notación	Convenio
	Chen (notación actual)	min-card: look here max-card: look across
	Teorey	min-card: look across max-card: look across
	Batini, Navathe y Ceri	min-card: look here max-card: look here
	Elmasri y Navathe	min-card: look here max-card: look across
	McFadden y Hoffer	min-card: look across max-card: look across

Nótese en la tabla anterior la variedad de formas de representar las cardinalidades descritas en Teorey, et al., 1986; Batini, et al., 2011; Chen, 2011; Elmasri & Navathe, 2012; McFadden & Hoffer, 2011. Una explicación más detallada sobre diversas notaciones del modelo ER y sus correspondientes representaciones de los convenios look across y look here puede encontrarse en Hay (1999); y Song, et al., (1995).

Para las notaciones que permiten modelar el *grado* de las interrelaciones de asociación, se observa que en especial para las interrelaciones ternarias o de mayor grado, su semántica queda mejor expresada si las restricciones de participación utilizan el convenio look here (Nieto, Martínez, Cuadra & de Miguel, 2012).

Dentro de las *construcciones*, la abstracción de generalización fue una de las más importantes contribuciones del modelo EER y en menor medida, otras como la agregación y la categorización, significaron aportes a la sintaxis y semántica del modelo ER.

Generalización/especialización: la abstracción de generalización fue abordada por Smith & Smith en (1977), al proporcionar una base formal para los subtipos dentro de un modelo de datos. Posteriormente, otros autores (Elmasri, et al., 2012; Ling, 1985; Navathe & Cheng, 1983; Sakai, 1983) introdujeron esta construcción en diversas extensiones al modelo ER.

La principal propiedad de una jerarquía de generalización/especialización es la herencia, lo que implica que todas las propiedades del tipo de entidad genérico son heredadas por los tipos de entidades especializados. La herencia constituye un aporte substancial a la modelación de la realidad, pues permite definir subconjuntos de tipos de entidades que tienen atributos e interrelaciones propias, a la vez que conservan todos los atributos e interrelaciones del tipo de entidad más general (García & Montes de Oca, 2015).

Las interrelaciones ISA (acrónimo del inglés ISA cuyo significado es “es un”) son un tipo especial de interrelaciones semánticas que se utilizan para modelar subconjuntos y cuya propiedad más significativa es la herencia. Para Manila & Rähä (2012), las interrelaciones ISA se modelan como entidades débiles lo que reduce la oportunidad de modelar hechos de diferente naturaleza. La identificación de un tipo de entidad débil en una interrelación ISA se hace a través de la llave primaria del tipo de entidad genérico, por lo que las entidades de los tipos de entidades genérico y especializado tendrán la misma llave primaria.

Hay dos restricciones que pueden aplicarse a una jerarquía de generalización/especialización: la restricción de participación y la restricción de disyunción (Parsons & Li, 2007). La imposición de estas restricciones determinará el significado que cada especialización tiene en el mundo real y la aplicación de las reglas correspondientes que regirán el comportamiento de las entidades que forman parte de este tipo de interrelación (Artale, Calvanese, Kontchakov, Ryzhikov & Zakharyashev, 2007).

Diversas notaciones del modelo EER (Finkelstein, 1998; Barker, 2011; Batini, et al., 2011; McFadden & Hoffer, 2011; Elmasri & Navathe, 2012; Bruce, 2013; Korth, Silberschatz, & Sudarshan,

