


Modelado en ciencias de datos

Estructuración del proceso

Modelado en ciencia de datos

- Corresponde con un conjunto de las fases sucesivas orientas a la estructurar un fenómeno natural u organizacional desde la perspectiva de la ciencia de datos
- Desarrollo sistemático de una serie de pasos ordenados u organizados, que se efectúan de forma alternativa o simultánea, estrechamente relacionados entre sí y cuyo propósito es llegar a un resultado preciso





Entender el problema – Fase 1

□ Parte de una idea

- Opiniones acerca de lo que sería interesante, apropiado, pertinente, oportuno o necesario, hacer, resolver o incorporar a cualquier fenómeno organizacional
- Opiniones generales. No se ha constatado su validez



Entender el problema



- La idea sencillamente surge, se le ocurre al científico de datos
- El profesional de la ciencia de datos deberá reconocer situaciones a tratar en su campo de conocimiento
- Se impone la intuición, la subjetividad, por encima de la objetividad

Entender el problema

- La idea surge de la experiencia del científico de datos con sus pares
- De ideas conversadas por otros científicos de datos
- De tendencias de la disciplina
- De experiencias previas en las que se ha visto inserto el profesional






Entender el problema

- ☐ Requiere de un proceso de construcción-deconstrucción-construcción de una idea preliminar [1]
- ☐ Fundamentado en sub-procesos de expansión y contracción de ideas
 - Proceso dirigido a “...estimular la mente de las personas para que piensen antes de actuar o de decidir” [2, p.47]
 - Se inicia considerando las ideas desde diferentes perspectivas, antes de generar conclusiones o de ofrecer soluciones o respuestas.



Entender el problema

- ☐ Se trata de dar al pensamiento, respecto a la idea, apertura, flexibilidad, equilibrio y autorregulación
- ☐ Es importante que las ideas se vean desde su impacto positivo o negativo, consecuencias, contribuciones, entre otros
- ☐ Es necesario valorar estos aspectos que le añadan valor agregado como posibles opciones de solución



Entender el problema

- ☐ Debe incorporar una representación abstracta de información orientado a hablar de las relaciones que los datos de una organización tienen entre sí
- ☐ Permite describir el tipo de datos que existen, y todos los elementos reales que intervienen en un problema o situación


Entender el problema

- Propósito
 - Intención del científico de datos con el desarrollo del trabajo.
 - Necesidad organizacional de realizar el trabajo.
 - ¿Para qué se hace el trabajo?



Entender el problema

- A partir de la idea preliminar



Entender el problema

Entender el problema

Disponibilidad y
accesibilidad de la
información

Asunto que se desea
tratar

Enfoque de la ciencia
de datos

Extracción de datos – Fase 2

- Seleccionar y crear un conjunto de datos en el cual se ejecutará la solución de ciencia de datos
- Definidos los objetivos, se deben determinar los datos que serán usados para el descubrimiento del conocimiento
 - ¿Qué datos están disponibles?
 - ¿Qué datos es necesario conseguir?
 - ¿Es posible integrar todos los datos para dar solución al problema?



Extracción de datos

- Esta fase es muy importante porque el científico de datos aprende y descubre conocimiento de los datos disponibles
- La no especificación de algunos datos importantes pone en riesgo el estudio completo
- La recolección, organización y operación de datos en repositorios complejos es costoso, lo cual puede ser equilibrado con una profunda comprensión del fenómeno



Extracción de datos

- La selección de los datos varía de acuerdo con los objetivos del negocio, no es un paso genérico en la fase de modelado
- Hay que enfatizar, que una vez identificado el conocimiento relevante y prioritario, y definidas las metas del intervención de ciencia de datos, se debe plantear la creación de un conjunto de datos objetivo, compuesto por todo el conjunto de datos o por una muestra representativa




Limpieza de datos – Fase 3

- En la etapa de limpieza/preprocesamiento (*data cleaning*) se analiza la calidad de los datos
- Se aplican operaciones básicas como la remoción de datos ruidosos
- Se seleccionan estrategias para el manejo de datos desconocidos (*missing and empty*), datos nulos, y datos duplicados
- Se establecen enfoques basados en técnicas estadísticas para el reemplazo de datos




Limpieza de datos

- Los datos ruidosos (*noisy data*) son valores que están significativamente fuera del rango de valores esperados
- Se deben principalmente a errores humanos, a cambios en el sistema, a información no disponible a tiempo y a fuentes heterogéneas de datos [3]



Limpieza de datos

- Los datos desconocidos (*empty*) son aquellos a los cuales no les corresponde un valor en el mundo real
- Mientras que los datos desconocidos (*missing*) son aquellos que tienen un valor que no fue capturado
- Los datos nulos son datos desconocidos que son permitidos por los sistemas gestores de bases



Limpieza de datos

- En la fase de limpieza, los valores de los datos ruidosos, desconocidos y duplicados se ignoran
- Se reemplazan por un valor por omisión, o por el valor más cercano
- Se usan métricas de tipo estadístico como media, moda, mínimo y máximo para reemplazarlos



Limpieza de datos

- El objetivo fundamental en esta fase es elevar la confiabilidad en los datos
- Está orientada a impulsar la claridad en los datos, el manejo de valores faltantes y la remoción de ruido o datos anómalos
- Se constituye, algunas veces, por el tiempo invertido, en un proyecto de KDD (*Knowledge Discovery in Databases*)
- Puede involucrar métodos estadísticos complejos o el uso de algoritmos de minería de datos (*data mining*)



Knowledge Discovery in Databases [4]

Proceso orientado a la identificación de patrones y al descubrimientos de patrones nuevos más significativos

Implica la evaluación e interpretación de patrones para tomar decisiones con respecto a lo que constituye conocimiento y lo que no


Actividad multidisciplinaria que abarca técnicas fuera del alcance de cualquier disciplina en particular, como el aprendizaje automático

Data mining [4]

Paso particular del proceso de identificar patrones y de descubrir patrones nuevos más significativos

Implica la aplicación de algoritmos específicos para extraer patrones a partir de los datos.
Puede conducir a descubrir patrones sin sentido e inválidos

Requiere de la interacción con el usuario o con una base de conocimientos. Los patrones presentados a los usuarios, pueden ser almacenados como nuevos en la base de conocimientos



Gracias

1. El pasado, como el futuro, es indefinido y existe solo como un espectro de posibilidades
2. La inteligencia es la habilidad para adaptarse a los cambios

Stephen Hawking

Bibliografía

- [1] D. Madriz y A. Bravo. Primero Yo, Luego el Método. Fondo Editorial UNET, 2018.
- [2] M. Castillo. Toma de decisiones. Un enfoque particular. UNET. San Cristóbal, Venezuela, 2002
- [3] S. Timarán-Pereira, I. Hernández-Arteaga, S. Caicedo-Zambrano, A. Hidalgo-Troya y J. Alvarado-Pérez. El proceso de descubrimiento de conocimiento en bases de datos. En Descubrimiento de patrones de desempeño académico con árboles de decisión en las competencias genéricas de la formación profesional (pp. 63-86). Ediciones Universidad Cooperativa de Colombia, 2016
- [4] V. Kotu y B. Deshpande. Chapter 1 – Introduction. Editor(s): V. Kotu y B. Deshpande. Data Science, Morgan Kaufmann, pp. 1-18, 2019.
- [5] Excelsior. Stephen Hawking, su manera de pensar en 10 frases. [Online]. Disponible en: <https://bit.ly/3JjyQyw>.