

La ciencia de datos y otras ciencias

Big data

Big data

- Conjuntos de datos cuyo tamaño está más allá de la capacidad de las herramientas típicas de software de base de datos para capturar, almacenar, administrar y analizar [1]
- Datos demasiado grandes para ser manejados y analizados por protocolos de bases de datos tradicionales como SQL [2]



Big data



- Los datos son demasiado grandes, se mueven demasiado rápido o no se ajustan a las restricciones de las arquitecturas de su base de datos [3]
- Es información de gran volumen, alta velocidad y gran variedad que requiere un enfoque rentable e innovador para su procesamiento, lo que brinda la oportunidad de mejorar el conocimiento, la toma de decisiones y la automatización de procesos [4]

Big data

Son grandes conjuntos de datos relacionados con el comportamiento de los individuos y la sociedad, que tienen que ser procesado computacionalmente debido a su complejidad con la idea de revelar ideas, tendencias y asociaciones profundas entre la sociedad y los mercados de capitales [5]



Big data

- ❑ Supone que el tamaño no es la única característica de big data, se caracterizan con apoyo de las tres V [6]
 - Volumen
 - Variedad
 - Velocidad
- ❑ También, se consideran [1]
 - Valor
 - Veracidad
 - Visualización



Big data

Volumen

Datos en reposo

Cantidad de datos que son generados cada segundo, minuto y días en nuestro entorno

Variedad

Datos en muchas formas

Formas, tipos y fuentes en las que se registran los datos

Velocidad

Datos en movimiento

Flujos de datos, creación de registros, disponibilidad para el acceso y la entrega.

Big data

Valor

Significancia en los
datos

Información significativa que se obtiene a partir
de los datos

Veracidad

Incertidumbre en los
datos

Lo que se conforma con la verdad o el hecho,
o en suma, exactitud, certeza, precisión

Visualización


Representación de
datos

Representación sencilla de los datos para su
acceso

Big data




Gestión de big data




Tecnología de big data

- Apache Hadoop es un marco que permite el procesamiento distribuido de grandes conjuntos de datos en grupos de computadoras utilizando modelos de programación simples
- Escrito en Java y creado por Doug Cutting
- Hadoop se compone de dos proyectos principales:
 - Hadoop Distributed File System (HDFS)
 - MapReduce




Tecnología de big data

- HDFS es un sistema de archivos distribuido diseñado para ejecutarse en grandes grupos de hardware básico basado en Google File System
- Está diseñado para almacenar conjuntos de datos muy grandes de manera confiable y para transmitir esos conjuntos de datos con un gran ancho de banda a las aplicaciones de los usuarios
- Por grande, se refiere a 10 a 100 GB y más



Tecnología de big data

- MapReduce es originalmente creado por Google para resolver el problema de generación de índices de búsqueda web
- Es un marco de software para escribir fácilmente aplicaciones que procesan grandes cantidades de datos en paralelo en grandes clústeres de hardware básico de manera confiable y tolerante a fallas



Tecnología de big data

- En torno a HDFS y MapReduce hay decenas de proyectos que no se pueden presentar aquí en detalle. Estos proyectos se pueden clasificar según sus capacidades:
 - Capacidad de almacenamiento y administración
 - Capacidad de base de datos
 - Capacidad de procesamiento
 - Capacidad de integración de datos

Técnicas de visualización en big data

- Técnicas y tecnologías utilizadas para crear imágenes, diagramas o animaciones para comunicar, comprender y mejorar los resultados de los análisis de big data
- Nube de etiquetas
- Clustergrama
- Flujo de historial
- Flujo de información espacial



Análisis de big data

- Uso de técnicas analíticas avanzadas en big data
 - Aprendizaje de reglas de asociación
 - Aprendizaje automático
 - Minería de datos
 - Análisis de conglomerados
 - Colaboración colectiva
 - Análisis de texto



Gracias

Big data are things one can do at a large scale that cannot be done at a smaller one, to extract new insights or create new forms of value, in ways that change markets, organizations, the relationship between citizens and governments, and more...

Viktor Mayer-Schönberger y Kenneth Cukier

Bibliografía

- [1] J. Manyika, M. Chui, B. Brown, J. Bughin, R. Dobbs, C. Roxburgh, A. Byers. Big Data: The Next Frontier for Innovation, Competition, and Productivity, McKinsey Global Institute, 2011.
- [2] K. Davis, D. Patterson, Ethics of Big Data: Balancing Risk and Innovation, O'Reilly Media, 2012.
- [3] I. O'Reilly Media, Big Data Now: 2014 Edition, O'Reilly Media, 2014.
- [4] A. Beyer, D. Laney. The Importance of Big Data: A Definition. Gartner, 2012

Bibliografía

- [5] J. Bukovina. “Social media big data and capital markets - An overview”. Journal of Behavioral and Experimental Finance, Vol. 11, pp. 18-26, 2016.
- [6] P. Hitzler y K. Janowicz. “Linked Data, Big Data, and the 4th Paradigm”. Semantic Web, vol. 4, no 3, pp. 233–235, 2013.
- [7] V. Mayer-Schönberger y K. Cukier. Big data: A revolution that will transform how we live, work, and think. Houghton Mifflin Harcourt, 2013.