

## REGRESIÓN LINEAL SIMPLE


### 1. MODELO DE REGRESIÓN LINEAL SIMPLE

#### SITUACIÓN PROBLEMA

Supón que te debes mudar a una nueva ciudad porque obtuviste un ascenso en la empresa donde trabajas. Desde luego, estarás preocupado por los problemas que enfrentarás al trasladarte hacia y desde el trabajo. Por ejemplo, te gustaría saber cuánto tardarás en ir al trabajo cada mañana usando el metro con el que cuenta la ciudad donde vivirás. Usa “distancia al trabajo en un sentido” como una medida de distancia de donde vives. Tú vives a  $x$  kilómetros de distancia del trabajo y quieres saber cuánto tardarás en trasladarte cada día. El dueño de la empresa, al prever esta pregunta, ya recolectó una muestra aleatoria de datos a usar para responder tu pregunta. A 10 de tus nuevos compañeros de trabajo se les pidió dar sus tiempos de viaje (min) en un sentido y las distancias (km) hasta el trabajo. Los datos resultantes se muestran en la siguiente tabla. (Por conveniencia, los datos se ordenaron de modo que los valores  $x$  están en orden numérico).

| Distancia (km) | Tiempo (min) |
|----------------|--------------|
| 4              | 8            |
| 5              | 15           |
| 6              | 13           |
| 6              | 18           |
| 8              | 20           |
| 9              | 20           |
| 10             | 25           |
| 11             | 21           |
| 12             | 30           |
| 15             | 32           |

a) Elabore un diagrama de dispersión para examinar si la regresión lineal puede ser apropiada.



Se puede observar que existe una tendencia lineal ascendente (positiva) y, por tanto, la regresión lineal simple puede ser apropiada.

b) Encuentra la recta de mejor ajuste (ecuación de regresión) entre el tiempo de viaje en un sentido y la distancia hasta el trabajo.

La ecuación de regresión lineal determinada por el método de los mínimos cuadrados entre una variable  $y$  (dependiente) y una variable  $x$  (independiente) se expresa así:

$$\hat{y} = bx + a$$

donde,

$$b = \frac{S_{xy}}{S_{xx}} \quad a = \frac{\sum y - b \sum x}{n}$$

$$S_{xy} = \sum xy - \frac{(\sum x)(\sum y)}{n} \quad S_{xx} = \sum x^2 - \frac{(\sum x)^2}{n} \quad S_{yy} = \sum y^2 - \frac{(\sum y)^2}{n}$$

Entonces, construimos la siguiente tabla aumentada para poder calcular las tres S:

| x = distancia (km) | y = tiempo (min) | $x^2$            | $y^2$             | xy                |
|--------------------|------------------|------------------|-------------------|-------------------|
| 4                  | 8                | $4^2 = 16$       | $8^2 = 64$        | $4 \cdot 8 = 32$  |
| 5                  | 15               | $5^2 = 25$       | $15^2 = 225$      | $5 \cdot 15 = 75$ |
| 6                  | 13               | $6^2 = 36$       | $13^2 = 169$      | $6 \cdot 13 = 78$ |
| 6                  | 18               | 36               | 324               | 108               |
| 8                  | 20               | 64               | 400               | 160               |
| 9                  | 20               | 81               | 400               | 180               |
| 10                 | 25               | 100              | 625               | 250               |
| 11                 | 21               | 121              | 441               | 231               |
| 12                 | 30               | 144              | 900               | 360               |
| 15                 | 32               | 225              | 1024              | 480               |
| $\sum x = 86$      | $\sum y = 202$   | $\sum x^2 = 848$ | $\sum y^2 = 4572$ | $\sum xy = 1954$  |

$$S_{xy} = \sum xy - \frac{(\sum x)(\sum y)}{n} = 1954 - \frac{(86)(202)}{10} = 216.8$$

$$S_{xx} = \sum x^2 - \frac{(\sum x)^2}{n} = 848 - \frac{(86)^2}{10} = 108.4 \text{ [Nunca puede ser negativa]}$$

$$S_{yy} = \sum y^2 - \frac{(\sum y)^2}{n} = 4572 - \frac{(202)^2}{10} = 491.6 \text{ [Nunca puede ser negativa]}$$

Ahora calculamos "b" y "a":

$$b = \frac{S_{xy}}{S_{xx}} = \frac{216.8}{108.4} = 2$$

$$a = \frac{\sum y - b(\sum x)}{n} = \frac{[202 - 2(86)]}{10} = \frac{30}{10} = 3$$

Nota: generalmente “a” y “b” son un número decimales, y se redondean de acuerdo a la precisión de los datos. Una regla simple, es colocarles uno o dos decimales más de los que tienen los datos.

De esta manera, encontramos que  $b = 2$  y  $a = 3$ . Entonces, la ecuación de regresión  $\hat{y} = bx + a$  se convierte en:

$$\hat{y} = 2x + 3$$

Colocando el nombre de las variables ( $x$  = distancia,  $y$  = tiempo), se tendría:

$$\text{Tiempo estimado} = 2 * \text{distancia} + 3$$

Para este problema,  $b = 2$ , es decir, **el tiempo estimado (y) para ir o venir del trabajo aumenta en 2 minutos por cada kilómetro adicional de distancia (x) entre el lugar de trabajo y el lugar de residencia.**

Nota:

- Una pendiente positiva indica cuánto aumenta la variable  $y$  por cada unidad adicional de la variable  $x$ .
- Una pendiente negativa indica cuánto disminuye la variable  $y$  por cada unidad adicional de la variable  $x$ .

En este problema,  $a = 3$ , lo que podría interpretarse como que **el tiempo estimado (y) para ir al trabajo es de 3 minutos si la persona vive a 0 kilómetros de distancia (x) del trabajo.** Sin embargo, esto no tiene sentido porque en el caso de que la persona viva a 0 kilómetros, entonces no tomaría el metro. Esta situación ocurre porque el valor de  $x = 0$  está por fuera del rango de  $x$  en los datos, es decir,  $x$  varía entre 4 y 15.

Nota:

- El intercepto indica cuál sería el valor estimado de la variable  $y$  si la variable  $x$  es igual a 0.

*c) Estima cuál sería el tiempo de viaje si consigues un lugar que se encuentra a una distancia de: i) 7 km y ii) 12 km.*

i) Si el lugar se encuentra a 7 km de distancia, entonces el tiempo estimado se calcula así:

Utilizamos la ecuación  $\hat{y} = 2x + 3$  y reemplazamos  $x = 7$

$$\hat{y}(7) = 2(7) + 3 = 14 + 3 = 17.$$

**Se estima que me demore 17 minutos en llegar al trabajo si consigo un lugar que esté a 7 km.**

ii) Si el lugar se encuentra a 12 km de distancia, entonces el tiempo estimado se calcula así:

Se utiliza la ecuación  $\text{Tiempo estimado} = 2 * \text{distancia} + 3$  y reemplazamos distancia = 12:

$$\text{Tiempo estimado}(12) = 2(12) + 3 = 24 + 3 = 27.$$

**Se estima que me demore 27 minutos en llegar al trabajo si consigo un lugar que esté a 12 km.**

## USO DE R: ELABORAR DIAGRAMA DE DÍSPERSON Y CALCULAR LOS COEFICIENTES

### Paso 1: introducir los datos en el programa

*distancia = c(4, 5, 6, 6, 8, 9, 10, 11, 12, 15)*

*tiempo = c(8, 15, 13, 18, 20, 20, 25, 21, 30, 32)*

## Paso 2: crear diagrama de dispersión


`plot(x=distancia, y=tiempo, xlab="Distancia (km)", ylab = "Tiempo (min)", main = "Diagrama de dispersión de \n distancia vs tiempo hacia el trabajo")`

`xlab` es el nombre del eje x, es decir, la variable x

`ylab` es el nombre del eje y, es decir, la variable y

`main` es el título del gráfico

`\n` sirve para dividir el título en varias líneas una debajo de otra. En este caso, dividimos el título en dos líneas por ser un poco extenso.



## Paso 3: calcular los coeficientes “a” y “b” de $\hat{y} = bx + a$

`lm(tiempo~distancia)`

El formato de lm es: `lm(y~x)`

```
Console Terminal x Jobs x
/cloud/project/
> distancia = c(4, 5, 6, 6, 8, 9, 10, 11, 12, 15)
> tiempo = c(8, 15, 13, 18, 20, 20, 25, 21, 30, 32)
> plot(x=distancia, y=tiempo, xlab="Distancia (km)", ylab = "Tiempo (min)", main = "Diagrama de dispersión de \n distancia vs tiempo hacia el trabajo")
> lm(tiempo~distancia)

Call:
lm(formula = tiempo ~ distancia)

Coefficients:
(Intercept)      distancia
           3              2
```

## 2. VALIDEZ DEL MODELO DE REGRESIÓN LINEAL

Con frecuencia, el problema de analizar la calidad de la recta de regresión estimada se maneja mediante el enfoque del **análisis de varianza** (ANOVA): procedimiento con el que la variación total de la variable se subdivide en componentes significativos (Regresión y Error). Los cálculos se resumen mediante una **tabla de análisis de varianza**, como se indica en la tabla abajo mostrada:

| ANOVA               |                   |                    |                           |                       |         |
|---------------------|-------------------|--------------------|---------------------------|-----------------------|---------|
| Fuente de Variación | Suma de cuadrados | Grados de libertad | Media cuadrática          | F Calculado           | Valor P |
| Regresión           | $SSR$             | 1                  | $SSR$                     | $F = \frac{SSR}{s^2}$ | #####   |
| Error               | $SSE$             | $n - 2$            | $s^2 = \frac{SSE}{n - 2}$ |                       |         |
| Total               | $SST$             | $n - 1$            |                           |                       |         |

A) Calcular las sumas de cuadrados:

$$SSR = bS_{xy} = 2(216.8) = 433.6$$

$$SST = S_{yy} = 491.6$$

$$SSE = SST - SSR = 491.6 - 433.6 = 58$$

B) Determinar los grados de libertad:

Para la regresión: 1, siempre para regresión lineal simple.

Para el error:  $n - 2 = 10 - 2 = 8$

Para el total:  $n - 1 = 10 - 1 = 9$

C) Obtener las medias cuadráticas:

Para la regresión: 433.6, es el mismo valor de  $SSR$

Para el error: se divide la suma de cuadrados del error entre sus grados de libertad

$$s^2 = \frac{SSE}{n - 2} = \frac{58}{8} = 7.25$$

D) Calcular el estadístico F:

Se divide la media cuadrática de la regresión entre la media cuadrática del error

$$F = \frac{SSR}{s^2} = \frac{433.6}{7.25} = 59.807$$

E) Hallar el valor P:

La fórmula para usar en R es: `pf(valor, df1, df2, lower.tail=FALSE)`, donde

- Valor = valor del estadístico F calculado en el paso anterior: 59.807
- df1 = grados de libertad de la regresión: 1
- df2 = grados de libertad del error: 8

De esta forma:

$$\text{Valor p} = \text{pf}(59.807, 1, 8, \text{lower.tail=FALSE}) = 5.57\text{e} - 05 \cong 0.0001$$

```
> pf(59.807, 1, 8, lower.tail=FALSE)
[1] 5.568275e-05
> round(5.568275e-05,4)
[1] 1e-04
> 0.0001 #Porque hay que colocarle cuatro ceros delante al 1
```

En estos momentos, ya hemos calculados todos los elementos de la tabla ANOVA y procedemos a rellenarla con los valores obtenidos.

| ANOVA               |                   |                    |                  |             |         |
|---------------------|-------------------|--------------------|------------------|-------------|---------|
| Fuente de Variación | Suma de cuadrados | Grados de libertad | Media cuadrática | F Calculado | Valor P |
| Regresión           | 433.6             | 1                  | 433.6            | 59.807      | 0.0001  |
| Error               | 58                | 8                  | 7.25             |             |         |
| Total               | 491.6             | 9                  |                  |             |         |

F) Determinar si el modelo es válido o no:

- i) Si el valor P es mayor que el nivel de significancia, entonces el modelo lineal no es válido y, por lo tanto, no existe una relación lineal estadísticamente significativa entre las variables.
- ii) Si el valor P es menor o igual que el nivel de significancia, entonces el modelo lineal sí es válido y, por lo tanto, sí existe una relación lineal estadísticamente significativa entre las variables.

Así las cosas, como el valor P (0.0001) es menor que el nivel de significancia (0.05), entonces podemos afirmar el modelo lineal es válido y, por lo tanto, existe una relación lineal estadísticamente significativa entre la distancia hacia el trabajo y el tiempo necesario para trasladarse en metro hasta el trabajo.

## USO DE R: CALCULAR EL ANOVA

**Paso 1: introducir los datos en el programa (se puede omitir si ya se habían introducido antes):**

*distancia* = c(4, 5, 6, 6, 8, 9, 10, 11, 12, 15)

*tiempo* = c(8, 15, 13, 18, 20, 20, 25, 21, 30, 32)

**Paso 2: usar los comandos summary y aov**

summary(aov(tiempo~distancia))

```

Console Terminal x Jobs x
/cloud/project/
> distancia = c(4, 5, 6, 6, 8, 9, 10, 11, 12, 15)
> tiempo = c(8, 15, 13, 18, 20, 20, 25, 21, 30, 32)
> summary(aov(tiempo~distancia))
              Df Sum Sq Mean Sq F value    Pr(>F)
distancia      1  433.6    433.6   59.81 5.57e-05 ***
Residuals      8   58.0      7.3

```

Nota: se obtiene el mismo ANOVA, pero sin la suma de cuadrados y los grados de libertad del total. Sin embargo, ambos valores se pueden obtener al sumar las cantidades respectivas de la regresión y del error:

$$\text{Suma de cuadrados del total} = 433.6 + 58.0 = 491.6$$

$$\text{Grados de libertad del total} = 1 + 8 = 9$$

### 3. COEFICIENTE DE CORRELACIÓN Y DE DETERMINACIÓN

Nuestro objetivo en adelante será medir la bondad del ajuste de la recta de regresión a los datos observados y cuantificar al mismo tiempo el grado de asociación lineal existente entre las variables en cuestión. A mejor ajuste, mejores serán las predicciones realizadas con el modelo.

La evaluación global de una recta de regresión puede hacerse mediante la varianza residual, que como sabemos es un índice de la precisión del modelo. Sin embargo, esta medida no es útil para comparar rectas de regresión de variables distintas, o comparar el grado de asociación lineal entre distintos pares de variables, ya que depende de las unidades de medida de las variables.

#### 3.1. Coeficiente de correlación

Como solución al inconveniente planteado, para medir la asociación lineal entre dos variables  $x$  e  $y$  se utiliza una medida adimensional denominada coeficiente de correlación lineal, dado por:

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}}$$

El coeficiente de correlación lineal toma valores entre  $-1$  y  $1$  y su interpretación es la siguiente:

- Un valor cercano o igual a 0 indica respectivamente poca o ninguna relación lineal entre las variables. Cuanto más se acerque en valor absoluto a 1 mayor será el grado de asociación lineal entre las variables. Un coeficiente igual a 1 en valor absoluto indica una dependencia lineal exacta entre las variables.
- Un coeficiente positivo indica asociación lineal positiva, es decir, tienden a variar en el mismo sentido. Un coeficiente negativo indica asociación lineal negativa, es decir, tienden a variar en sentido opuesto.
- Para describir la fuerza de la asociación (tamaño del efecto) se compara el valor absoluto del coeficiente de regresión con los siguientes umbrales: 0 asociación nula, 0.3: asociación débil, 0.5: asociación moderada, 0.7: asociación fuerte y 0.9 asociación muy fuerte..

Para el problema desarrollado en esta guía:

$$r = \frac{S_{xy}}{\sqrt{S_{xx}S_{yy}}} = \frac{216.8}{\sqrt{(108.4)(491.6)}} = 0.9392$$

El coeficiente de correlación entre la distancia hacia el trabajo y el tiempo para ir hasta el trabajo en metro es de 0.9392. Por lo tanto, se evidencia una asociación *positiva muy fuerte* entre estas dos variables.

#### USO DE R: CALCULAR EL COEFICIENTE DE CORRELACIÓN

**Paso 1: introducir los datos en el programa (ver secciones anteriores)**

**Paso 2: usar el comando *cor***

`cor(distancia, tiempo)` [se pueden colocar las variables en cualquier orden]

```
> cor(distancia, tiempo) > cor(tiempo, distancia)
[1] 0.9391581             [1] 0.9391581
```

### 3.2. Coeficiente de determinación

Según hemos visto, el coeficiente de correlación lineal puede interpretarse como una medida de la bondad del ajuste del modelo lineal, concretamente, un valor del coeficiente igual a 1 o -1 indica dependencia lineal exacta, en cuyo caso el ajuste es perfecto. No obstante, para cuantificar la bondad del ajuste de un modelo, lineal o no, se utiliza una medida que se denomina coeficiente de determinación  $R^2$ , que es la proporción de variabilidad de la variable Y que queda explicada por el modelo de entre todas las variables presentes, y cuya expresión es:

$$R^2 = 1 - \frac{SSE}{SST} \quad \text{o} \quad R^2 = \frac{SSR}{SST}$$

que en modelo de regresión lineal coincide con el cuadrado del coeficiente de correlación lineal:  
 $R^2 = r^2$ .

El coeficiente de determinación toma valores entre 0 y 1, y cuanto más se aproxime a 1 mejor será el ajuste y, por lo tanto, mayor la fiabilidad de las predicciones que con él realicemos. Nótese que si el coeficiente de correlación lineal  $r$  es igual a -1 o 1 entonces  $R^2 = 1$ , y por lo tanto el ajuste lineal es perfecto.

Para el problema desarrollado en esta guía:

| ANOVA               |                   |                    |                  |             |         |
|---------------------|-------------------|--------------------|------------------|-------------|---------|
| Fuente de Variación | Suma de cuadrados | Grados de libertad | Media cuadrática | F Calculado | Valor P |
| Regresión           | 433.6             | 1                  | 433.6            | 59.807      | 0.0001  |
| Error               | 58                | 8                  | 7.25             |             |         |
| Total               | 491.6             | 9                  |                  |             |         |

$$R^2 = \frac{SSR}{SST} = \frac{433.6}{491.6} = 0.8820 = \mathbf{88.20\%} \text{ [Expresar siempre como porcentaje]}$$

De manera alternativa

$$R^2 = r^2 = (0.9392)^2 = 0.8821 = \mathbf{88.21\%}$$

El coeficiente de determinación del modelo lineal es de **88.21%**, por lo tanto, la variación de la distancia hacia el trabajo explica el **88.21%** de la variación del tiempo para ir hasta el trabajo en metro. Se puede decir que es un buen modelo ya que  $R^2 \geq 60\%$ .

### USO DE R: CALCULAR EL COEFICIENTE DE DETERMINACIÓN

**Paso 1: introducir los datos en el programa (ver secciones anteriores)**

```
> summary(lm(tiempo~distancia))
```

**Paso 2: usar los comandos *summary* y *lm***

```
summary(lm(tiempo~distancia))
```

```
Call:
lm(formula = tiempo ~ distancia)

Residuals:
    Min       1Q   Median       3Q      Max
-4.00  -1.75   0.00   2.00   3.00

Coefficients:
            Estimate Std. Error t value Pr(>|t|)
(Intercept)   3.0000     2.3815   1.260    0.243
distancia     2.0000     0.2586   7.733 5.57e-05 ***
---
Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1

Residual standard error: 2.693 on 8 degrees of freedom
Multiple R-squared:  0.882    Adjusted R-squared:  0.8673
F-statistic: 59.81 on 1 and 8 DF, p-value: 5.568e-05
```



## 4. INTERVALO DE CONFIANZA PARA LA RESPUESTA MEDIA Y UNA RESPUESTA

### 4.1. Intervalo de confianza para la respuesta media

Este intervalo se calcula cuando se desea obtener un intervalo de confianza para el valor promedio de la variable  $y$  cuando la variable  $x$  toma un valor específico  $x_0$ :

$$\hat{y}(x_0) \pm t_{\left(\frac{\alpha}{2}, n-1\right)} \cdot s \cdot \sqrt{\frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

- Calcule un **intervalo de confianza** para el **tiempo promedio** necesario para ir al trabajo de las personas que viven a 14 km de distancia.

Paso 1: Como  $x_0 = 14$ , entonces debemos estimar  $\hat{y}(14)$  usando  $\hat{y} = 2x + 3$ :

$$\hat{y}(14) = 2(14) + 3 = 31$$

Paso 2: Calcular  $\bar{x}$ :

$$\bar{x} = \frac{\sum x}{n} = \frac{86}{10} = 8.6$$

Paso 3: Calcular  $s$ :

$$s = \sqrt{\text{Media cuadrática del error}}$$

$$s = \sqrt{7.25} = 2.69$$

Paso 4: Encontrar  $t_{\left(\frac{\alpha}{2}, n-1\right)}$ :

$$\alpha = 1 - c = 1 - 0.95 = 0.05$$

$$\alpha/2 = 0.05/2 = 0.025$$

$$df = n - 1 = 10 - 1 = 9$$

$$\text{qt}(\alpha/2, df, \text{lower.tail} = \text{FALSE})$$

$$t = \text{qt}(0.025, 9, \text{lower.tail} = \text{FALSE}) = 2.262$$

Paso 5: Calcular el valor de  $S_{xx}$

$$S_{xx} = 108.4$$

Ahora sí podemos calcular el intervalo de confianza pedido

$$\text{I.C.} = 31 \pm (2.262)(2.69) \sqrt{\frac{1}{10} + \frac{(14 - 8.6)^2}{108.4}} = 31 \pm 3.7 = (27.3, 34.7)$$

**Podemos afirmar con un 95% de confianza que el tiempo promedio que necesitan las personas para ir al trabajo en metro está entre 27.3 y 34.7 minutos si viven a 14 km de distancia.**

### 4.2. Intervalo de confianza para una respuesta

Este intervalo se calcula cuando se desea obtener un intervalo de confianza para un valor individual de la variable  $y$  cuando la variable  $x$  toma un valor específico  $x_0$ :

$$\hat{y}(x_0) \pm t_{\left(\frac{\alpha}{2}, n-1\right)} \cdot s \cdot \sqrt{1 + \frac{1}{n} + \frac{(x_0 - \bar{x})^2}{S_{xx}}}$$

- Halle un intervalo de confianza para el tiempo que necesita una persona para ir al trabajo si vive a 14 km de distancia.

$$\text{I.C.} = 31 \pm (2.262)(2.69) \sqrt{1 + \frac{1}{10} + \frac{(14 - 8.6)^2}{108.4}} = 31 \pm 7.1 = (23.9, 38.1)$$

**Podemos afirmar con un 95% de confianza que el tiempo que necesita una persona para ir al trabajo en metro está entre 24 y 38 minutos si vive a 14 km.**