

Sección 1.2

Modelos *logit* y *probit*

Métodos estadísticos II para la ciencia de datos



1.2 Modelos logit y probit

1.2.1. Modelo logit

1.2.2. Modelo probit

Tema 1.2.1


Modelo *logit*

Sección 1.2.1 Modelo logit

Definición

La regresión logística, también llamada modelo logit, se utiliza para modelar variables de resultado dicotómicas.

En el modelo logit, las probabilidades logarítmicas del resultado se modelan como una combinación lineal de las variables predictoras.



Sección 1.2.1 Modelo logit

Paquetes R a instalar

```
install.packages("aod")
```

```
install.packages("ggplot2")
```

Datos a usar

Binary_data.csv

Descripción de los datos

```
## view the first few rows of the data  
head(mydata)
```

```
##   admit gre  gpa rank  
## 1     0 380 3.61    3  
## 2     1 660 3.67    3  
## 3     1 800 4.00    1  
## 4     1 640 3.19    4  
## 5     0 520 2.93    4  
## 6     1 760 3.00    2
```

Sección 1.2.1 Modelo logit

Resumen de datos

```
summary(mydata)
```

```
##      admit      gre      gpa      rank
##  Min.    :0.000  Min.    :220  Min.    :2.26  Min.    :1.00
##  1st Qu.:0.000  1st Qu.:520  1st Qu.:3.13  1st Qu.:2.00
##  Median :0.000  Median :580  Median :3.40  Median :2.00
##  Mean   :0.318  Mean   :588  Mean   :3.39  Mean   :2.48
##  3rd Qu.:1.000  3rd Qu.:660  3rd Qu.:3.67  3rd Qu.:3.00
##  Max.   :1.000  Max.   :800  Max.   :4.00  Max.   :4.00
```

```
sapply(mydata, sd)
```

```
##      admit      gre      gpa      rank
##  0.466 115.517   0.381   0.944
```

```
## two-way contingency table of categorical outcome and predictors we want
## to make sure there are not 0 cells
xtabs(~admit + rank, data = mydata)
```

```
##      rank
## admit  1  2  3  4
##      0 28 97 93 55
##      1 33 54 28 12
```


Sección 1.2.1 Modelo logit

Cálculo del modelo logit

```
mydata$rank <- factor(mydata$rank)
mylogit <- glm(admit ~ gre + gpa + rank, data = mydata, family = "binomial")
```

```
summary(mylogit)
```

```
## Coefficients:
##              Estimate Std. Error z value Pr(>|z|)
## (Intercept) -3.98998      1.13995  -3.50  0.00047 ***
## gre          0.00226      0.00109   2.07  0.03847 *
## gpa          0.80404      0.33182   2.42  0.01539 *
## rank2       -0.67544      0.31649  -2.13  0.03283 *
## rank3       -1.34020      0.34531  -3.88  0.00010 ***
## rank4       -1.55146      0.41783  -3.71  0.00020 ***
## ---
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
## (Dispersion parameter for binomial family taken to be 1)
##
##      Null deviance: 499.98  on 399  degrees of freedom
## Residual deviance: 458.52  on 394  degrees of freedom
## AIC: 470.5
##
## Number of Fisher Scoring iterations: 4
```

Sección 1.2.1 Modelo logit

Predicciones

```
newdata1 <- with(mydata, data.frame(gre = mean(gre), gpa = mean(gpa), rank = factor(1:4)))
```

```
## view data frame  
newdata1
```

```
##   gre   gpa rank  
## 1 588 3.39    1  
## 2 588 3.39    2  
## 3 588 3.39    3  
## 4 588 3.39    4
```

```
newdata1$rankP <- predict(mylogit, newdata = newdata1, type = "response")  
newdata1
```

```
##   gre   gpa rank rankP  
## 1 588 3.39    1 0.517  
## 2 588 3.39    2 0.352  
## 3 588 3.39    3 0.219  
## 4 588 3.39    4 0.185
```


Tema 1.2.2


Modelo *probit*

Sección 1.2.2 Modelo probit

Definición

La regresión probit, también llamada modelo probit, se utiliza para modelar variables de resultado dicotómicas o binarias.

En el modelo probit, la distribución normal estándar inversa de la probabilidad se modela como una combinación lineal de los predictores.



Sección 1.2.2 Modelo probit

Descripción de los datos

Paquetes R a instalar

```
install.packages("aod")
```

```
install.packages("ggplot2")
```

Datos a usar

Binary_data.csv

```
## view the first few rows of the data  
head(mydata)
```

```
##   admit gre  gpa rank  
## 1     0 380 3.61   3  
## 2     1 660 3.67   3  
## 3     1 800 4.00   1  
## 4     1 640 3.19   4  
## 5     0 520 2.93   4  
## 6     1 760 3.00   2
```

Sección 1.2.2 Modelo probit

Resumen de datos

```
summary(mydata)
```

```
##      admit      gre      gpa      rank
##  Min.    :0.000  Min.    :220  Min.    :2.26  Min.    :1.00
##  1st Qu.:0.000  1st Qu.:520  1st Qu.:3.13  1st Qu.:2.00
##  Median :0.000  Median :580  Median :3.40  Median :2.00
##  Mean   :0.318  Mean   :588  Mean   :3.39  Mean   :2.48
##  3rd Qu.:1.000  3rd Qu.:660  3rd Qu.:3.67  3rd Qu.:3.00
##  Max.   :1.000  Max.   :800  Max.   :4.00  Max.   :4.00
```

```
sapply(mydata, sd)
```

```
##      admit      gre      gpa      rank
##  0.466 115.517    0.381    0.944
```

```
## two-way contingency table of categorical outcome and predictors we want
## to make sure there are not 0 cells
xtabs(~admit + rank, data = mydata)
```

```
##      rank
## admit  1  2  3  4
##      0 28 97 93 55
##      1 33 54 28 12
```


Sección 1.2.2 Modelo probit

Cálculo del modelo probit

```
myprobit <- glm(admit ~ gre + gpa + rank, family = binomial(link = "probit"),  
  data = mydata)
```

```
## model summary  
summary(myprobit)
```

```
## Coefficients:
```

```
##           Estimate Std. Error z value Pr(>|z|)  
## (Intercept) -2.38684    0.67395  -3.54  0.00040 ***  
## gre          0.00138    0.00065   2.12  0.03433 *  
## gpa          0.47773    0.19720   2.42  0.01541 *  
## rank2       -0.41540    0.19498  -2.13  0.03313 *  
## rank3       -0.81214    0.20836  -3.90  9.7e-05 ***  
## rank4       -0.93590    0.24527  -3.82  0.00014 ***
```

```
## ---
```

```
## Signif. codes:  0 '***' 0.001 '**' 0.01 '*' 0.05 '.' 0.1 ' ' 1
```

```
##
```

```
## (Dispersion parameter for binomial family taken to be 1)
```

```
##
```

```
##      Null deviance: 499.98  on 399  degrees of freedom
```

```
## Residual deviance: 458.41  on 394  degrees of freedom
```

```
## AIC: 470.4
```

```
##
```

```
## Number of Fisher Scoring iterations: 4
```

Sección 1.2.2 Modelo probit

Predicciones

```
newdata <- data.frame(gre = rep(seq(from = 200, to = 800, length.out = 100),  
  4 * 4), gpa = rep(c(2.5, 3, 3.5, 4), each = 100 * 4), rank = factor(rep(rep(1:4,  
  each = 100), 4)))
```

```
newdata[, c("p", "se")] <- predict(myprobit, newdata, type = "response", se.fit = TRUE)[-3]
```


```
ggplot(newdata, aes(x = gre, y = p, colour = rank)) + geom_line() + facet_wrap(~gpa)
```

```
head(newdata)
```

##		gre	gpa	rank
##	1	200.0	2.5	1
##	2	206.1	2.5	1
##	3	212.1	2.5	1
##	4	218.2	2.5	1
##	5	224.2	2.5	1
##	6	230.3	2.5	1

Sección 1.2.2 Modelo probit

Predicciones



¿Preguntas?

Actividades asociadas a esta presentación:

- Actividad ABC
- Actividad DEF

Bibliografía

- Lacourly, N. (2012). Estadística multivariada. Santiago de Chile, Chile: Editorial ebooks Patagonia - J.C. Sáez Editor.
- Miranda, D. (2016). Comparación de la calidad de los ajustes obtenidos mediante los modelos de respuesta binaria: LOGIT vs PROBI, en índices de inestabilidad atmosférica para la ocurrencia o no de precipitaciones.URL
- Ross, S. M. y Valdés Sánchez, T. (2014). Introducción a la estadística. Barcelona, Spain: Editorial Reverté.URL