

Sección 2.2

Análisis discriminante

Métodos estadísticos II para la ciencia de datos

2.2 Análisis discriminante

2.2.1. Introducción al análisis discriminante

2.2.2. Reglas de discriminación

Tema 2.2.1

Introducción al análisis discriminante

Objetivos

Dos son los objetivos principales abordados por el análisis discriminante, de una parte está la separación o discriminación de grupos, y de otra, la predicción o asignación de un objeto en uno de entre varios grupos previamente definidos, con base en los valores de las variables que lo identifican.

En otras palabras, el análisis discriminante se orienta a “ubicar” un objeto o unidad muestral, en uno de varios grupos de acuerdo con una regla de clasificación.

Sin embargo, frecuentemente la mejor función para separar grupos provee también la mejor regla de localización de observaciones futuras; de tal forma que estos dos términos generalmente se emplean indistintamente.

Ejemplos de aplicación

- Una persona que aspira a ocupar un cargo en una empresa, es sometida a una serie de pruebas; de acuerdo con su puntaje se sugiere ubicarlo en alguno de los departamentos de la empresa.
- Un biólogo quiere clasificar una “nueva” planta en una de varias especies conocidas (taxonomía numérica).
- Un arqueólogo debe ubicar a un antepasado en uno de cuatro períodos históricos.
- En medicina forense, se debe determinar el género (sexo) de una persona con base en algunas medidas sobre determinados huesos de su cuerpo

Descripción del procedimiento

En el análisis discriminante se obtiene una función que separa entre varios grupos definidos a priori, esta función es una combinación, generalmente lineal, de las variables de identificación, la cual minimiza los errores de clasificación.

El problema de la discriminación es entonces comprobar si tales variables permiten diferenciar las clases definidas previamente y precisar como se puede hacer.

Cabe resaltar que el problema es identificar la clase a la que se debe asignar un individuo, de quien se sabe que pertenece a una de las clases definidas de antemano, y para el cual solo se conocen los valores de las variables “explicativas”.

Se sigue entonces una tarea de discriminación descriptiva en primer lugar, con la que se asignan individuos a las clases, más no se agrupan, puesto que no se trata de construir grupos sino de asignar individuos a estos.

Tema 2.2.2

Reglas de discriminación para dos grupos

Regla general

La mayor parte de la literatura sobre análisis discriminante trata el problema para dos poblaciones. Con base en un vector X de variables medidas sobre una unidad de observación, que en adelante se indicará como la observación X , se quiere clasificar esta unidad en una de dos poblaciones.

Sean $f(X|G_1)$ la función de densidad para X en G_1 y $f(X|G_2)$ la función de densidad para X en G_2 , con G_1 y G_2 las dos poblaciones. Sean p_1 y p_2 las probabilidades a priori, donde $p_1 + p_2 = 1$, entonces, la regla de discriminación óptima, es decir, la regla que minimiza la probabilidad total de clasificación incorrecta, es:

- *Asignar X a G_1 si $p_1 f(X|G_1) > p_2 f(X|G_2)$*
- *Asignar X a G en otro caso.*

Clasificación vía máxima verosimilitud

Supóngase que se conocen las distribuciones de las dos poblaciones. Sean $f_1(X)$ y $f_2(X)$ las *fdp* de cada una de las poblaciones, con X vector de observaciones de tamaño $(p \times 1)$ (un caso).

La regla de discriminación máximo verosímil para localizar el caso caracterizado por X en alguna de dos poblaciones, consiste en ubicarlo en la población para la cual X maximiza la verosimilitud o probabilidad.

En símbolos, si G_1 y G_2 son las dos poblaciones, entonces se ubica a X en G_i si

$$L_i(X) = \max_j \{L_j\}, \text{ con } i, j = 1, 2$$

Esta regla es extensible a cualquier número de poblaciones. En caso de empates, X se asigna a cualquiera de las poblaciones.

Clasificación vía máxima verosimilitud: matrices de covarianzas iguales

Supóngase que las poblaciones G_i se distribuyen $N(\boldsymbol{\mu}_i, \boldsymbol{\Sigma})$ con $i = 1, 2$, tal que la verosimilitud de la i -ésima población es:

$$L_i(X) = |2\pi\boldsymbol{\Sigma}|^{-1/2} \exp \left\{ -\frac{1}{2} (X - \boldsymbol{\mu}_i)' \boldsymbol{\Sigma}^{-1} (X - \boldsymbol{\mu}_i) \right\}$$

Maximizar $L_i(X)$ equivale a obtener el mínimo de $(X - \boldsymbol{\mu}_i)' \boldsymbol{\Sigma}^{-1} (X - \boldsymbol{\mu}_i)$, el cual es la distancia de Mahalanobis de X a $\boldsymbol{\mu}_i$.

De esta forma, se asigna X a G_1 si:

$$(\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \boldsymbol{\Sigma}^{-1} X - \frac{1}{2} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2)' \boldsymbol{\Sigma}^{-1} (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)$$

El término $b = (\boldsymbol{\mu}_1 - \boldsymbol{\mu}_2)' \boldsymbol{\Sigma}^{-1}$ es la *función discriminante lineal*. Así, la función discriminante es de la forma $Y = b'X$; la cual es una combinación lineal de las medidas asociadas con las variables para un objeto o individuo particular.

Entonces, la regla de asignación será:

- Si $b(X - \boldsymbol{\mu}_c) \geq 0$, entonces X se asigna a G_1 ,
- Si $b(X - \boldsymbol{\mu}_c) < 0$, entonces X se asigna a G_2 ,

donde $\boldsymbol{\mu}_c = \frac{1}{2} (\boldsymbol{\mu}_1 + \boldsymbol{\mu}_2)$

Clasificación vía máxima verosimilitud: matrices de covarianzas diferentes

Si las dos poblaciones G_1 y G_2 tienen distribución normal p -variante con matrices de covarianzas distintas $\Sigma_1 \neq \Sigma_2$, el logaritmo de la razón de la verosimilitud para una observación particular X es el siguiente:

$$Q(X) = \ln \left(\frac{L_1(X)}{L_2(X)} \right)$$

Utilizando la definición de $L_i(X)$ se puede expresar $Q(X)$ de la siguiente forma:

$$\begin{aligned} Q(X) &= \frac{1}{2} \ln \left(\frac{|\Sigma_2|}{|\Sigma_1|} \right) - \frac{1}{2} (\mu'_1 \Sigma_1^{-1} \mu_1 - \mu'_2 \Sigma_2^{-1} \mu_2) \\ &\quad + (\mu'_1 \Sigma_1^{-1} - \mu'_2 \Sigma_2^{-1})X - \frac{1}{2} X'(\Sigma_1^{-1} - \Sigma_2^{-1})X \end{aligned}$$

Entonces, la regla de asignación será:

- Si $Q(X) \geq 0$, entonces X se asigna a G_1 ,
- Si $Q(X) < 0$, entonces X se asigna a G_2 ,

Bibliografía

- Aguado Franco, J. C. (2006). Teoría de la decisión y de los juegos. Las Rozas (Madrid), Delta Publicaciones.