

Análisis discriminante

*Métodos estadísticos II
para la ciencia de datos*

Guía aplicada con R

Ejemplo 1: clasificación de vinos

Ejemplo 2: riesgo crediticio

Teoría breve · código en R · visualización · matriz de
confusión · interpretación

Propósito de la guía

Objetivo general

Comprender el análisis discriminante como una técnica supervisada para separar grupos conocidos y asignar observaciones a uno de esos grupos usando variables cuantitativas.

- ▶ La teoría se presenta junto con comandos en R.
- ▶ El caso wine muestra tres grupos y dos funciones discriminantes.
- ▶ El caso de clientes muestra dos grupos y una única función discriminante.
- ▶ La evaluación se realiza mediante matriz de confusión y precisión.

3 grupos

vinos: LD1 y LD2

2 grupos

clientes: solo LD1

R

ajuste, predicción, evaluación

Informe

interpretación aplicada

Ruta de trabajo: concepto y R se alternan



Descripción del flujo de la guía

Cada concepto se conecta con un resultado computacional inmediato: primero se plantea la idea, luego se observa en R y finalmente se interpreta.

Sección 1

Primer contacto: clasificar vinos con grupos conocidos


Pregunta inicial del caso wine

Problema de clasificación

Una base contiene muestras de vino de tres cultivos. Cada muestra tiene mediciones químicas. Se quiere construir una regla para clasificar una nueva muestra en uno de los tres cultivos.

- Unidad de observación: una muestra de vino.
- Grupo conocido: cultivo o tipo de vino.
- Predictoras: compuestos químicos.
- Resultado: grupo predicho.

Muestras por cultivo



Código base:

```
ggplot(vinos, aes(x = Type)) +  
  geom_bar() +  
  labs(x = "Cultivo", y = "Frecuencia")
```

R desde el inicio: cargar la base

```
library(MASS)
library(rattle)
library(ggplot2)

data(wine, package = "rattle")

vinos <- wine
vinos$Type <- as.factor(vinos$Type)

head(vinos)
str(vinos)
table(vinos$Type)
```

Lectura

Antes de hablar de fórmulas, se identifica la estructura: una variable de grupo y varias variables predictoras.

Estructura básica de los datos para análisis discriminante


Elemento	En el caso de vinos
Unidad de observación	Una muestra de vino.
Variable de grupo	Type: cultivo o tipo de vino.
Variables predictoras	Compuestos químicos medidos sobre cada muestra.
Tarea estadística	Asignar una muestra a uno de los grupos existentes.
Evaluación	Comparar grupo real con grupo predicho.

Advertencia

No se deben usar identificadores como variables predictoras. El modelo aprende de variables con significado analítico, no de códigos.

Primer vistazo con dos variables

Vista bivariada: dos variables químicas



Código base:

```
ggplot(vinos, aes(x = Alcohol, y = Flavanoids,  
                  color = Type)) +  
  geom_point()
```

Lectura

Con dos variables químicas ya se observa cierta separación, pero el análisis discriminante aprovecha simultáneamente las 13 variables.

- ▶ La separación no siempre es perfecta en una vista bivariada.
- ▶ La función discriminante crea ejes más útiles para clasificar.
- ▶ La visualización inicial prepara la intuición.

PCA vs. análisis discriminante

PCA / ACP	Análisis discriminante
No usa grupos conocidos.	Requiere una variable de grupo conocida.
Técnica no supervisada.	Técnica supervisada.
Busca resumir variables.	Busca separar y clasificar grupos.
Produce componentes principales.	Produce funciones discriminantes.
Maximiza variabilidad total.	Maximiza separación entre grupos.

Puente con PCA

En PCA el eje se elige por varianza; en análisis discriminante, por capacidad de separar grupos.

La idea estadística central

Definición aplicada

El análisis discriminante construye una o más funciones, generalmente lineales, de las variables predictoras para separar grupos definidos previamente y clasificar observaciones.

$$LD_1 = b_1X_1 + b_2X_2 + \cdots + b_pX_p$$

- ▶ $X_1, \dots, X_p$ son las variables predictoras.
- ▶ $b_1, \dots, b_p$ son coeficientes discriminantes.
- ▶ La puntuación LD ubica cada observación en un nuevo eje de separación.

Ajuste inicial del modelo en R

```
modelo_lda <- lda(Type ~ ., data = vinos)

modelo_lda
modelo_lda$prior
modelo_lda$means
modelo_lda$scaling
```

Interpretación de la fórmula

Type ~ . significa: usar todas las demás variables de la base como predictoras para discriminar los grupos de Type.

Supuestos y condiciones de uso

Supuestos clásicos

- ▶ Variable de grupo definida previamente.
- ▶ Variables predictoras cuantitativas.
- ▶ Observaciones independientes.
- ▶ Aproximación a normalidad multivariada por grupo.

Supuesto central de LDA

- ▶ Los grupos pueden tener medias diferentes.
- ▶ Sus matrices de covarianza deberían ser aproximadamente similares.
- ▶ Bajo esta condición, las fronteras de clasificación son lineales.

Lectura práctica

Los supuestos orientan la interpretación: no impiden usar el modelo como herramienta didáctica, pero sí deben mencionarse al reportar resultados.

Errores frecuentes

- ▶ Usar análisis discriminante sin variable de grupo conocida.
- ▶ Incluir identificadores como variables predictoras.
- ▶ Evaluar solo con la muestra de entrenamiento.
- ▶ Reportar precisión sin matriz de confusión.
- ▶ Ignorar que priors y tamaños de grupo afectan la clasificación.

Sección 2

Construcción e interpretación del modelo de vinos

Análisis discriminante

¿Cuántas funciones discriminantes aparecen en wine?

Regla general

Si hay p variables predictoras y g grupos, el número máximo de funciones discriminantes es:

$$\min(p, g - 1)$$

Caso wine

- ▶ $p = 13$ variables químicas.
- ▶ $g = 3$ cultivos.
- ▶ Máximo: $\min(13, 2) = 2$.

Resultado práctico

El modelo puede producir dos ejes: **LD1** y **LD2**. Por eso se puede graficar el caso en un plano discriminante.

Puntuaciones discriminantes en R

```
pred <- predict(modelo_lda)

head(pred$class)      # grupo predicho
head(pred$posterior)  # probabilidades posteriores
head(pred$x)          # puntuaciones LD1 y LD2
```

Salida clave

`predict()` devuelve tres objetos centrales: grupo predicho, probabilidades posteriores y puntuaciones discriminantes.

Probabilidades a priori y posteriores

Probabilidad a priori

Probabilidad inicial de pertenecer a cada grupo antes de observar las variables del caso. Puede venir de proporciones muestrales o de información externa.

Probabilidad posterior

Probabilidad actualizada después de observar las variables del caso. Se usa para asignar el grupo más probable.

En `lda()`

`modelo_lda$prior` muestra los priors; `pred$posterior` muestra las probabilidades posteriores.

La regla práctica de clasificación

Regla

Asignar la observación al grupo con mayor probabilidad posterior:

$$\hat{G}(X) = \arg \max_k P(G_k | X)$$

Muestra	$P(G_1 X)$	$P(G_2 X)$	$P(G_3 X)$	Grupo asignado
A	0.92	0.07	0.01	G_1
B	0.05	0.88	0.07	G_2
C	0.03	0.12	0.85	G_3

¿Cómo decide LDA a qué grupo pertenece una observación?

Idea aplicada

Después de ejecutar `predict()`, LDA calcula qué tan compatible es la observación con cada grupo y la asigna al grupo con mayor probabilidad posterior.

1. Compara el caso con el centro de cada grupo.
2. Considera la variabilidad y correlación entre variables.
3. Tiene en cuenta probabilidades a priori.
4. Calcula probabilidades posteriores.
5. Asigna el grupo más probable.

Distancia de Mahalanobis

$$D_i^2 = (X - \mu_i)^\top \Sigma^{-1} (X - \mu_i)$$

Mide qué tan lejos está un caso del centro de un grupo, considerando escala y correlación.

$$\hat{G}(X) = \arg \max_k P(G_k | X)$$

Coefficientes discriminantes

```
coeficientes <- modelo_lda$scaling
coeficientes

sort(abs(coeficientes[, 1]), decreasing = TRUE)
sort(abs(coeficientes[, 2]), decreasing = TRUE)
```

Uso

Este paso ayuda a identificar las variables que más aportan a la separación en LD1 y LD2.

Cuidado con la interpretación de coeficientes

Advertencia técnica

El tamaño de un coeficiente depende de la escala de la variable. Por eso no debe interpretarse mecánicamente como “importancia” sin revisar la escala y el contexto.


- ▶ Mirar valores absolutos ayuda, pero no es suficiente.
- ▶ Conviene revisar estandarización o comparar variables en escalas similares.
- ▶ La interpretación debe conectarse con el gráfico LD y la matriz de confusión.

Sección 3

Visualización y evaluación del caso wine

Análisis discriminante

Importancia relativa de LD1 y LD2



Lectura


LD1 explica la mayor parte de la separación entre cultivos y LD2 aporta separación complementaria.

- ▶ LD1: alrededor de 68.7 %.
- ▶ LD2: alrededor de 31.3 %.
- ▶ Juntas representan la separación disponible para tres grupos.

Código base:

```
prop <- modelo_lda$svd^2 / sum(modelo_lda$svd^2)
barplot(prop * 100)
```

Distribución de LD1




Interpretación

Cuando las distribuciones por grupo ocupan zonas diferentes de LD1, esa función discrimina bien.

Código base:

```
ldahist(data = pred$x[, 1], g = vinos$Type)
```


Distribución de LD2




Código base:

```
ldahist(data = pred$x[, 2], g = vinos$Type)
```

Interpretación

LD2 puede separar grupos que LD1 no termina de distinguir. En problemas con tres grupos, suele aportar información complementaria.

Plano discriminante LD1 vs LD2



Lectura visual

Cada punto es una muestra de vino. La separación entre regiones indica que los compuestos químicos distinguen muy bien los cultivos.

Código para graficar LD1 vs LD2

```
lda_df <- data.frame(  
  Type = vinos$Type,  
  LD1 = pred$x[, 1],  
  LD2 = pred$x[, 2]  
)  
  
ggplot(lda_df, aes(x = LD1, y = LD2, color = Type)) +  
  geom_point(size = 2.5, alpha = 0.85) +  
  labs(title = "Separacion de muestras de vino mediante LDA",  
        x = "Primera funcion discriminante (LD1)",  
        y = "Segunda funcion discriminante (LD2)") +  
  theme_minimal()
```


Matriz de confusión en la muestra completa

```
matriz_confusion <- table(  
  Real = vinos$Type,  
  Predicho = pred$class  
)  
  
matriz_confusion  
  
precision <- mean(pred$class == vinos$Type)  
precision
```

Qué evalúa

Compara el grupo real de cada muestra con el grupo predicho por el modelo.

Resultado sobre muestra completa



Lectura

En la muestra completa, el modelo clasifica correctamente todas las observaciones. La separación del caso wine es muy fuerte.

Precaución

Esta evaluación usa los mismos datos con los que se ajustó el modelo. Por eso se debe mostrar también una evaluación con datos de prueba.

Código base:

```
table(Real = vinos$Type, Predicho = pred$class
      )
mean(pred$class == vinos$Type)
```

Partición entrenamiento/prueba


```
set.seed(123)

# Separar la base por tipo de vino
tipo1 <- vinos[vinos$Type == 1, ]
tipo2 <- vinos[vinos$Type == 2, ]
tipo3 <- vinos[vinos$Type == 3, ]

# Seleccionar al azar el 70 % de cada tipo
i1 <- sample(nrow(tipo1), floor(0.70 * nrow(tipo1)))
i2 <- sample(nrow(tipo2), floor(0.70 * nrow(tipo2)))
i3 <- sample(nrow(tipo3), floor(0.70 * nrow(tipo3)))

# Crear los conjuntos de entrenamiento y prueba
entrenamiento <- rbind(tipo1[i1, ], tipo2[i2, ], tipo3[i3, ])
prueba <- rbind(tipo1[-i1, ], tipo2[-i2, ], tipo3[-i3, ])
```

Evaluación sobre prueba



Resultado obtenido

La prueba quedó distribuida en 18 muestras del cultivo 1, 22 del cultivo 2 y 15 del cultivo 3. El modelo obtuvo una precisión de **98.18 %**.

Interpretación

Solo hubo un error: una muestra real del cultivo 3 fue clasificada como cultivo 2. Ese caso debe revisarse como posible observación cercana a la frontera entre esos grupos.

Código base:

```
modelo_train <- lda(Type ~ ., data =  
  entrenamiento)  
pred_prueba <- predict(modelo_train, newdata =  
  prueba)
```

Código para evaluar en prueba

```
# Distribucion de los grupos en entrenamiento y prueba
table(entrenamiento$Type)
table(prueba$Type)

matriz_prueba <- table(Real = prueba$Type,
                      Predicho = pred_prueba$class)
matriz_prueba

precision_prueba <- mean(pred_prueba$class == prueba$Type)
precision_prueba

# Ubicar errores de clasificacion, si existen
errores_prueba <- which(pred_prueba$class != prueba$Type)
errores_prueba
```

Resultado numérico

Entrenamiento: 41, 49 y 33 observaciones por cultivo. Prueba: 18, 22 y 15. Matriz de prueba: (18, 0, 0); (0, 22, 0); (0, 1, 14). Precisión: 0.9818.

Matriz de confusión: cómo se lee

	Predicho G_1	Predicho G_2	Predicho G_3
Real G_1	Correctos de G_1	Error $G_1 \rightarrow G_2$	Error $G_1 \rightarrow G_3$
Real G_2	Error $G_2 \rightarrow G_1$	Correctos de G_2	Error $G_2 \rightarrow G_3$
Real G_3	Error $G_3 \rightarrow G_1$	Error $G_3 \rightarrow G_2$	Correctos de G_3

Regla de lectura

La diagonal principal contiene clasificaciones correctas. Los valores fuera de la diagonal son errores.

Precisión global

Definición

La precisión global es la proporción de observaciones correctamente clasificadas.

$$\text{Precisión} = \frac{\text{número de clasificaciones correctas}}{\text{número total de observaciones}}$$

Cuidado

Una precisión alta no reemplaza la interpretación. También se debe revisar qué grupos se confunden, si hay solapamiento y si el resultado tiene sentido contextual.

Clasificar una nueva muestra de vino

```
# Usar la primera observacion como si fuera un nuevo caso
nuevo_vino <- vinos[1, -1]

pred_nuevo <- predict(modelo_lda, newdata = nuevo_vino)

pred_nuevo$class
pred_nuevo$posterior
pred_nuevo$x
```

Aplicación

El modelo no solo describe la base histórica; también permite clasificar nuevos casos.

Sección 4

Segundo ejemplo: riesgo crediticio con una única función discriminante

¿Por qué agregar un segundo ejemplo?

Propósito didáctico

El caso wine tiene tres grupos y produce dos funciones discriminantes. Para entender la regla $\min(p, g - 1)$, conviene contrastarlo con un caso binario que produzca solo una función.

Ejemplo	Grupos	Funciones discriminantes
Vinos	3 cultivos	LD1 y LD2
Clientes	Riesgo bajo / alto	Solo LD1


Contexto del ejemplo de clientes

Problema

Una entidad financiera desea clasificar clientes según su nivel de riesgo crediticio: **Bajo** o **Alto**.

- ▶ Unidad de observación: un cliente.
- ▶ Variable de grupo: Riesgo.
- ▶ Predictoras: ingreso, puntaje, endeudamiento, mora, antigüedad y productos.
- ▶ Objetivo: construir una regla de clasificación.

Clientes por nivel de riesgo



Código base:

```
ggplot(clientes, aes(x = Riesgo)) +  
  geom_bar()
```

Variables del caso de clientes

Variable	Descripción
Cliente	Identificador del cliente; no entra al modelo.
Riesgo	Variable de grupo: Bajo / Alto.
Ingreso_mensual_millones	Ingreso mensual estimado en millones de pesos.
Puntaje_crediticio	Puntaje crediticio del cliente.
Nivel_endeudamiento_pct	Porcentaje de endeudamiento relativo.
Dias_mora_ult_12m	Días de mora acumulados en los últimos 12 meses.
Antiguedad_laboral_meses	Meses de antigüedad laboral.
Numero_productos_financieros	Número de productos financieros activos.

Nota

La base contiene 120 clientes: 60 de riesgo bajo y 60 de riesgo alto.

Importar el archivo CSV en R

```
library(MASS)
library(ggplot2)

getwd()

clientes <- read.csv("Datos_clientes_riesgo_discriminante.csv",
                     stringsAsFactors = TRUE)

clientes$Riesgo <- as.factor(clientes$Riesgo)

head(clientes)
str(clientes)
table(clientes$Riesgo)
```

Lectura del código

`read.csv()` importa la base desde el directorio de trabajo. La columna Cliente es un identificador; por eso se excluye antes de ajustar el modelo.

Preparar la base para LDA

```
# Excluir el identificador
clientes_modelo <- clientes[, -1]

# Verificar variables y grupos
names(clientes_modelo)
table(clientes_modelo$Riesgo)

# Ajustar LDA
modelo_clientes <- lda(Riesgo ~ ., data = clientes_modelo)

modelo_clientes
modelo_clientes$prior
modelo_clientes$means
modelo_clientes$scaling
```

Lectura del código

`clientes[, -1]` elimina la primera columna de la base. Esta operación evita que el identificador del cliente sea usado como predictor.

¿Por qué solo aparece una función?

Regla general

Número máximo de funciones discriminantes = $\min(p, g - 1)$


Caso clientes

- ▶ $p = 6$ variables predictoras.
- ▶ $g = 2$ grupos: Bajo y Alto.
- ▶ Máximo: $\min(6, 1) = 1$.

Resultado

El modelo construye una única función discriminante: **LD1**.

Vista bivariada del riesgo



Código base:

```
ggplot(clientes, aes(Puntaje_crediticio,  
  Nivel_endeudamiento_pct,  
  color = Riesgo)) + geom_point()
```

Lectura

Los clientes de alto riesgo tienden a presentar mayor endeudamiento y menor puntaje crediticio, aunque existe solapamiento.

- ▶ El LDA combina todas las variables.
- ▶ No se limita a dos dimensiones originales.
- ▶ La separación final ocurre sobre LD1.

Predicción en el ejemplo de clientes

```
pred_clientes <- predict(modelo_clientes)


head(pred_clientes$class)
head(pred_clientes$posterior)
head(pred_clientes$x)

matriz_clientes <- table(
  Real = clientes_modelo$Riesgo,
  Predicho = pred_clientes$class
)

matriz_clientes
mean(pred_clientes$class == clientes_modelo$Riesgo)
```

Cientes proyectados en LD1

Separación de clientes sobre una sola función LD1




Código base:

```
plot(pred_clientes$x[,1], rep(1, nrow(clientes_modelo)),  
     col = clientes_modelo$Riesgo, xlab = "LD1", ylab = "")
```

Lectura

Cada punto es un cliente proyectado sobre la única función discriminante. La separación se observa a lo largo de un solo eje.

Histograma de LD1 en clientes




Interpretación

Si los grupos se ubican en zonas diferentes de LD1, la función tiene capacidad discriminante.

Código base:

```
ldahist(data = pred_clientes$x[,1],  
        g = clientes_modelo$Riesgo)
```

Matriz de confusión: clientes



Código base:

```
table(Real = clientes_modelo$Riesgo,  
      Predicho = pred_clientes$class)
```

Lectura

En la muestra completa se obtiene una precisión de **99.17 %**: 119 de 120 clientes son clasificados correctamente.

Valor didáctico

A diferencia del caso wine, este ejemplo permite discutir errores de clasificación en un contexto empresarial.

Partición entrenamiento/prueba: clientes

```
set.seed(456)

# Separar la base por nivel de riesgo
riesgo_bajo <- clientes_modelo[clientes_modelo$Riesgo == "Bajo", ]
riesgo_alto <- clientes_modelo[clientes_modelo$Riesgo == "Alto", ]

# Seleccionar al azar el 70 % de cada grupo
i_bajo <- sample(nrow(riesgo_bajo), floor(0.70 * nrow(riesgo_bajo)))
i_alto <- sample(nrow(riesgo_alto), floor(0.70 * nrow(riesgo_alto)))

# Crear los conjuntos de entrenamiento y prueba
entrenamiento <- rbind(riesgo_bajo[i_bajo, ], riesgo_alto[i_alto, ])
prueba <- rbind(riesgo_bajo[-i_bajo, ], riesgo_alto[-i_alto, ])
```


Evaluación en prueba: clientes

	Predicho Alto	Predicho Bajo
Real Alto	18	0
Real Bajo	0	18

Precisión

100 % en el conjunto de prueba.

Código base:

```
modelo_train <- lda(Riesgo ~ ., data =  
  entrenamiento)  
pred_prueba <- predict(modelo_train, newdata =  
  prueba)  
table(Real = prueba$Riesgo, Predicho = pred_  
  prueba$class)
```

Lectura

La prueba quedó balanceada: 18 clientes de riesgo Alto y 18 de riesgo Bajo. En esta partición no se presentaron errores de clasificación.

Discusión

Aunque la precisión de prueba fue perfecta, esto no prueba que el modelo sea perfecto en cualquier muestra futura. Debe leerse como evidencia favorable para esta partición.

Clasificar un nuevo cliente

```
nuevo_cliente <- data.frame(  
  Ingreso_mensual_millones = 4.2,  
  Puntaje_crediticio = 620,  
  Nivel_endeudamiento_pct = 55,  
  Dias_mora_ult_12m = 22,  
  Antigüedad_laboral_meses = 24,  
  Numero_productos_financieros = 2  
)  
  
pred_nuevo <- predict(modelo_clientes, newdata = nuevo_cliente)  
pred_nuevo$class  
pred_nuevo$posterior  
pred_nuevo$x
```

Interpretación

El grupo predicho debe leerse junto con la probabilidad posterior. No todas las decisiones tienen el mismo nivel de confianza.

Sección 5

Interpretación, reporte y cierre

Comparación de los dos ejemplos

Aspecto	Wine	Riesgo crediticio
Unidad	Muestra de vino	Cliente
Grupo	Cultivo 1, 2 o 3	Bajo / Alto
Predictoras	Compuestos químicos	Indicadores financieros
Funciones	LD1 y LD2	Solo LD1
Visualización	Plano LD1-LD2	Eje LD1
Discusión	Separación casi perfecta	Un error completo; prueba perfecta

Aprendizaje central

El número de funciones discriminantes depende del número de grupos, no solo del número de variables predictoras.

Cuándo usar análisis discriminante


Usarlo cuando...

- ▶ Existen grupos conocidos de antemano.
- ▶ Las variables predictoras son cuantitativas.
- ▶ Se quiere clasificar nuevas observaciones.
- ▶ Interesa interpretar dimensiones de separación.

No usarlo cuando...

- ▶ No existe variable de grupo.
- ▶ Se busca descubrir grupos desde cero.
- ▶ La respuesta es continua, no categórica.
- ▶ Hay muchos predictores y pocas observaciones sin control adicional.

Síntesis del procedimiento



Mensaje final

El valor del análisis discriminante está en unir clasificación, visualización e interpretación estadística.

Cinco ideas clave

1. El análisis discriminante requiere grupos conocidos.
2. Las funciones discriminantes son combinaciones lineales orientadas a separar grupos.
3. Con tres grupos pueden obtenerse hasta dos funciones discriminantes.
4. Con dos grupos solo se obtiene una función discriminante.
5. La matriz de confusión es indispensable para evaluar clasificación.

Cómo reportar resultados de LDA

Estructura recomendada

Un buen reporte debe conectar el problema de clasificación, los grupos, las variables predictoras, la regla discriminante y la evaluación del desempeño.

1. Describir la unidad de observación y los grupos.
2. Justificar por qué se usa análisis discriminante.
3. Indicar cuántas funciones discriminantes se obtienen.
4. Presentar visualización y matriz de confusión.
5. Concluir con una interpretación aplicada.

Qué debe decir una buena interpretación

1. Qué función discriminante separa más los grupos.
2. Qué variables tienen mayor peso en cada función.
3. Qué grupos quedan claramente separados.
4. Qué grupos presentan mayor cercanía o confusión.
5. Cómo se conecta la separación visual con la matriz de confusión.

Regla didáctica

Interpretar no es repetir el output de R: es traducirlo a una conclusión estadística y contextual.

Cómo construir una conclusión

La conclusión debe responder

- ▶ ¿Qué grupos se analizaron?
- ▶ ¿Cuántas funciones discriminantes se obtuvieron?
- ▶ ¿Qué tan clara fue la separación visual?
- ▶ ¿Cuál fue el desempeño en prueba?
- ▶ ¿Dónde aparecieron errores o casos ambiguos?
- ▶ ¿Qué implicación tiene el resultado en el contexto?

Qué no debe concluirse

Evitar conclusiones excesivas

- ▶ Una precisión alta no demuestra que todos los supuestos se cumplan perfectamente.
- ▶ Una buena clasificación en entrenamiento no garantiza desempeño futuro.
- ▶ Un coeficiente grande no siempre implica mayor importancia si las escalas son distintas.
- ▶ Una probabilidad posterior alta depende del modelo ajustado y de los priors utilizados.

Interpretar no es solo clasificar

Clasificación

Responde si el modelo asigna correctamente las observaciones a los grupos.

Interpretación

Explica por qué los grupos se separan y qué variables contribuyen a esa separación.

Mensaje clave

Un modelo con alta precisión pero sin interpretación puede ser insuficiente para una decisión académica o gerencial.

Checklist antes de entregar resultados

- ▶ La variable de grupo está correctamente definida como categórica.
- ▶ Los identificadores fueron excluidos de las variables predictoras.
- ▶ Se reportan funciones discriminantes y no solo clasificación final.
- ▶ Se incluye matriz de confusión y precisión.
- ▶ Se diferencia entre evaluación en entrenamiento y en prueba.
- ▶ La conclusión conecta los números con el contexto del problema.

Limitaciones del análisis discriminante

Puntos de cuidado

- ▶ LDA puede ser sensible a diferencias fuertes en covarianzas entre grupos.
- ▶ Las variables muy colineales pueden dificultar la interpretación.
- ▶ La precisión puede ser optimista si se evalúa solo con datos de entrenamiento.
- ▶ Si las matrices de covarianza difieren mucho, podrían considerarse extensiones como el análisis discriminante cuadrático, fuera del alcance de esta guía.

Bibliografía y material base

- ▶ Aguado Franco, J. C. (2006). *Teoría de la decisión y de los juegos*. Delta Publicaciones.
- ▶ Material de clase: Sección 2.2, Análisis discriminante.
- ▶ MASS: función `lda()` para análisis discriminante lineal.
- ▶ `rattle`: base de datos wine.

Análisis discriminante

Separar · Clasificar · Evaluar · Interpretar

