

Sección 2.1

Análisis de componentes principales

Métodos estadísticos II para la ciencia de datos



2.1 Análisis de componentes principales

2.1.1. Concepto de componentes principales

2.1.1. Cálculo de las componentes principales

Tema 2.1.1

Concepto de componentes principales

El origen de los componentes principales

Uno de los problemas que enfrenta el investigador es la elección de las variables a medir.

En un proceso de investigación, durante las etapas iniciales frecuentemente hay una escasa teoría sobre el campo a abordar; consecuentemente, el investigador recoge información sobre un número amplio de variables, que a su juicio son relevantes en el problema.

En casos donde resultan muchas variables se presentan algunos problemas con la estimación de parámetros, así por ejemplo:

Con diez variables puede hacerse necesario estimar 45 correlaciones, con 20 se pueden estimar 190 coeficientes de correlación, y así, el número de correlaciones a estimar crece conforme aumenta el número de variables.

El concepto de los componentes principales

Además, del problema de estimación, está el de la comprensión, de tal forma que se hace necesario abocar alguna técnica que resuma la información contenida en las variables y facilite su análisis.

El ACP tiene como objetivo la estructuración de un conjunto de datos multivariado mediante la reducción del número de variables. Esta es una metodología de tipo matemático para la cual no es necesario asumir distribución probabilística alguna.

El objetivo de los componentes principales

- Generar nuevas variables que expresen la información contenida en un conjunto de datos.
- Reducir la dimensión del espacio donde están inscritos los datos.
- Eliminar las variables (si es posible) que aporten poco al estudio del problema.
- Facilitar la interpretación de la información contenida en los datos.

El concepto de los componentes principales

Más específicamente, se puede decir que el análisis de componentes principales transforma el conjunto de variables originales en un conjunto más pequeño de variables, las cuales son combinaciones lineales de las primeras, que contienen la mayor parte de la variabilidad presente en el conjunto inicial.

El ACP tiene como objetivo la estructuración de un conjunto de datos multivariado mediante la reducción del número de variables. Esta es una metodología de tipo matemático para la cual no es necesario asumir distribución probabilística alguna.

Tema 2.1.2

Cálculo de los componente principales

Consideraciones generales y notación

Supóngase que los valores de p -variables $X_1, \dots, X_p$ se obtienen sobre una muestra de n individuos, la matriz X , de tamaño $(n \times p)$ representa tales datos.

Sean $\bar{X}_j$ la media muestral de la variable X_j , s_{jk} la covarianza muestral entre las variables X_j y X_k y la matriz $S = (s_{jk})$, corresponde a la matriz de varianzas y covarianzas muestral de las p -variables.

Descripción del procedimiento

Inicialmente, se trata de encontrar la primera componente principal, que tenga máxima varianza muestral, a través de la combinación lineal:

$$Y_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p = \sum_{j=1}^p a_{1j}X_j$$

La varianza muestral de esta combinación lineal es igual a $\mathbf{a}'_1 \mathbf{S} \mathbf{a}_1$, donde el vector

$$\mathbf{a}'_1 = (a_{11}, \dots, a_{1p}),$$

es tal que $\|\mathbf{a}_1\| = 1$. Así mismo, las componentes de $\mathbf{a}_1$ deben satisfacer:

$$[\mathbf{S} - l_1 \mathbf{I}] \mathbf{a}_1 = 0.$$

Descripción del procedimiento

Inicialmente, se trata de encontrar la primera componente principal, a través de la combinación lineal:

$$Y_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p = \sum_{j=1}^p a_{1j}X_j$$

La varianza muestral de esta combinación lineal es igual a $\mathbf{a}'_1 \mathbf{S} \mathbf{a}_1$, donde el vector $\mathbf{a}'_1 = (a_{11}, \dots, a_{1p})$, es tal que $\|\mathbf{a}_1\| = 1$.

Así mismo, las componentes de $\mathbf{a}_1$ deben satisfacer: $[\mathbf{S} - l_1 \mathbf{I}] \mathbf{a}_1 = 0$, con l_1 el multiplicador de Lagrange. Entonces, l_1 es tal que:

$$|\mathbf{S} - l_1 \mathbf{I}| = 0.$$

la cantidad l_1 es el valor propio más grande de $\mathbf{S}$ y $\mathbf{a}_1$ su correspondiente vector propio.

Descripción del procedimiento

El proceso para la extracción de las demás componentes principales es similar. Las m componentes principales ($m \leq p$) que contienen, de manera decreciente, fracciones de la varianza total, se generan a partir de los respectivos α_k , con:

$$l_1 \geq l_2 \geq \cdots \geq l_m \geq \cdots \geq l_p$$

Siendo los valores propios de S .

El orden, en términos de la magnitud, de los valores propios (y variabilidad) con que se generan las componentes principales hace que algunos usuarios de esta metodología la califiquen como una técnica de ordenamiento.

Descripción del procedimiento

La contribución de la i -ésima variable a la k -ésima componente principal está dada por la magnitud del coeficiente a_{ik} .

La covarianza entre la variable X_i y la componente principal Y_k es:

$$\text{cov}(X_i, Y_k) = a_{ik} l_k.$$

La varianza muestral de las observaciones con respecto a la k -ésima componente principal es:

$$\text{var}(Y_k) = \mathbf{a}_k' \mathbf{S} \mathbf{a}_k = l_k,$$

con l_k el k -ésimo valor propio ordenado descendientemente.

Descripción del procedimiento

La varianza total de las p -variables es:

$$V_T = \text{tra}(S) = \sum_{j=1}^p l_j.$$

Al dividir esta expresión por la desviación estándar de X_i y Y_k respectivamente, se obtiene la correlación:

$$r_{X_i Y_k} = \frac{a_{ki} l_k}{(\sqrt{s_{ii}})(\sqrt{l_k})} = \frac{a_{ki} \sqrt{l_k}}{\sqrt{s_{ii}}}$$

La valor de $r_{X_i Y_k}$ es el grado de importancia de la i -ésima variable en la k -ésima componente principal. Además, nótese que esta correlación depende en forma directa de las a_{ki} , pues s_{ii} y l_k son fijos.

Esta se convierte en una forma de leer e interpretar las componentes principales, ya que una observación de los valores a_{ki} auxilia la búsqueda del significado de las diferentes componentes principales.

Resumen del procedimiento

1. Calcula la matriz S .
2. Obtener los valores propios de la matriz S ; estos corresponden a la varianza de cada componente principal.
3. Hallar la razón entre cada uno de los valores propios y la suma total de ellos (la traza de S), e ir acumulando estas razones.
4. Los valores más altos obtenidos en (3) suministran un indicio del número de componentes relevantes.
5. Calcular las ponderaciones dadas en el cálculo de $r_{X_i Y_k}$, las cuales indican el grado de asociación entre la variable y la componente principal respectiva.
6. Calcular los “nuevos” puntajes usando la transformación $Y = AX$, donde A es la matriz ortogonal que define la rotación “rígida”.
7. Interpretar los “nuevos” ejes. Esta es la parte crucial de todo lo anterior ya que sino todo el trabajo se convierte en un ejercicio puramente numérico.

Bibliografía

- Aguado Franco, J. C. (2006). Teoría de la decisión y de los juegos. Las Rozas (Madrid), Delta Publicaciones.
- Mindtools. (2022). Decision trees. Recuperado de <https://www.mindtools.com/dectree.html>