

Análisis de componentes principales

*Métodos estadísticos II
para la ciencia de datos*

Guía aplicada con R

Caso conductor: tiendas de comercio electrónico

Reducción de dimensionalidad · autovalores · cargas · interpretación

Propósito de la guía

Objetivo general

Comprender el ACP/PCA como una técnica para transformar varias variables numéricas relacionadas en menos componentes interpretables, conservando la mayor parte de la variabilidad de los datos.

- ▶ No se parte de una respuesta específica, sino de una estructura multivariada.
- ▶ La decisión central será **cuántos componentes conservar** y **cómo interpretarlos**.
- ▶ En el caso conductor se espera una reducción importante, alrededor de **2 o 3 componentes**, si la evidencia lo justifica.

80

tiendas/canales

9

variables numéricas


3

dimensiones conceptuales iniciales

2–3

componentes esperados

Ruta de aprendizaje



Idea didáctica

Cada bloque introduce un concepto y lo aplica inmediatamente al caso de las tiendas. La teoría no queda separada del análisis.

Sección 1


El problema: muchas variables, poca síntesis

¿Por qué aparece el PCA?

Problema analítico

En bases multivariadas, medir muchas variables puede ser necesario, pero interpretar muchas relaciones simultáneas se vuelve difícil.

- ▶ Con 10 variables hay 45 correlaciones bivariadas.
- ▶ Con 20 variables hay 190 correlaciones.
- ▶ Aumenta la complejidad del análisis, no necesariamente la comprensión.



Muchas relaciones

El PCA no elimina el juicio del analista; organiza la información para que pueda interpretarse mejor.

Caso conductor: tiendas de comercio electrónico

Contexto

Una empresa de comercio electrónico registra información anual de 80 tiendas o canales de venta. La gerencia quiere resumir su desempeño en pocos indicadores generales.

- ▶ Las tiendas no se evaluarán por una sola variable.
- ▶ Hay información comercial, de clientes y de operación.
- ▶ La pregunta no es predecir ventas: es **resumir la estructura multivariada**.

80

observaciones

9

variables analíticas

1

unidad de observación

Unidad de observación

Definición

La unidad de observación es una **tienda o canal de venta de comercio electrónico durante un año**.

- ▶ Cada fila resume el comportamiento anual de una tienda.
- ▶ No se analizan transacciones individuales.
- ▶ No se analizan clientes individuales.
- ▶ El identificador Tienda sirve para reconocer la observación, no para entrar al PCA.

Regla práctica

Antes de calcular PCA, siempre responder:

¿Qué representa cada fila?

Tres dimensiones conceptuales iniciales

Desempeño comercial

- ▶ Ventas anuales
- ▶ Número de pedidos
- ▶ Clientes activos
- ▶ Inversión publicitaria

Experiencia del cliente

- ▶ Satisfacción
- ▶ Recompra
- ▶ Quejas

Operación logística

- ▶ Tiempo de entrega
- ▶ Entregas tardías

Pregunta clave: ¿los datos sostienen tres componentes independientes o bastan menos componentes?

Muestra de la base de datos

Tienda	Ventas	Pedidos	Clientes	Publicidad	Satisf.	Recompra	Quejas	Entrega	Tardías
Tienda_01	646.7	5633	2400	89.9	82.0	43.4	3.7	3.8	8.9
Tienda_02	755.1	6404	2737	95.3	71.7	35.7	6.3	4.6	10.3
Tienda_03	833.7	6301	2968	92.8	71.4	37.6	5.9	4.0	10.9
Tienda_04	618.6	5770	2446	96.2	90.0	54.3	1.7	3.8	6.4
Tienda_05	761.6	6266	2648	98.3	79.1	39.2	6.3	4.6	10.5
Tienda_06	593.7	5679	2334	70.6	78.9	41.1	4.5	4.3	8.2

Lectura

Los valores están en escalas distintas: ventas, conteos, porcentajes, días e indicadores. Por eso, la estandarización será obligatoria antes de calcular el PCA.

Pregunta analítica del ejemplo 1

¿Podemos resumir 9 variables de tiendas de comercio electrónico en pocos componentes interpretables?

Hipótesis conceptual

Podrían existir tres dimensiones: comercial, experiencia y logística.

Pregunta empírica

El PCA decidirá si esas tres dimensiones aparecen como componentes principales o si alguna queda absorbida por otra.

PCA no es regresión lineal

Regresión lineal

- ▶ Tiene una variable respuesta.
- ▶ Busca explicar o predecir.
- ▶ Estima efectos marginales.
- ▶ Ejemplo: explicar ventas.

Regresión: quiero explicar una variable.

PCA

- ▶ No tiene variable respuesta.
- ▶ Busca resumir variables.
- ▶ Construye componentes sintéticos.
- ▶ Ejemplo: resumir desempeño integral.

PCA: quiero resumir muchas variables.

Sección 2

Intuición: de variables originales a componentes

Idea central del PCA

Definición aplicada


El PCA transforma un conjunto de variables originales en nuevas variables llamadas **componentes principales**. Cada componente es una combinación lineal de las variables originales y captura una parte de la variabilidad total.

Variables originales $\longrightarrow$ Componentes principales

En el caso de tiendas

El objetivo es pasar de 9 variables a pocos componentes, posiblemente 2 o 3, que resuman la mayor parte de la información de las tiendas.

Intuición geométrica



- ▶ El primer componente busca el eje de mayor variabilidad.
- ▶ El segundo componente es perpendicular al primero y resume variabilidad restante.
- ▶ En más dimensiones, la lógica es la misma.

Clave

PCA cambia el sistema de coordenadas para mirar los datos desde ejes más informativos.

Componentes como combinaciones lineales

Forma general

$$PC_k = a_{1k}Z_1 + a_{2k}Z_2 + \cdots + a_{pk}Z_p$$

- ▶ Z_j representa una variable estandarizada.
- ▶ a_{jk} es el peso o carga de la variable j en el componente k .
- ▶ Cada componente combina todas las variables, pero algunas pesan más.

Ejemplo conceptual

$$PC_{comercial} \approx .50Z_{ventas} + .49Z_{pedidos} + .50Z_{clientes} + \cdots$$

Interpretación

Si ventas, pedidos y clientes pesan alto en el mismo componente, ese eje puede interpretarse como desempeño comercial.

¿Qué conserva y qué descarta PCA?

Conserva

- ▶ Patrones dominantes de variabilidad.
- ▶ Relaciones fuertes entre variables.
- ▶ Ejes que resumen grupos de variables.


Descarta o reduce

- ▶ Variabilidad pequeña.
- ▶ Ruido o diferencias menores.
- ▶ Componentes con baja contribución interpretativa.

En el ejemplo

Aunque hay tres dimensiones conceptuales, el PCA puede mostrar que menos componentes explican suficientemente la estructura de los datos.

Dimensiones conceptuales versus componentes empíricos



Comercial
Experiencia
Logística

Experiencia + logística
Comercial

Mensaje importante

El PCA no está obligado a confirmar todas las dimensiones que se pensaron al inicio. Algunas pueden mezclarse o no aportar suficiente varianza independiente.

Tres preguntas que guiarán el análisis

1

¿Cuánta varianza explica cada componente?

2

¿Cuántos componentes se conservan?

3

¿Qué significa cada componente?

Orden lógico

Primero se calcula. Luego se decide. Finalmente se interpreta. Saltarse la interpretación convierte el PCA en un ejercicio meramente numérico.

Sección 3

Datos, escalas y estandarización

La matriz de datos

Notación

$$\mathbf{X}_{n \times p} = \begin{bmatrix} x_{11} & x_{12} & \cdots & x_{1p} \\ x_{21} & x_{22} & \cdots & x_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ x_{n1} & x_{n2} & \cdots & x_{np} \end{bmatrix}$$

- ▶ $n = 80$ tiendas.
- ▶ $p = 9$ variables numéricas.
- ▶ El identificador de tienda no entra al PCA.
- ▶ Cada columna aporta una dimensión original.

No incluir identificadores en PCA

Advertencia

Si una columna de identificación es numérica, R puede tratarla como variable analítica. Eso distorsiona el PCA.

Excluir

- ▶ Código de tienda
- ▶ ID de vendedor
- ▶ Año si funciona solo como etiqueta
- ▶ Nombre de unidad

Incluir

- ▶ Ventas
- ▶ Clientes
- ▶ Porcentajes
- ▶ Indicadores de satisfacción
- ▶ Tiempos de entrega

Variables del ejemplo y escalas

Variable	Media	Desv. estándar	Mínimo	Máximo
Ventas anuales	720.00	140.00	379.40	1068.80
Pedidos	5999.96	999.99	3376.00	8725.00
Clientes activos	2599.99	450.06	1659.00	3699.00
Publicidad	90.00	18.00	54.60	132.00
Satisfacción	76.99	7.50	60.50	97.80
Recompra	42.00	7.00	28.00	61.00
Quejas	5.00	1.40	1.60	8.30
Tiempo entrega	4.21	0.60	2.70	5.50
Entregas tardías	9.01	2.00	3.90	14.80

Conclusión

Como las variables tienen escalas distintas, el PCA debe aplicarse sobre variables estandarizadas.

Estandarización: poner variables en escala comparable

Transformación

$$Z_j = \frac{X_j - \bar{X}_j}{s_j}$$

- ▶ $\bar{X}_j$ es la media.
- ▶ s_j es la desviación estándar.
- ▶ Cada variable queda con media 0 y desviación estándar 1.

En R

```
pca <- prcomp(tiendas_pca,  
               center = TRUE,  
               scale. = TRUE)
```

Por qué importa

Sin estandarizar, variables con valores grandes pueden dominar el análisis solo por su unidad de medida.

Matriz de covarianzas versus matriz de correlaciones

Covarianzas

- ▶ Usa escalas originales.
- ▶ Conviene si las unidades son comparables.
- ▶ Puede ser dominada por variables con mayor varianza.

Correlaciones

- ▶ Equivale a PCA con variables estandarizadas.
- ▶ Conviene cuando las escalas son diferentes.
- ▶ Es la opción recomendada en este ejemplo.

Para este curso: usaremos `center = TRUE` y `scale. = TRUE`.

Relaciones iniciales entre variables

Relación	Correlación
Ventas anuales – Pedidos	0.87
Ventas anuales – Clientes activos	0.92
Ventas anuales – Publicidad	0.90
Satisfacción – Recompra	0.87
Satisfacción – Quejas	-0.88
Satisfacción – Tiempo entrega	-0.79
Quejas – Tiempo entrega	0.77
Tiempo entrega – Entregas tardías	0.75

Lectura previa

- ▶ Las variables comerciales se mueven juntas.
- ▶ Satisfacción y recompra se asocian positivamente.
- ▶ Quejas, entregas tardías y tiempos se asocian negativamente con satisfacción.

Preparar los datos en R

```
library(readr)
base <- read_csv("PCA_TIENDAS.csv")

str(base)
head(base)

tiendas_pca <- base[, -1]
```

Control de calidad

Antes del PCA, verificar que `tiendas_pca` contenga solo variables numericas analíticas.

Sección 4

Cálculo del PCA

Descripción matemática básica

Primera componente

$$Y_1 = a_{11}X_1 + a_{12}X_2 + \cdots + a_{1p}X_p$$

$$\text{var}(Y_1) = \mathbf{a}_1' \mathbf{S} \mathbf{a}_1$$

- ▶ PCA busca la combinación lineal con máxima varianza.
- ▶ Los pesos se obtienen a partir de vectores propios.
- ▶ Los autovalores indican varianza explicada por cada componente.

Autovalores y vectores propios

Relación central

$$(\mathbf{S} - \lambda_k \mathbf{I})\mathbf{a}_k = 0$$

Autovalor λ_k

Representa la varianza explicada por el componente k .

Vector propio $\mathbf{a}_k$

Contiene los coeficientes para construir el componente k .

En R: los autovalores se calculan como `pca$sdev^2`.

Aplicar PCA en R

```
pca_ecommerce <- prcomp(  
  tiendas_pca,  
  center = TRUE,  
  scale. = TRUE  
)  
  
summary(pca_ecommerce)
```

Qué hace este comando

- ▶ Centra cada variable en su media.
- ▶ Escala cada variable por su desviación estándar.
- ▶ Calcula componentes principales con base en las variables estandarizadas.

Objetos principales de prcomp()

pca\$sdev

Desviaciones estándar de los componentes. Al cuadrado dan los autovalores.

pca\$rotation

Coeficientes o cargas para construir cada componente.

pca\$x

Puntuaciones de cada tienda en los componentes principales.

Cálculo, decisión e interpretación salen de estos tres objetos.

Tabla de autovalores y varianza explicada en R

```
autovalores <- pca_ecommerce$sdev^2

varianza <- data.frame(
  Componente = paste0("PC", 1:length(autovalores)),
  Autovalor = autovalores,
  Varianza_Explicada = autovalores / sum(autovalores) * 100,
  Varianza_Acumulada = cumsum(autovalores / sum(autovalores) * 100)
)

round(varianza, 2)
```



Resultado del ejemplo 1: varianza explicada

Componente	Autovalor	Varianza explicada (%)	Varianza acumulada (%)	Decisión
PC1	4.37	47.95	47.95	Conservar
PC2	3.68	40.39	88.34	Conservar
PC3	0.29	3.20	91.53	Descartar
PC4	0.21	2.27	93.80	Descartar
PC5	0.16	1.72	95.52	Descartar
PC6	0.13	1.46	96.98	Descartar
PC7	0.13	1.40	98.38	Descartar
PC8	0.10	1.04	99.42	Descartar
PC9	0.05	0.58	100.00	Descartar


Lectura

Los dos primeros componentes explican **88.34 %** de la varianza total. El tercer componente aporta solo **3.20 %** adicional.

Gráfico de sedimentación: varianza por componente



Varianza acumulada



Sección 5

Criterios para conservar componentes

Criterio de Kaiser

Regla

Cuando el PCA se hace sobre variables estandarizadas, se conservan los componentes con **autovalor mayor que 1**.

Razón

Cada variable estandarizada tiene varianza 1. Un componente con autovalor menor que 1 explica menos que una variable original.

En el ejemplo

$PC1 = 4.37$ y $PC2 = 3.68$. $PC3 = 0.29$. Según Kaiser, se conservan dos componentes.


Criterio de varianza acumulada

Regla didáctica para este curso

Conservar los componentes necesarios para explicar al menos **85 % de la varianza total**, siempre que tengan interpretación coherente.

Componentes conservados	Varianza acumulada	Decisión
Solo PC1	47.95 %	Insuficiente
PC1 + PC2	88.34 %	Adecuado
PC1 + PC2 + PC3	91.53 %	Mayor, pero PC3 aporta poco

Scree plot y umbral de Kaiser



- ▶ Solo PC1 y PC2 superan el umbral de Kaiser.
- ▶ La caída fuerte ocurre después de PC2.
- ▶ El resto de componentes explica poca varianza individual.

Decisión integrada

Kaiser

PC1 y PC2 tienen autovalor >

1

88.34 %

PC1 + PC2 superan 85 %


Scree

codo después de PC2

Decisión

Para el caso de tiendas, se conservan **dos componentes principales**. Ahora falta interpretar qué significa cada componente.

De dimensiones conceptuales a componentes retenidos



Conclusión preliminar

La logística no desaparece del análisis; queda incorporada en el eje de experiencia del cliente.

Sección 6

Cargas, contribuciones e interpretación

Cargas de los tres primeros componentes

Variable	PC1	PC2	PC3
Ventas anuales	0.054	0.506	0.005
Pedidos	0.037	0.495	0.012
Clientes activos	0.015	0.502	-0.202
Publicidad	0.073	0.487	0.266
Satisfacción	0.457	-0.050	0.196
Recompra	0.447	-0.041	-0.089
Quejas	-0.453	0.034	-0.217
Tiempo entrega	-0.426	0.005	0.799
Entregas tardías	-0.442	0.067	-0.396

Cómo leer

Las variables con mayor valor absoluto en una columna son las que más ayudan a interpretar ese componente.


Contribución porcentual de las variables

Variable	PC1 (%)	PC2 (%)	PC3 (%)
Ventas anuales	0.29	25.56	0.00
Pedidos	0.13	24.51	0.01
Clientes activos	0.02	25.24	4.09
Publicidad	0.54	23.71	7.08
Satisfacción	20.86	0.25	3.86
Recompra	20.02	0.17	0.78
Quejas	20.50	0.12	4.69
Tiempo entrega	18.13	0.00	63.83
Entregas tardías	19.51	0.45	15.65

Clave


En `prcomp()`, si se usan los coeficientes de `rotation`, las contribuciones pueden calcularse como $a_{jk}^2 \times 100$.
Por columna suman 100 %.

Contribuciones a PC1




PC1 está dominado por satisfacción, recompra, quejas, tiempo de entrega y entregas tardías.

Contribuciones a PC2



PC2 está dominado por ventas, pedidos, clientes e inversión publicitaria.

Mapa de variables en PC1 y PC2



Interpretación de PC1

Variables con alta contribución

- ▶ Satisfacción: 20.86 %
- ▶ Recompra: 20.02 %
- ▶ Quejas: 20.50 %
- ▶ Tiempo de entrega: 18.13 %
- ▶ Entregas tardías: 19.51 %

Nombre del componente

Experiencia del cliente
integrada con operación
logística

- ▶ Alta satisfacción y recompra van en un sentido.
- ▶ Quejas, retrasos y tiempos altos van en el sentido contrario.

Interpretación de PC2

Variables con alta contribución

- ▶ Ventas anuales: 25.56 %
- ▶ Pedidos: 24.51 %
- ▶ Clientes activos: 25.24 %
- ▶ Publicidad: 23.71 %

Nombre del componente

Desempeño comercial

- ▶ Las cuatro variables comerciales cargan fuertemente en el mismo eje.
- ▶ PC2 resume volumen de actividad comercial.

¿Dónde quedó la operación logística?

Respuesta analítica

La operación logística no queda como un componente independiente. Sus variables tienen alta contribución en PC1, junto con satisfacción, recompra y quejas.

- ▶ Tiempo de entrega y entregas tardías se relacionan con la experiencia del cliente.
- ▶ Los retrasos tienden a acompañarse de más quejas y menor satisfacción.
- ▶ Por eso, el PCA no separa claramente logística de experiencia.

Conclusión contextual

En este caso, la logística opera como parte de la experiencia percibida por el cliente, no como una dimensión aislada.

Cuidado con el signo de las cargas

Propiedad del PCA

El signo de un componente puede invertirse sin cambiar su significado estadístico. Si todas las cargas de un componente cambian de signo, el eje sigue representando la misma dimensión.

Versión A

Satisfacción positiva, quejas negativas.

Versión B

Satisfacción negativa, quejas positivas.

Lo importante es **qué variables pesan más**, no el signo aislado.

Puntuaciones o scores de las tiendas

Qué son

Los scores son los valores de cada tienda en los componentes principales.

- ▶ Permiten ubicar tiendas en el nuevo espacio reducido.
- ▶ Sirven para comparar perfiles de tiendas.
- ▶ Pueden usarse para visualización o segmentación.

En R

```
scores <- pca_ecommerce$x  
head(scores[, 1:2])
```

Tiendas extremas por componente

PC1 alto

Tienda	PC1
Tienda_52	5.67
Tienda_25	4.33
Tienda_40	4.25

PC1 bajo

Tienda	PC1
Tienda_62	-4.62
Tienda_36	-3.86
Tienda_67	-3.81


PC2 alto

Tienda	PC2
Tienda_14	5.08
Tienda_64	3.75
Tienda_50	3.56

PC2 bajo

Tienda	PC2
Tienda_80	-4.00
Tienda_30	-3.68
Tienda_68	-3.59

Mapa de tiendas en los dos componentes



Lectura gerencial de los cuadrantes

PC1 alto + PC2 alto

Tiendas con buena experiencia del cliente y alto desempeño comercial.

PC1 bajo + PC2 alto

Tiendas comercialmente fuertes, pero con problemas de experiencia o logística.

PC1 alto + PC2 bajo

Tiendas con buena experiencia, pero menor volumen comercial.

PC1 bajo + PC2 bajo

Tiendas con bajo desempeño comercial y problemas de experiencia.

Sección 7

Flujo completo en R

Análisis de Componentes Principales

Código completo: importar y preparar

```
library(readr)
base <- read_csv("PCA_TIENDAS.csv")

# Verificar dimensiones
nrow(base)    # 80 observaciones
ncol(base)    # 10 columnas incluyendo ID

# Matriz para PCA: solo variables numericas analiticas
tiendas_pca <- base[, -1]
```

Código completo: PCA y autovalores

```
pca_ecommerce <- prcomp(
  tiendas_pca,
  center = TRUE,
  scale. = TRUE
)

autovalores <- pca_ecommerce$sdev^2

varianza <- data.frame(
  Componente = paste0("PC", seq_along(autovalores)),
  Autovalor = autovalores,
  Varianza = autovalores / sum(autovalores) * 100,
  Acumulada = cumsum(autovalores / sum(autovalores) * 100)
)

round(varianza, 2)
```

Código completo: cargas y contribuciones

```
# Cargas o coeficientes de los componentes
cargas <- pca_ecommerce$rotation
round(cargas[, 1:2], 3)

# Contribuciones porcentuales por componente
contribuciones <- cargas^2 * 100
round(contribuciones[, 1:2], 2)

# Verificar que sumen 100 por componente
colSums(contribuciones[, 1:2])
```

Precisión

Las contribuciones suman 100 por columna/componentes, no por fila/variable.

Código completo: scores

```
# Puntuaciones de cada tienda en los componentes
scores <- as.data.frame(pca_ecommerce$x)

# Combinar con identificador
scores_tiendas <- cbind(
  Tienda = base$Tienda,
  scores
)

head(scores_tiendas[, c("Tienda", "PC1", "PC2")])
```

Uso

Los scores permiten comparar o graficar tiendas en el espacio reducido de componentes.

Gráficos básicos en R

```
# Scree plot basico
plot(pca_ecommerce, type = "l")

# Biplot basico
biplot(pca_ecommerce, scale = 0)

# Grafico PC1 vs PC2 con scores
plot(scores_tiendas$PC1, scores_tiendas$PC2,
      xlab = "PC1: experiencia/logistica",
      ylab = "PC2: desempeno comercial")
abline(h = 0, v = 0, lty = 2)
```

Ecuación de un componente

Con variables estandarizadas

$$PC1 = a_1 Z_{ventas} + a_2 Z_{pedidos} + \cdots + a_9 Z_{tardias}$$

En este ejemplo

PC1 se interpreta principalmente con variables de satisfacción, recompra, quejas, tiempo de entrega y entregas tardías.

Nota

Aunque matemáticamente se puede escribir con variables originales sustituyendo $Z = (X - \bar{X})/s$, para interpretar el PCA se prefieren las cargas sobre variables estandarizadas.

Resultado final del ejemplo 1

PC1

Experiencia del cliente
integrada con operación
logística

Variables dominantes: satisfacción, recompra, quejas, tiempo de entrega y entregas tardías.

PC2

Desempeño comercial

Variables dominantes: ventas, pedidos, clientes activos e inversión publicitaria.

Conclusión

El PCA resume las 9 variables iniciales en 2 componentes que explican el 88.34 % de la variabilidad total.

Sección 8

Informe, tarea y cierre

Estructura sugerida del informe

1. Contexto del problema y unidad de observación.
2. Variables incluidas y justificación de su uso.
3. Justificación de la estandarización.
4. Tabla de autovalores y varianza explicada.
5. Criterios usados para conservar componentes.
6. Tabla de cargas y contribuciones.
7. Interpretación y nombre de cada componente.
8. Conclusión aplicada para la organización.

Tarea: segundo ejemplo

Contexto

La tarea trabajará una base de producción textil con cuatro dimensiones conceptuales iniciales.

- ▶ Capacidad productiva
- ▶ Desempeño comercial
- ▶ Calidad operativa
- ▶ Gestión del talento operativo

Pregunta

¿Los datos justifican conservar cuatro componentes o solo tres? Sustente con autovalores, varianza acumulada, scree plot, cargas e interpretación.

Checklist de entrega

Debe incluir

- ▶ Código usado en R.
- ▶ Tabla de varianza explicada.
- ▶ Decisión justificada.
- ▶ Tabla de cargas.
- ▶ Interpretación de componentes.

Debe evitar

- ▶ Incluir ID como variable.
- ▶ Omitir estandarización.
- ▶ Decidir solo por una regla.
- ▶ No interpretar los ejes.
- ▶ Confundir PCA con regresión.

Errores frecuentes

Error	Consecuencia
Incluir identificadores	El PCA interpreta códigos como variables reales.
No estandarizar	Variables con escala mayor dominan el análisis.
Decidir solo por Kaiser	Puede ignorar el sentido contextual del componente.
Mirar solo signos	El signo puede invertirse sin cambiar la interpretación.
No nombrar componentes	El análisis queda incompleto y puramente numérico.

Cierre conceptual

**El PCA no responde qué variable causa otra.
Responde cómo se organiza la variabilidad de
muchas variables en pocos ejes interpretables.**

Idea final

Un buen PCA combina cálculo, criterio estadístico e interpretación sustantiva del contexto.

Análisis de componentes principales

De muchas variables a pocos ejes interpretables

Fin de la guía