MODELO PREDICTIVO CON DATOS SINTÉTICOS PARA LA ESTIMACIÓN DE TIEMPOS Y LA ASIGNACIÓN DE RECURSOS EN LABORATORIOS DE CONTROL DE CALIDAD FARMACÉUTICOS

ALDAIR RAFAEL CÉTARES BARRIOS
CARLOS DAVID CAMPO URZOLA



UNIVERSIDAD SIMÓN BOLÍVAR
MAESTRÍA EN CIENCIA DE DATOS
BARRANQUILLA
2026

MODELO PREDICTIVO CON DATOS SINTÉTICOS PARA LA ESTIMACIÓN DE TIEMPOS Y LA ASIGNACIÓN DE RECURSOS EN LABORATORIOS DE CONTROL DE CALIDAD FARMACÉUTICOS

Autores:
ALDAIR RAFAEL CÉTARES BARRIOS
CARLOS DAVID CAMPO URZOLA

Trabajo de Grado presentado para optar al título de Magister en Ciencia de Datos

Tutor:
Dr. ANTONIO JOSÉ BRAVO VALERO

UNIVERSIDAD SIMÓN BOLÍVAR
MAESTRÍA EN CIENCIA DE DATOS
BARRANQUILLA
2026

Nota de aceptación

_____

Tutor del Trabajo de Grado

_____

Jurado 1

_____

Jurado 2

Ciudad, Fecha

CONTENIDO

PROBLEMA **5**

1. Planteamiento del Problema **5**
1.1 Preámbulo: contextualización teórica 5
1.2 Preámbulo: contextualización práctica 6
1.3 Preámbulo: contextualización espacial 6
1.4 Diseño del planteamiento: enfoque en el caso de estudio 7
1.5 Fundamentación del problema: evidencias frente a juicios de valor 7
1.6 Pronóstico del fenómeno 8
1.7 Planteamiento de la propuesta investigativa 9
1.8 Pregunta de investigación 9

2. Objetivos **10**
2.1 Objetivo general 10
2.2 Objetivos especificos 10

3. Justificación **10**

4. Alcance y limitaciones **11**

MARCO REFERENCIAL **13**

5. Antecedentes **13**
5.1 Programación y asignación de recursos en laboratorios analíticos 13
5.2 La simulación como fuente de datos de entrenamiento 15
5.3 Evaluación de la calidad de los datos sintéticos 15
5.4 Analítica avanzada y aprendizaje automático en la manufactura farmacéutica 16
5.5 Síntesis y vacío identificado 17

6. Macrotópicos **18**
6.1 Gestión y programación de laboratorios de control de calidad farmacéuticos 18
6.1.1 Actividades analíticas 18
6.1.2 Asignación de recursos 18
6.1.3. Disponibilidad cruzada de recursos 18
6.1.4. Laboratorio de control de calidad farmacéutico 19
6.1.5. Makespan 19
6.1.6. Personal calificado y equipos 19
6.1.7. Programación de laboratorios 20
6.1.8. Tiempos de ejecución 20
6.1.9. Utilización de recursos 21

7. Marco legal **21**

8. SISTEMA DE VARIABLES **22**

8.1 Objetivo de diagnóstico 22
8.2 Variable de diagnóstico 23
8.3 Definición conceptual de variable 23
8.4 Definición operacional de la variable 23
8.5 Dimensiones e indicadores 23

REFERENCIAS BIBLIOGRÁFICAS 26

PROBLEMA

1. Planteamiento del Problema

1.1 Preámbulo: contextualización teórica

El control de calidad farmacéutico puede entenderse, siguiendo a Juran y Godfrey (1999), como un proceso recursivo articulado en planificación, control y mejora continua. En el laboratorio ese proceso se materializa en ensayos fisicoquímicos y microbiológicos que compiten por recursos finitos: analistas con calificaciones específicas, equipos instrumentales y ventanas de tiempo acotadas por los plazos de liberación. Costigliola et al. (2017) muestran que la gestión de estos laboratorios se apoya predominantemente en la experiencia acumulada de los supervisores más que en modelos validados por datos, y Danzinger et al. (2025) demostraron que el problema de programación subyacente —el Test Laboratory Scheduling Problem— es NP-difícil: la intuición del planificador opera sobre un espacio de soluciones que crece de forma factorial.

Frente a esa dureza combinatoria se han consolidado dos familias de respuesta. La primera es la optimización explícita: programación con restricciones (Danzinger et al., 2025), optimización multiobjetivo con explicabilidad mediante valores de Shapley (Mischek y Musliu, 2024) y heurísticas de gran escala (Martins et al., 2023). La segunda es el modelado basado en datos, que Dong et al. (2023) sistematizan para procesos farmacéuticos. La línea de estudio de laboratorios analíticos está consolidada (Klaessens et al., 1988; Boyd y Savory, 2001; Schäfer, 2004; Maslaton, 2012; Dudnikov et al., 2012; Costigliola et al., 2017; Lopes et al., 2020), pero opera sobre modelos de reglas o sobre datos operativos propios de cada instalación.

El pilar metodológico de este trabajo —generar datos por simulación para entrenar modelos predictivos— cuenta con literatura propia. Hassi et al. (2025) documentan la simulación de Monte Carlo con estimaciones de tres puntos y factores de correlación, y muestran que la elección de la distribución altera significativamente las estimaciones de duración. Chan et al. (2022) formalizaron el uso de simulación de eventos discretos para producir conjuntos de entrenamiento, P. V. Lopes et al. (2024) lo aplicaron al análisis de sistemas de producción en ausencia de datos reales, y Elbasheer et al. (2025) reportan un error porcentual absoluto medio de 15,47 % al estimar duraciones con datos simulados de un taller de trabajo flexible, valor que sirve de referencia para los criterios de éxito. La calidad del dato sintético se valora en fidelidad, utilidad y privacidad (Figueira y Vaz, 2022; Vallevik et al., 2024; Hernandez et al., 2025), con TSTR como protocolo estándar de utilidad (Esteban et al., 2017); el marco conceptual general lo aportan Jordon et al. (2022) y Goncalves et al. (2020), y las rutas generativas alternativas, Patki et al. (2016) y Xu et al. (2019). Kodumuru et al. (2025) y Abdulhussain et al. (2026) sitúan estas

herramientas en el marco Quality by Digital Design, y Khadivi et al. (2025) sistematizan el aprendizaje por refuerzo profundo en programación de máquinas, cuya incorporación se declara como línea de trabajo futuro.

1.2 Preámbulo: contextualización práctica

Un laboratorio de control de calidad recibe muestras de materias primas, productos intermedios, producto a granel y producto terminado, y debe ejecutar sobre ellas los ensayos definidos por especificación antes de que un lote pueda liberarse. La Resolución 1160 de 2016 del Ministerio de Salud y Protección Social exige que se lleven a cabo todos los controles necesarios y asigna al jefe de control de calidad la responsabilidad de aprobar o rechazar según especificaciones; el Decreto 335 de 2022 regula la certificación de Buenas Prácticas de Manufactura y de Laboratorio ante el INVIMA.

Dos rasgos definen esa operación. Los recursos son cruzadamente restringidos: un mismo cromatógrafo sirve a varios ensayos, un mismo analista está calificado solo para algunos métodos, y la disponibilidad de ambos debe coincidir en el tiempo. Y el proceso está sujeto a perturbaciones no planificadas —reanálisis por resultados fuera de especificación, ingreso de muestras urgentes, indisponibilidad de equipos— que invalidan la programación establecida al inicio del día.

1.3 Preámbulo: contextualización espacial

Según la Encuesta Anual Manufacturera del DANE (2025), la división CIIU 21 registró en 2024 una producción bruta de $11,15 billones de pesos, equivalente al 2,5 % de la producción bruta manufacturera nacional y al 5,0 % de su valor agregado, con el coeficiente técnico más bajo de la industria colombiana. El INVIMA opera como Autoridad Reguladora Nacional de Referencia Regional de Nivel IV (OPS, 2020), condición que impone exigencias sostenidas de capacidad analítica y documental, mientras el propio instituto adoptó un plan de contingencia para atender más de 14.000 trámites represados (INVIMA, 2025) y el CONPES 4170 declaró de importancia estratégica el fortalecimiento de la producción farmacéutica nacional (Consejo Nacional de Política Económica y Social, 2025).

La adopción de analítica avanzada, en cambio, es incipiente. CINTEL (2023) reporta, sobre 431 empresas entre las mayores del país, que solo el 12 % implementa inteligencia artificial y que el 63 % de los procesos permanece manual; Muñoz-Pinzón et al. (2024), sobre 121 pymes, encuentran que el 40,5 % de las manufactureras nunca la utiliza para análisis. Ambas muestras son no censales, por lo que sus valores deben leerse como indicativos y no como parámetros poblacionales.

1.4 Diseño del planteamiento: enfoque en el caso de estudio

La investigación no se desarrolla sobre un laboratorio empírico identificable. El caso de estudio es un laboratorio de control de calidad farmacéutico de referencia, construido computacionalmente a partir de parámetros operativos reportados en literatura arbitrada. La decisión responde a dos restricciones documentables y no a una preferencia metodológica: los registros operativos de una planta farmacéutica constituyen secreto empresarial bajo los artículos 260 a 265 de la Decisión 486 de 2000 de la Comunidad Andina, y su divulgación o uso no autorizado está tipificado como acto de competencia desleal por la Ley 256 de 1996; además, la búsqueda en repositorios públicos (Kaggle, Zenodo, UCI Machine Learning Repository y Mendeley Data) no arrojó ningún conjunto de datos de operación de estos laboratorios. Los datos crudos que sustentan a Costigliola et al. (2017) y Lopes et al. (2020) nunca fueron publicados; el propio grupo debió generar instancias sintéticas calibradas con distribuciones de literatura para su estudio de 2023 (Martins et al., 2023).

El término «datos sintéticos» se emplea aquí en el sentido de datos generados por simulación estocástica a partir de parámetros calibrados con literatura, y no de datos derivados de un conjunto real mediante modelos generativos; la validez del conjunto depende, por tanto, enteramente de la trazabilidad de sus supuestos. La unidad de análisis es la actividad analítica individual —un ensayo específico sobre una muestra específica—, caracterizada por su método, complejidad, equipo requerido, calificación exigida al analista y plazo de entrega. Sobre ella operan tres capas: generación mediante simulación de Monte Carlo con estimaciones de tres puntos (BetaPERT) y factores de correlación, calibrada con Coito et al. (2021) y Costigliola et al. (2017) y contrastada estructuralmente con las instancias públicas del TLSP y de Martins et al. (2023); predicción supervisada de la duración de cada actividad; y asignación mediante una regla de despacho informada por las duraciones estimadas, evaluada frente a FIFO, asignación aleatoria y regla experta en el mismo entorno de simulación.

1.5 Fundamentación del problema: evidencias frente a juicios de valor

El planteamiento distingue lo documentado por una fuente verificable, lo que se infiere de forma razonada a partir de ello, y lo que constituye un juicio de valor sin respaldo empírico. Está documentado que la programación de laboratorios de ensayo con recursos heterogéneos es un problema NP-difícil (Danzinger et al., 2025); que la gestión de estos laboratorios se apoya predominantemente en criterio experto (Costigliola et al., 2017, en contexto europeo); que el sector farmacéutico colombiano es de alta densidad de valor agregado (DANE, 2025) y opera bajo un regulador de referencia regional con carga administrativa documentada (OPS, 2020; INVIMA, 2025); que la adopción de analítica avanzada en la empresa colombiana es incipiente (CINTEL, 2023; Muñoz-Pinzón et al.,

2024); y que no existe estadística pública colombiana sobre tiempos de liberación de lotes ni sobre capacidad analítica instalada por laboratorio, evidencia negativa obtenida mediante búsqueda sistemática en INVIMA, MinSalud, DANE y literatura indexada.

De ahí se desprenden tres inferencias, enunciadas como tales y sujetas a refutación: que existe margen de mejora en la asignación de recursos de estos laboratorios —plausible, no demostrado, porque ninguna de las evidencias mide desempeño operativo colombiano—; que la ausencia de indicadores públicos limita tanto la gestión interna basada en evidencia como la investigación académica sobre el tema; y que, a partir de cierto número de muestras, analistas y equipos, la calidad de una programación construida manualmente se degrada respecto del óptimo alcanzable, consecuencia matemática de la dureza del problema y no observación sobre laboratorios concretos.

Se excluyen deliberadamente cuatro afirmaciones frecuentes por carecer de respaldo verificable: que los laboratorios de control de calidad colombianos son ineficientes, pues no existe medición pública de su desempeño y afirmarlo sería atribuir un déficit no observado; que el represamiento de trámites del INVIMA se explica por la operación de los laboratorios, lo que confunde el trámite regulatorio ante la autoridad sanitaria con la operación analítica interna de la planta; que la inteligencia artificial resolverá el desabastecimiento de medicamentos, cuyas causas documentadas son múltiples y mayoritariamente ajenas a la planificación analítica (MinSalud, 2023); y que la gestión basada en la experiencia del supervisor es deficiente, cuando el conocimiento experto acumulado es un activo operativo y lo que la evidencia sugiere es la ausencia de un complemento cuantitativo.

El vacío es, entonces, preciso. No se identificaron trabajos que integren la estimación supervisada de duraciones y la recomendación de asignación de recursos entrenadas exclusivamente con datos sintéticos calibrados con literatura y evaluadas frente a políticas de referencia, en el contexto de laboratorios de control de calidad farmacéuticos. El problema no es de desempeño observado sino de capacidad instalada de decisión, y está bloqueado en las fases iniciales: no es posible desarrollar ni evaluar modelos predictivos de apoyo a la planificación analítica farmacéutica mientras no se disponga de un sustituto metodológicamente defendible de los datos operativos reales. La situación a investigar corresponde, así, con un problema de investigación.

1.6 Pronóstico del fenómeno

El escenario que sigue es prospectivo y se construye por extrapolación de tendencias documentadas: expansión de la capacidad productiva nacional (Consejo Nacional de Política Económica y Social, 2025), persistencia de la carga administrativa regulatoria

(INVIMA, 2025) y adopción analítica que avanza lentamente (CINTEL, 2023). No constituye una predicción.

Si la capacidad analítica instalada crece por adición de recursos —más analistas, más equipos— sin incorporar planificación basada en datos, es razonable esperar que la brecha entre demanda de ensayos y capacidad efectiva de procesamiento se amplíe en lugar de cerrarse: en un problema NP-difícil, añadir recursos incrementa el espacio de soluciones más rápido de lo que incrementa la capacidad de un planificador humano para explorarlo. El resultado previsible no es la ausencia de capacidad sino su subutilización —recursos ociosos junto a otros congestionados—, con efecto sobre los tiempos de liberación. A ello se suma que, sin indicadores de desempeño analítico, no se dispone de la información necesaria para localizar la restricción: la ausencia de medición no solo impide corregir, impide saber que hay algo que corregir.

El escenario es modificable. Un modelo capaz de estimar con antelación la duración de las actividades analíticas y de recomendar asignaciones de personal y equipo permitiría anticipar congestiones antes de que se materialicen y contrastar alternativas de programación antes de comprometer recursos. Esta investigación no interviene sobre ningún laboratorio real: aporta la evidencia de viabilidad técnica que una intervención de ese tipo requeriría como paso previo.

1.7 Planteamiento de la propuesta investigativa

La propuesta desarrolla capacidades analíticas predictivas para el estudio de la planificación de laboratorios de control de calidad farmacéuticos en condiciones de acceso restringido a datos reales, y entrega tres productos: un conjunto de datos sintéticos documentado con trazabilidad de cada supuesto a su fuente, un análisis comparativo de algoritmos de estimación de duraciones con métricas y protocolo de validación declarados, y un prototipo de recomendación de asignación evaluado frente a políticas de referencia. Produce evidencia de viabilidad técnica y no de eficacia operativa en una instalación concreta; la validación con registros reales bajo protocolo TSTR (Esteban et al., 2017) y la incorporación de políticas aprendidas por refuerzo profundo (Khadivi et al., 2025) se declaran como líneas de trabajo futuro.

1.8 Pregunta de investigación

La ejecución de actividades analíticas exige estimar duraciones y asignar recursos bajo restricciones cruzadas de calificación del personal, disponibilidad de equipos y plazos de entrega, sobre un problema de programación cuya dureza computacional está demostrada. Cuando esa doble tarea se resuelve solo con criterio experto y sin apoyo predictivo, la

capacidad operativa real del laboratorio permanece invisible y los cuellos de botella se identifican tarde. En consecuencia, se plantea la siguiente pregunta de investigación:

- ¿Qué modelo de aprendizaje automático, en su fase de prototipado, permite la predicción de la duración de actividades analíticas y la recomendación de la asignación de recursos en los laboratorios farmacéuticos basado en datos sintéticos?

2. Objetivos

2.1 Objetivo general

Desarrollar un prototipo basado en aprendizaje automático y datos sintéticos que permita predecir la duración de las actividades analíticas y recomendar la asignación de recursos humanos y materiales en laboratorios farmacéuticos.

2.2 Objetivos especificos

2.2.1 Estructurar un conjunto de datos sintéticos que represente los tiempos de ejecución, la disponibilidad de recursos humanos y materiales y su disponibilidad cruzada en un laboratorio farmacéutico de referencia, mediante simulación estocástica calibrada con parámetros operativos reportados en la literatura científica.

2.2.2 Comparar el desempeño de diferentes algoritmos de aprendizaje automático supervisado en la estimación de la duración de las actividades analíticas, con el fin de seleccionar el modelo con mejor capacidad predictiva.

.

2.2.3 Construir un prototipo funcional que integre el modelo predictivo seleccionado y genere recomendaciones para la asignación de personal calificado y equipos, evaluando su desempeño frente a estrategias de asignación de referencia mediante indicadores de eficiencia operativa.

3. Justificación

La investigación se justifica, en primer lugar, por la posición que ocupa el proceso estudiado. El laboratorio de control de calidad es la última compuerta antes de la liberación de un lote, de modo que cualquier demora o desbalance en la planificación de sus actividades se traslada de forma directa al tiempo de liberación. Sobre él pesan exigencias

regulatorias sostenidas, en un sector cuya capacidad administrativa está documentadamente tensionada, y el problema de asignación subyacente es computacionalmente duro: el apoyo cuantitativo a la decisión no constituye un refinamiento administrativo sino la única vía de explorar de forma sistemática un espacio de soluciones que crece factorialmente.

Se justifica, en segundo lugar, por lo que aporta. En el plano metodológico entrega una vía auditable para investigar un dominio cuyo acceso a los datos está bloqueado por secreto empresarial y por inexistencia de estadística pública: no reclama un dato que no puede obtener, sino que construye un sustituto cuya legitimidad no descansa en la intuición de quien lo genera sino en la trazabilidad de cada supuesto a su fuente en literatura arbitrada, reutilizable por otras investigaciones que enfrenten la misma restricción. En el plano aplicado entrega un estimador de duraciones y un prototipo de recomendación de asignación evaluado frente a políticas de referencia bajo condiciones idénticas de simulación: para el responsable de un laboratorio, un instrumento para anticipar congestiones y contrastar alternativas antes de comprometer recursos; para la línea de investigación, la línea base contra la cual deberá medirse cualquier política de asignación más sofisticada.

4. Alcance y limitaciones

Este trabajo busca generar evidencia de viabilidad técnica del uso de modelos de aprendizaje automático y técnicas de asignación de recursos en un laboratorio farmacéutico simulado, y no demostrar su eficacia operativa en un laboratorio real. Los resultados obtenidos deberán interpretarse dentro de las condiciones y supuestos establecidos para el entorno sintético.

I. Representatividad de los datos sintéticos. Los datos utilizados en el estudio son generados mediante simulación a partir de parámetros y supuestos obtenidos de literatura científica, por lo que no representan registros operativos de un laboratorio farmacéutico específico. En consecuencia, la capacidad de los datos sintéticos para reproducir completamente la variabilidad de un entorno real estará condicionada por la calidad, pertinencia y trazabilidad de los parámetros utilizados para su generación.

II. Riesgo de circularidad. Los modelos predictivos se entrenan y evalúan con datos provenientes de un entorno construido por los investigadores, mientras que el modelo de asignación aprende dentro del mismo entorno simulado. Por tanto, un desempeño favorable demuestra inicialmente la capacidad de los algoritmos para aprender las relaciones representadas en el simulador, pero no garantiza un comportamiento equivalente en condiciones reales. Para reducir este riesgo, los parámetros serán sustentados en literatura científica, se incorporarán perturbaciones estocásticas como reanálisis, indisponibilidad de equipos e ingreso de actividades no planificadas, y los modelos serán evaluados bajo diferentes condiciones de carga.

III. Comparabilidad de las estrategias de asignación. Las estrategias de referencia y el modelo propuesto serán evaluados bajo las mismas condiciones del entorno simulado, permitiendo una comparación controlada entre ellas. Sin embargo, las mejoras obtenidas en indicadores como makespan, utilización de recursos, tardanza o cumplimiento de plazos no podrán extrapolarse directamente a un laboratorio farmacéutico real.

IV. Validación externa. La contrastación del modelo con registros operativos reales se encuentra fuera del alcance de esta investigación. Por esta razón, la evaluación con datos provenientes de laboratorios farmacéuticos reales constituye una etapa posterior necesaria para determinar la aplicabilidad y generalización del prototipo en condiciones operativas reales.

MARCO REFERENCIAL

5. Antecedentes

El presente apartado organiza los estudios previos en cuatro líneas de trabajo que confluyen en el problema planteado: la programación y asignación de recursos en laboratorios analíticos, el empleo de la simulación como fuente de datos de entrenamiento para modelos predictivos, la evaluación de la calidad de los datos sintéticos y la incorporación de analítica avanzada en la manufactura farmacéutica. De cada trabajo se señalan el problema abordado, el enfoque metodológico adoptado y la limitación que deja abierta, de modo que el cierre del apartado pueda cruzar las cuatro líneas y delimitar con precisión el vacío que esta investigación se propone atender. La revisión se apoya en literatura arbitrada indexada; las fuentes normativas y estadísticas del contexto colombiano se examinaron en el planteamiento del problema y no se reiteran aquí.

5.1 Programación y asignación de recursos en laboratorios analíticos

La organización del trabajo de un laboratorio analítico bajo recursos limitados cuenta con casi cuatro décadas de tratamiento sistemático. Klaessens et al. (1988) propusieron un sistema experto para el modelado basado en conocimiento de laboratorios analíticos como herramienta de gestión: el laboratorio se representaba mediante reglas codificadas a partir de la experiencia de los responsables, lo que permitía simular decisiones de gestión pero dejaba el desempeño del modelo atado a la calidad del conocimiento explicitado. Boyd y Savory (2001) desplazaron el enfoque hacia la optimización al resolver la programación del personal de laboratorio mediante un algoritmo genético, con lo que la asignación dejó de ser un problema de representación del conocimiento para convertirse en uno de búsqueda sobre un espacio de soluciones. Schäfer (2004) introdujo la dimensión dinámica al formular conceptos de programación capaces de reaccionar ante cambios durante la jornada, reconocimiento temprano de que una programación construida al inicio del día se invalida ante perturbaciones no planificadas. Dudnikov et al. (2012), por su parte, trasladaron el problema del entorno clínico al industrial mediante un sistema de planificación de análisis de laboratorio para empresas de manufactura.

La especificidad farmacéutica se formalizó en la misma década. Ruiz-Torres et al. (2012) modelaron la programación con múltiples tareas por trabajo para el caso de los laboratorios de control de calidad de la industria farmacéutica, reconociendo que una muestra no genera una actividad sino un conjunto de ensayos con requisitos propios, que es la unidad de análisis adoptada en esta investigación. Maslaton (2012) documentó desde la práctica profesional la manera en que se programan los recursos en estos laboratorios, y Ruiz-Torres et al. (2017) incorporaron de forma explícita la calificación del analista como restricción dura al construir un sistema de planificación que maximiza la preferencia del trabajador sujeto a restricciones de certificación y de balance. Costigliola et al. (2017)

construyeron un modelo de simulación de un laboratorio de control de calidad farmacéutico y documentaron que su gestión se apoya predominantemente en la experiencia acumulada de los supervisores antes que en modelos validados por datos. Cunha et al. (2019) formalizaron la condición que caracteriza a estos laboratorios como problema de programación: la doble restricción de recursos, en la que una actividad solo puede ejecutarse cuando coinciden en el tiempo un analista calificado y un equipo compatible. Lopes et al. (2020) llevaron esa línea a su expresión más integrada mediante un gemelo digital del laboratorio, concebido como modelo de gobernanza para la planificación y programación de recursos.

En paralelo se consolidó una línea centrada en la formulación del problema y en su complejidad. Mischek y Musliu (2021) propusieron un marco de búsqueda local para la programación de laboratorios de ensayo industriales y dispusieron públicamente un conjunto de instancias de referencia, recurso que este trabajo emplea para el contraste estructural del conjunto generado. Martins et al. (2023) abordaron instancias de gran tamaño con heurísticas orientadas a minimizar el tiempo total de finalización; para hacerlo debieron generar instancias sintéticas calibradas con distribuciones tomadas de la literatura, precedente directo de la estrategia metodológica adoptada aquí. Mischek y Musliu (2024) incorporaron la explicabilidad al apoyo a la decisión mediante valores de Shapley en un contexto multiobjetivo, señal de que la aceptación operativa de una recomendación de asignación depende de que pueda justificarse ante quien la ejecuta. Danzinger et al. (2025) modelaron y resolvieron la versión generalizada del problema mediante programación con restricciones y establecieron su dureza computacional, resultado que sustenta el argumento del planteamiento sobre los límites de una programación construida manualmente.

Tres rasgos comunes atraviesan esta línea. El primero es que la duración de las actividades se trata como dato de entrada del problema de programación y no como objeto de estimación: los modelos reciben las duraciones y optimizan sobre ellas, de modo que la incertidumbre asociada a ese insumo permanece fuera del alcance. El segundo es que los trabajos que abordan el caso farmacéutico operan sobre registros operativos propios de cada instalación, cuyos datos crudos no fueron publicados, lo que impide replicar los estudios o reutilizar sus datos. El tercero es que la evaluación se realiza frente a otras formulaciones o algoritmos de optimización y no frente a las políticas de asignación efectivamente empleadas en la operación. La línea resuelve, en suma, cómo asignar; no resuelve cómo estimar el insumo sobre el que se asigna, ni con qué datos hacerlo cuando la instalación no los cede.

5.2 La simulación como fuente de datos de entrenamiento

La segunda línea sostiene el pilar metodológico de esta investigación: generar por simulación los datos con los que se entrenan modelos predictivos. Hassi et al. (2025) documentaron el uso de simulación de Monte Carlo con estimaciones de tres puntos y factores de correlación para la optimización de la programación y el análisis de riesgo de un proyecto, y mostraron que la elección de la distribución altera significativamente las estimaciones de duración; de ahí se desprende la necesidad de declarar de manera explícita la familia de distribuciones empleada y de incorporar la correlación entre variables, en lugar de asumir independencia por conveniencia. Chan et al. (2022) formalizaron el procedimiento al generar conjuntos de datos sintéticos de manufactura para aprendizaje automático mediante simulación de eventos discretos, con lo que establecieron que un modelo de simulación puede sustituir al registro histórico como fuente de entrenamiento. P. V. Lopes et al. (2024) aplicaron esa estrategia al análisis de sistemas de producción en ausencia de datos, en el marco de los gemelos digitales, que es exactamente la condición de acceso restringido que enfrenta este trabajo. Elbasheer et al. (2025) combinaron simulación de eventos discretos y aprendizaje automático para la planificación de la producción en talleres de trabajo flexibles y reportaron un error porcentual absoluto medio de 15,47 % en la estimación de duraciones con datos simulados, valor que ofrece una referencia cuantitativa externa frente a la cual situar el desempeño esperado del estimador. Coito et al. (2021) aportan, por su parte, parámetros operativos que sirven a la calibración del generador.

El procedimiento está, por tanto, legitimado y documentado, pero su aplicación se ha concentrado en manufactura discreta, talleres de trabajo flexibles y proyectos de construcción. No se identificaron aplicaciones de esta estrategia a laboratorios de control de calidad farmacéuticos, cuyo régimen de restricciones —calificación del analista, compatibilidad instrumental y coincidencia temporal de ambos recursos— no se reduce al de una máquina en un taller.

5.3 Evaluación de la calidad de los datos sintéticos

La tercera línea define bajo qué criterios puede considerarse aceptable un conjunto de datos sintéticos. Patki et al. (2016), con el Synthetic Data Vault, y Xu et al. (2019), con redes generativas antagónicas condicionales para datos tabulares, establecieron las rutas generativas que aprenden la distribución de un conjunto real para producir uno artificial; constituyen la alternativa metodológica que este trabajo no adopta, por cuanto no dispone del conjunto real que dichas rutas requieren como punto de partida. Esteban et al. (2017) propusieron el protocolo de entrenar con datos sintéticos y evaluar con datos reales, que se consolidó como criterio estándar de utilidad. Goncalves et al. (2020) compararon métodos de generación y evaluación de datos sintéticos de pacientes, y Figueira y Vaz

(2022) sistematizaron en una revisión los procedimientos de generación y los métodos de evaluación disponibles. Jordon et al. (2022) aportaron el marco conceptual general, y Vallevik et al. (2024) y Hernandez et al. (2025) propusieron marcos integrales de evaluación articulados en tres dimensiones: fidelidad, utilidad y privacidad.

Este consenso evaluativo descansa, sin embargo, sobre un supuesto que conviene explicitar: fue construido para datos sintéticos derivados de un conjunto real. La fidelidad se mide comparando distribuciones con las del conjunto de origen; la utilidad se establece contrastando el desempeño de un modelo entrenado con datos sintéticos sobre datos reales; y la privacidad se evalúa frente al riesgo de reidentificar registros de ese mismo origen. Cuando el conjunto se genera por simulación estocástica calibrada con parámetros publicados y no existe un conjunto real de contraste, ninguno de los tres criterios es aplicable en su forma habitual: no hay distribución de referencia contra la cual medir la fidelidad, no hay conjunto real sobre el cual evaluar la utilidad y no hay registros individuales cuya privacidad pueda comprometerse. La consecuencia metodológica es doble. Por una parte, la legitimidad del conjunto debe descansar en otro lugar: la trazabilidad documental de cada supuesto a su fuente y la consistencia estructural de los registros generados, criterios que el sistema de variables de esta investigación recoge como indicadores. Por otra, la evaluación de utilidad bajo el protocolo de entrenamiento sintético y prueba real solo puede declararse como etapa posterior, una vez se disponga de registros operativos reales.

5.4 Analítica avanzada y aprendizaje automático en la manufactura farmacéutica

La cuarta línea sitúa el trabajo en su sector. La concepción de la calidad como proceso recursivo de planificación, control y mejora, formulada por Juran y Godfrey (1999), sigue organizando la función del laboratorio dentro del sistema de calidad. Sobre esa base, Dong et al. (2023) sistematizaron los métodos y técnicas de modelado basado en datos aplicados a procesos farmacéuticos; Kodumuru et al. (2025) revisaron la integración de inteligencia artificial e internet de las cosas en la manufactura farmacéutica; y Abdulhussain et al. (2026) situaron estas herramientas en el marco de la calidad por diseño digital. Khadivi et al. (2025) revisaron el estado del arte del aprendizaje por refuerzo profundo aplicado a la programación de máquinas y documentaron dos condiciones relevantes para el diseño de esta investigación: que las políticas aprendidas superan de manera consistente a las reglas de despacho heurísticas, y que su desempeño depende fuertemente del entorno de simulación empleado y exige un entrenamiento intensivo. De la primera se sigue que una regla de despacho constituye la línea base frente a la cual debe medirse cualquier política aprendida; de la segunda, que incorporar esa capa sin registros reales contra los cuales contrastarla produciría un resultado no auditable por un tercero. Ambas sustentan la

decisión de acotar el alcance a la estimación supervisada y a la regla de despacho informada, y de declarar la política aprendida como línea de trabajo futuro.

El rasgo común de esta línea es que la analítica avanzada se ha desplegado sobre el proceso productivo —formulación, escalado y control de proceso—, mientras el laboratorio de control de calidad aparece como una restricción de la programación de planta y no como objeto de modelado predictivo propio.

5.5 Síntesis y vacío identificado

El cruce de las cuatro líneas delimita el vacío con precisión. La primera resuelve la asignación de recursos en laboratorios analíticos, pero recibe la duración de las actividades como dato y depende de registros operativos que las instalaciones no publican. La segunda demuestra que un modelo de simulación puede sustituir al registro histórico como fuente de entrenamiento, pero se ha aplicado a manufactura discreta, a talleres flexibles y a proyectos de construcción, no a laboratorios de control de calidad farmacéuticos. La tercera ofrece criterios de calidad para el dato sintético, pero formulados para el caso en que ese dato deriva de un conjunto real disponible. La cuarta despliega aprendizaje automático sobre el proceso farmacéutico de manufactura y deja el laboratorio de control como restricción externa. Cada línea aporta una pieza; ninguna por sí sola, ni las cuatro en la configuración en que se encuentran, resuelve el problema planteado.

A ello se suma una evidencia negativa que refuerza la delimitación. La búsqueda en repositorios públicos de datos —Kaggle, Zenodo, UCI Machine Learning Repository y Mendeley Data— no arrojó conjuntos de datos de operación de laboratorios de control de calidad farmacéuticos, y los datos crudos que sustentan a Costigliola et al. (2017) y a Lopes et al. (2020) nunca fueron publicados. El propio grupo que produjo esos trabajos debió generar instancias sintéticas calibradas con distribuciones de literatura para su estudio posterior (Martins et al., 2023), lo que constituye a la vez el precedente más cercano y la diferencia más clara: esas instancias se generaron para evaluar algoritmos de optimización, no para entrenar modelos predictivos de duración.

En consecuencia, no se identificaron trabajos que integren la estimación supervisada de duraciones y la recomendación de asignación de recursos, entrenadas exclusivamente con datos sintéticos calibrados con literatura y evaluadas frente a políticas de referencia, en el contexto de laboratorios de control de calidad farmacéuticos. Lo que la revisión muestra no es una línea de investigación agotada, sino una bloqueada en su punto de entrada: existe el conocimiento para formular el problema de asignación, existe el procedimiento para generar datos por simulación y existen los criterios para juzgar su calidad, pero esas piezas no se han ensamblado en el dominio que aquí se estudia porque el insumo que lo haría posible —el registro operativo real— no está disponible. Producir y documentar ese

sustituto, y demostrar que sobre él pueden entrenarse y compararse modelos de estimación de duraciones y políticas de asignación, es la contribución que esta investigación se propone.

6. Macrotópicos

6.1 Gestión y programación de laboratorios de control de calidad farmacéuticos

6.1.1 Actividades analíticas

Las actividades analíticas constituyen la unidad básica de trabajo en un laboratorio de control de calidad farmacéutico y comprenden las operaciones necesarias para demostrar que una muestra cumple las especificaciones establecidas. Cada análisis puede integrar tareas como preparación de soluciones, acondicionamiento de equipos, ejecución instrumental, procesamiento de datos y revisión de resultados, con relaciones de precedencia y requerimientos técnicos particulares. Para efectos de programación, estas actividades deben caracterizarse por su duración, equipo requerido, competencia del analista, posibilidad de ejecución paralela y restricciones temporales. Esta desagregación permite representar con mayor precisión la carga real del laboratorio, identificar dependencias entre tareas y construir modelos de secuenciación y asignación orientados a reducir tiempos de espera y mejorar el flujo analítico. Esta distinción permite aprovechar mejor fases instrumentales autónomas y reducir tiempos improductivos. (Ruiz-Torres et al., 2012; Martins et al., 2023).

6.1.2 Asignación de recursos

La asignación de recursos consiste en determinar qué analista y qué equipo deben atender cada actividad analítica, considerando disponibilidad, competencia, compatibilidad técnica y prioridad. En un laboratorio farmacéutico, una tarea solo puede ejecutarse cuando coinciden un analista calificado y capacitado y un equipo apto para el procedimiento (Ministerio de Salud y Protección Social, 2016), por lo que la programación se comporta como un problema de doble restricción de recursos. Una asignación eficiente debe contemplar turnos, mantenimiento, tiempos de preparación, continuidad de corridas instrumentales, carga acumulada y fechas objetivo. El análisis conjunto de estas condiciones permite evitar sobreasignaciones, reducir esperas y distribuir mejor el trabajo. Además, facilita evaluar diferentes alternativas de programación antes de ejecutar las actividades y seleccionar aquellas que aprovechen mejor la capacidad disponible sin comprometer los requisitos técnicos del análisis. Esto ayuda a priorizar trabajos críticos y anticipar restricciones operativas (Cunha et al., 2019; Martins et al., 2023).

6.1.3. Disponibilidad cruzada de recursos

La disponibilidad cruzada de recursos representa la coincidencia temporal entre los elementos necesarios para ejecutar una actividad analítica, personal calificado y equipos compatibles. La existencia de un instrumento libre no garantiza que una prueba pueda

iniciar si el analista autorizado se encuentra ocupado; del mismo modo, un analista disponible no genera capacidad efectiva cuando el equipo requerido está en uso, mantenimiento o fuera de servicio. Esta interdependencia hace que la capacidad nominal difiera de la capacidad realmente utilizable. Incorporar matrices de competencias, calendarios de turnos, disponibilidad instrumental y recursos equivalentes permite identificar combinaciones factibles, anticipar conflictos y evitar asignaciones inviables. También favorece una programación flexible, capaz de redistribuir tareas entre alternativas técnicamente válidas cuando cambian las condiciones operativas del laboratorio. Así, la programación refleja con mayor precisión la capacidad real disponible. (Cunha et al., 2019; Ruiz-Torres et al., 2017).

6.1.4. Laboratorio de control de calidad farmacéutico

El laboratorio de control de calidad farmacéutico es una unidad esencial del sistema de calidad porque genera evidencia analítica para establecer si materias primas, productos en proceso, productos terminados y muestras de estabilidad cumplen las especificaciones definidas. Su operación combina exigencias regulatorias con una diversidad de métodos, instrumentos, muestras y competencias técnicas. Además, la demanda puede variar por liberaciones, estudios de estabilidad, investigaciones, transferencias, validaciones o eventos no planificados, generando fluctuaciones en la carga. Por esta razón, su gestión debe integrar confiabilidad analítica y eficiencia operativa, garantizando resultados trazables y oportunos mediante el uso racional de personas y equipos. Esta complejidad justifica aplicar herramientas de planificación, simulación y programación para anticipar capacidad, identificar restricciones y mejorar el flujo de trabajo. También facilita anticipar el efecto de la demanda sobre la capacidad disponible. (WHO, 2024; Costigliola et al., 2017).

6.1.5. Makespan

El makespan es un indicador de desempeño utilizado en programación para representar el tiempo transcurrido desde el inicio de un conjunto de trabajos hasta la finalización del último de ellos. En un laboratorio de control de calidad, reducirlo implica organizar actividades, analistas y equipos de manera que la carga programada termine en el menor horizonte posible, respetando precedencias, competencias y disponibilidad instrumental. Sin embargo, minimizar únicamente el makespan no refleja todas las prioridades operativas, debido a que ciertas muestras pueden tener fechas objetivo distintas o mayor impacto sobre la liberación de producto. Por ello, debe interpretarse junto con otros indicadores como tardanza, tiempo total de finalización, cumplimiento de fechas y utilización de recursos. Su análisis permite comparar escenarios de programación y cuantificar cuánto puede reducirse el horizonte total mediante una mejor secuenciación y asignación. Además, permite comparar alternativas de secuenciación bajo un criterio común. (Cunha et al., 2019; Martins et al., 2023).

6.1.6. Personal calificado y equipos

El personal calificado y los equipos constituyen recursos heterogéneos cuya disponibilidad condiciona la capacidad del laboratorio. La ejecución de una prueba no depende solo de contar con tiempo laboral o con un instrumento libre, sino de que el analista posea la competencia y autorización requeridas y de que el equipo sea técnicamente compatible, esté calificado y disponible para el procedimiento. Esto genera restricciones de elegibilidad, ya que no todas las personas ni todos los instrumentos son intercambiables. Modelar matrices de competencias y equipos equivalentes permite representar estas diferencias y ampliar las opciones de asignación sin perder control técnico. Además, deben considerarse mantenimiento, calibración, turnos, ausencias y actividades de soporte, pues estos factores reducen la capacidad efectiva. Una programación robusta integra ambos tipos de recurso y evita planificar sobre disponibilidades que no pueden materializarse. Esto ayuda a anticipar restricciones y orientar decisiones de entrenamiento. (WHO, 2024; Ruiz-Torres et al., 2017).

6.1.7. Programación de laboratorios

La programación de laboratorios consiste en secuenciar actividades analíticas y asignarlas a recursos disponibles para cumplir fechas, prioridades y restricciones del proceso. En el entorno farmacéutico, esta tarea es compleja por la existencia de múltiples pruebas por muestra, duraciones diferentes, intervenciones del analista durante corridas instrumentales, requisitos de competencia y variaciones frecuentes en la demanda. La programación manual puede depender en exceso del conocimiento del supervisor y dificultar la evaluación simultánea de numerosas combinaciones posibles. Los enfoques de investigación operacional permiten representar estas condiciones mediante modelos matemáticos, heurísticas, metaheurísticas o programación por restricciones. Además, la incorporación de datos históricos puede mejorar las estimaciones utilizadas para programar y facilitar reajustes cuando aparecen retrasos, indisponibilidades o nuevas prioridades, favoreciendo decisiones más consistentes y reproducibles. (Martins et al., 2023; Mischek & Musliu, 2021).

6.1.8. Tiempos de ejecución

Los tiempos de ejecución representan la duración requerida para completar actividades y tareas analíticas y son esenciales para estimar capacidad y construir programas realistas. Un ensayo puede combinar tiempo activo del analista, tiempo autónomo del equipo, preparación, estabilización, procesamiento y periodos de espera; por ello, utilizar una única duración promedio puede ocultar la estructura real del trabajo. Diferenciar estos componentes permite conocer cuándo se libera cada recurso y mejorar la asignación simultánea de personal e instrumentos. Además, la duración puede variar según método, producto, número de muestras, tamaño de corrida, experiencia del analista o incidencias operativas. El registro sistemático de datos históricos permite identificar esa variabilidad y generar estimaciones más precisas, además de constituir una base para modelos predictivos orientados a anticipar la duración de futuras actividades y apoyar la asignación de recursos. Esta separación facilita aprovechar tareas que pueden solaparse. (Costigliola et al., 2017; Martins et al., 2023).

6.1.9. Utilización de recursos

La utilización de recursos expresa la proporción de la capacidad disponible de analistas o equipos que se encuentra comprometida en actividades productivas durante un periodo. En un laboratorio de control de calidad, este indicador ayuda a identificar recursos ociosos, equipos altamente demandados y perfiles de personal que actúan como restricciones del sistema. Sin embargo, una utilización cercana al cien por ciento no implica necesariamente mayor eficiencia, ya que reduce el margen para absorber variabilidad, fallas, investigaciones o trabajos urgentes y puede aumentar las colas de espera. Por ello, debe analizarse junto con tiempos de procesamiento, cumplimiento de fechas, carga pendiente y flujo de muestras. La comparación de estos indicadores permite determinar si un problema de capacidad puede resolverse mediante una redistribución de recursos o cambios de programación antes de justificar incrementos de personal o adquisición de nuevos equipos. Así, la utilización refleja el equilibrio del sistema y no solo la ocupación. (Costigliola et al., 2017; Lopes et al., 2020).

7. Marco legal

La presente investigación se desarrolla en el contexto de los laboratorios de control de calidad farmacéuticos, por lo que se encuentra relacionada, en primer lugar, con la normativa sanitaria colombiana que regula su funcionamiento. La Resolución 3619 de 2013 del Ministerio de Salud y Protección Social expide el Manual de Buenas Prácticas de Laboratorio de Control de Calidad de Productos Farmacéuticos y establece requisitos asociados con la organización, gestión de calidad, registros, equipos procesadores de datos, personal, instrumentos y trazabilidad de la información. Esta disposición fue modificada parcialmente por la Resolución 662 de 2022 en lo relacionado con las actividades desarrolladas por estos laboratorios. De manera complementaria, la Resolución 1160 de 2016 establece el Manual de Buenas Prácticas de Manufactura de medicamentos e incorpora requisitos relacionados con personal calificado, documentación, equipos adecuados y procedimientos de control de calidad. Asimismo, el Decreto 335 de 2022 establece el procedimiento para la obtención de los certificados de cumplimiento de las Buenas Prácticas de Laboratorio ante el Instituto Nacional de Vigilancia de Medicamentos y Alimentos —INVIMA—, incluyendo dentro de su ámbito de aplicación a los laboratorios que realizan análisis de control de calidad de medicamentos (Ministerio de Salud y Protección Social, 2013, 2016, 2022).

La disponibilidad y utilización de información operativa también debe analizarse desde la protección de la información empresarial. La Decisión 486 de 2000 de la Comunidad Andina establece el régimen aplicable al secreto empresarial y señala que una información puede adquirir esta condición cuando no sea generalmente conocida o fácilmente accesible, posea valor comercial por su carácter reservado y haya sido objeto de medidas razonables para mantenerla secreta. Complementariamente, la Ley 256 de 1996 considera desleal la divulgación o explotación no autorizada de secretos empresariales a los que se haya tenido acceso legítimamente bajo deber de reserva o mediante mecanismos ilegítimos. En consecuencia, determinados registros relacionados con capacidades, tiempos, procesos o recursos de una organización podrían encontrarse sujetos a mecanismos de protección cuando cumplan las condiciones jurídicas establecidas, aspecto que sustenta la decisión de esta investigación de no utilizar información confidencial de

una empresa específica y trabajar con datos generados sintéticamente (Comunidad Andina, 2000; Congreso de Colombia, 1996).

En materia de información personal, la Ley Estatutaria 1581 de 2012 establece las disposiciones generales para la protección de datos personales y regula su tratamiento por entidades públicas y privadas. Aunque la presente investigación no emplea registros personales reales ni información identificable de trabajadores, esta norma constituye un referente para el manejo responsable de información dentro de sistemas analíticos. Su relación con la inteligencia artificial se complementa con la Circular Externa 002 de 2024 de la Superintendencia de Industria y Comercio, que establece lineamientos para el tratamiento de datos personales en sistemas de inteligencia artificial. El diseño del estudio mediante analistas, recursos y actividades generados computacionalmente permite desarrollar y evaluar el prototipo sin requerir datos personales de trabajadores reales, reduciendo los riesgos asociados con privacidad y tratamiento de información personal (Congreso de Colombia, 2012; Superintendencia de Industria y Comercio, 2024).

Finalmente, el desarrollo y utilización de técnicas de aprendizaje automático se enmarca en la Política Nacional de Inteligencia Artificial establecida mediante el Documento CONPES 4144 de 2025. Esta política contempla, entre sus ejes estratégicos, la gobernanza y ética de los sistemas de inteligencia artificial, la infraestructura y disponibilidad de datos, la investigación, desarrollo e innovación, la formación de capacidades, la gestión de riesgos y la adopción responsable de estas tecnologías en diferentes sectores. Su orientación resulta pertinente para la presente investigación, dado que el prototipo propuesto combina generación de datos, aprendizaje automático y apoyo cuantitativo a la toma de decisiones. El CONPES 4144 constituye un referente de política pública y no una ley que regule específicamente los algoritmos de aprendizaje automático. Al momento de elaboración de este trabajo, Colombia no cuenta con una ley general de inteligencia artificial plenamente aprobada y vigente, por lo que no se incorporan proyectos legislativos en trámite como parte del marco normativo aplicable (Departamento Nacional de Planeación, 2025).

8. SISTEMA DE VARIABLES

La operacionalización de variables permite precisar los elementos de la situación investigada que serán objeto de análisis y medición. En la presente investigación, el sistema de variables se establece a partir del objetivo específico de diagnóstico, relacionado con la estructuración del conjunto de datos sintéticos que representará las condiciones operativas de un laboratorio farmacéutico de referencia. De acuerdo con el diseño de la investigación, la variable de diagnóstico corresponde a los datos sintéticos, cuya representación considera los tiempos de ejecución, los recursos humanos y materiales, su disponibilidad cruzada y las condiciones necesarias para garantizar la consistencia del conjunto generado.

8.1 Objetivo de diagnóstico

Estructurar un conjunto de datos sintéticos que represente los tiempos de ejecución, la disponibilidad de recursos humanos y materiales y su disponibilidad cruzada en un laboratorio farmacéutico de referencia, mediante simulación estocástica calibrada con parámetros operativos reportados en la literatura científica.

8.2 Variable de diagnóstico

Datos sintéticos.

8.3 Definición conceptual de variable

Los datos sintéticos corresponden a observaciones generadas artificialmente mediante procedimientos computacionales con el propósito de representar características y relaciones de un sistema sin requerir necesariamente el uso directo de registros reales. Su utilidad puede evaluarse considerando aspectos como fidelidad, utilidad y privacidad (Jordon et al., 2022; Figueira & Vaz, 2022). En la presente investigación, los datos sintéticos serán generados mediante simulación estocástica a partir de parámetros operativos reportados en literatura científica.

8.4 Definición operacional de la variable

La variable datos sintéticos se operacionalizará mediante la generación computacional de actividades analíticas individuales. Cada registro del conjunto de datos representará un ensayo sobre una muestra y contendrá información relacionada con su duración, recursos requeridos, disponibilidad y calificación del personal, compatibilidad y disponibilidad de los equipos, así como las condiciones de coincidencia temporal necesarias para su ejecución. Los valores serán generados mediante simulación estocástica a partir de parámetros y distribuciones sustentados en literatura científica, y posteriormente se verificará su consistencia estructural y la trazabilidad de los supuestos empleados.

8.5 Dimensiones e indicadores

Variable	Dimensión	Indicadores
Datos sintéticos	Tiempos de ejecución	Tiempo optimista por actividad; tiempo más probable; tiempo pesimista; duración simulada de la actividad; media y dispersión de las duraciones generadas.
Datos sintéticos	Recursos humanos	Número de analistas disponibles; calificación o elegibilidad del analista por actividad; disponibilidad temporal del analista; carga asignada al analista.
Datos sintéticos	Recursos materiales	Número de equipos disponibles; compatibilidad equipo–actividad; disponibilidad temporal del

		equipo; condición de disponibilidad o indisponibilidad del equipo.
Datos sintéticos	Disponibilidad cruzada de recursos	Número de combinaciones factibles analista–equipo por actividad; porcentaje de actividades con al menos una combinación factible; coincidencia temporal entre analista calificado y equipo compatible; porcentaje de actividades restringidas por falta de alguno de los recursos requeridos.
Datos sintéticos	Variabilidad y consistencia estructural	Distribución de los tiempos simulados; correlaciones entre variables definidas; porcentaje de registros que cumplen las restricciones establecidas; porcentaje de valores fuera de los rangos definidos; porcentaje de parámetros con trazabilidad bibliográfica.

Las dimensiones establecidas permiten desagregar la variable datos sintéticos en los componentes necesarios para representar el comportamiento del laboratorio farmacéutico de referencia. Los tiempos de ejecución caracterizan la duración y variabilidad de las actividades analíticas; los recursos humanos y materiales representan las capacidades necesarias para su ejecución; la disponibilidad cruzada identifica la coincidencia entre personal calificado y equipos compatibles; y la consistencia estructural permite verificar que los registros generados respeten las reglas y parámetros definidos para la simulación. La duración de las actividades y la disponibilidad de recursos constituyen elementos fundamentales de los modelos de planificación de laboratorios (Costigliola et al., 2017; Martins et al., 2023), mientras que la generación mediante distribuciones probabilísticas y relaciones entre variables permite incorporar la variabilidad propia del sistema simulado (Hassi et al., 2025).

Los indicadores asociados a estas dimensiones permitirán comprobar que el conjunto generado no corresponde únicamente a valores aleatorios, sino a una representación estructurada del sistema definido para la investigación. La trazabilidad de los parámetros utilizados permitirá identificar el origen documental de los supuestos incorporados en la generación de los datos y establecer las condiciones bajo las cuales estos serán utilizados posteriormente para el entrenamiento y evaluación de los modelos predictivos. En este sentido, la calidad del conjunto sintético se complementa mediante criterios de

consistencia, utilidad y trazabilidad de los parámetros empleados (Figueira & Vaz, 2022; Vallevik et al., 2024).

REFERENCIAS BIBLIOGRÁFICAS

Abdulhussain, R., Muhamad, H., Fiza, T., Dereiah, S., Mawla, N., Patel, K., Adebisi, A., & Asare-Addo, K. (2026). The integration of artificial intelligence through quality by digital design for sustainable pharmaceutical manufacturing. *International Journal of Pharmaceutics, 693*, Article 126682. https://doi.org/10.1016/j.ijpharm.2026.126682

Boyd, J. C., & Savory, J. (2001). Genetic algorithm for scheduling of laboratory personnel. *Clinical Chemistry, 47*(1), 118–123. https://doi.org/10.1093/clinchem/47.1.118

Centro de Investigación y Desarrollo en Tecnologías de la Información y las Comunicaciones. (2023). *Índice de madurez de transformación digital de las empresas colombianas*. CINTEL.

Chan, K. C., Rabaev, M., & Pratama, H. (2022). Generation of synthetic manufacturing datasets for machine learning using discrete-event simulation. *Production & Manufacturing Research, 10*(1), 337–353. https://doi.org/10.1080/21693277.2022.2086642

Coito, T., Firme, B., Martins, M. S. E., Vieira, S. M., Figueiredo, J., & Sousa, J. M. C. (2021). Intelligent sensors for real-time decision-making. *Automation, 2*(2), 62–82. https://doi.org/10.3390/automation2020004

Comunidad Andina. (2000). *Decisión 486 de 2000: Régimen Común sobre Propiedad Industrial*. Gaceta Oficial del Acuerdo de Cartagena.

Congreso de la República de Colombia. (1996). *Ley 256 de 1996, por la cual se dictan normas sobre competencia desleal*. Diario Oficial.

Congreso de la República de Colombia. (2012). *Ley Estatutaria 1581 de 2012, por la cual se dictan disposiciones generales para la protección de datos personales*.

Consejo Nacional de Política Económica y Social. (2025). *Documento CONPES 4170: Declaración de importancia estratégica del proyecto de inversión Fortalecimiento de la producción nacional de productos farmacéuticos que garanticen la soberanía sanitaria nacional*. Departamento Nacional de Planeación.

Costigliola, A., Ataíde, F. A. P., Vieira, S. M., & Sousa, J. M. C. (2017). Simulation model of a quality control laboratory in pharmaceutical industry. *IFAC-PapersOnLine, 50*(1), 9014–9019. https://doi.org/10.1016/j.ifacol.2017.08.1582

Cunha, M. M., Viegas, J. L., Martins, M. S. E., Coito, T., Costigliola, A., Figueiredo, J., Sousa, J. M. C., & Vieira, S. M. (2019). Dual resource constrained scheduling for quality control laboratories. *IFAC-PapersOnLine, 52*(13), 1421–1426.

Danzinger, P., Geibinger, T., Mischek, F., & Musliu, N. (2025). Modeling and solving the generalized test laboratory scheduling problem. In G. Tack (Ed.), *Integration of constraint programming, artificial intelligence, and operations research* (Lecture Notes in Computer Science, Vol. 15762, pp. 188–204). Springer. https://doi.org/10.1007/978-3-031-95973-8_12

Departamento Administrativo Nacional de Estadística. (2025). *Encuesta Anual Manufacturera 2024*. DANE.

Departamento Nacional de Planeación. (2025). *Política Nacional de Inteligencia Artificial: Documento CONPES 4144*.

Dong, Y., Yang, T., Xing, Y., Du, J., & Meng, Q. (2023). Data-driven modeling methods and techniques for pharmaceutical processes. *Processes, 11*(7), Article 2096. https://doi.org/10.3390/pr11072096

Dudnikov, E. E., Sidorenko, A. M., & Khobotov, E. N. (2012). Laboratory analysis planning system for industrial enterprises. *Automation and Remote Control, 73*(11), 1910–1915. https://doi.org/10.1134/S0005117912110124

Elbasheer, M., Longo, F., Madden, M. G., Padovano, A., & Ullah, I. (2025). Towards a digital twin for production planning: Combining discrete event simulation and ML for flexible job shops. *Procedia Computer Science, 253*, 3078–3087. https://doi.org/10.1016/j.procs.2025.02.032

Esteban, C., Hyland, S. L., & Rätsch, G. (2017). *Real-valued (medical) time series generation with recurrent conditional GANs* (arXiv:1706.02633). arXiv. https://arxiv.org/abs/1706.02633

Figueira, A., & Vaz, B. (2022). Survey on synthetic data generation, evaluation methods and GANs. *Mathematics, 10*(15), Article 2733. https://doi.org/10.3390/math10152733

Goncalves, A., Ray, P., Soper, B., Stevens, J., Coyle, L., & Sales, A. P. (2020). Generation and evaluation of synthetic patient data. *BMC Medical Research Methodology, 20*, Article 108. https://doi.org/10.1186/s12874-020-00977-1

Hassi, H., El Mkhalet, M., & Lamdouar, N. (2025). Scheduling optimization and risk analysis using Monte Carlo simulation for a construction project in Morocco. *International Journal of Engineering Trends and Technology, 73*(6), 336–349. https://doi.org/10.14445/22315381/IJETT-V73I6P128

Hernandez, M., Osorio-Marulanda, P. A., Catalina, M., Loinaz, L., Epelde, G., & Aginako, N. (2025). Comprehensive evaluation framework for synthetic tabular data in health: Fidelity, utility and privacy analysis of generative models with and without privacy guarantees. *Frontiers in Digital Health, 7*, Article 1576290. https://doi.org/10.3389/fdgth.2025.1576290

Instituto Nacional de Vigilancia de Medicamentos y Alimentos. (2025). *Resolución 2025010547 de 2025, por la cual se adopta un plan de contingencia para el trámite de registros sanitarios de medicamentos*. INVIMA.

Jordon, J., Szpruch, L., Houssiau, F., Bottarelli, M., Cherubin, G., Maple, C., Cohen, S. N., & Weller, A. (2022). *Synthetic data—What, why and how?* (arXiv:2205.03257). arXiv. https://doi.org/10.48550/arXiv.2205.03257

Juran, J. M., & Godfrey, A. B. (Eds.). (1999). *Juran's quality handbook* (5th ed.). McGraw-Hill.

Khadivi, M., Charter, T., Yaghoubi, M., Jalayer, M., Ahang, M., Shojaeinasab, A., & Najjaran, H. (2025). Deep reinforcement learning for machine scheduling: Methodology, the state-of-the-art, and future directions. *Computers & Industrial Engineering, 200*, Article 110856. https://doi.org/10.1016/j.cie.2025.110856

Klaessens, J., Saris, T., Vandeginste, B. G. M., & Kateman, G. (1988). Expert system for knowledge-based modelling of analytical laboratories as a tool for laboratory management. *Journal of Chemometrics, 2*(1), 49–65. https://doi.org/10.1002/cem.1180020107

Kodumuru, R., Sarkar, S., Parepally, V., & Chandarana, J. (2025). Artificial intelligence and Internet of Things integration in pharmaceutical manufacturing: A smart synergy. *Pharmaceutics, 17*(3), Article 290. https://doi.org/10.3390/pharmaceutics17030290

Lopes, M. R., Costigliola, A., Pinto, R., Vieira, S. M., & Sousa, J. M. C. (2020). Pharmaceutical quality control laboratory digital twin—A novel governance model for resource planning and scheduling. *International Journal of Production Research, 58*(21), 6553–6567. https://doi.org/10.1080/00207543.2019.1683250

Lopes, P. V., Silveira, L., Aquino, R. D. G., Ribeiro, C. H., Skoogh, A., & Verri, F. A. N. (2024). Synthetic data generation for digital twins: Enabling production systems analysis in the absence of data. *International Journal of Computer Integrated Manufacturing, 37*(10–11), 1252–1269. https://doi.org/10.1080/0951192X.2024.2322981

Martins, M. S. E., Viegas, J. L., Coito, T., Firme, B., Costigliola, A., Figueiredo, J., Vieira, S. M., & Sousa, J. M. C. (2023). Minimizing total completion time in large-sized pharmaceutical quality control scheduling. *Journal of Heuristics, 29*(1), 177–206. https://doi.org/10.1007/s10732-023-09509-8

Maslaton, R. (2012). Resource scheduling in QC laboratories. *Pharmaceutical Engineering, 32*(6).

Ministerio de Salud y Protección Social. (2013). *Resolución 3619 de 2013, por la cual se expide el Manual de Buenas Prácticas de Laboratorio de Control de Calidad de Productos Farmacéuticos, se establece la Guía de Evaluación y se dictan otras disposiciones*.

Ministerio de Salud y Protección Social. (2016). *Resolución 1160 de 2016, por la cual se establecen los Manuales de Buenas Prácticas de Manufactura y las Guías de Inspección de Laboratorios o Establecimientos de Producción de medicamentos para la obtención del Certificado de Cumplimiento de las Buenas Prácticas de Manufactura*. República de Colombia.

Ministerio de Salud y Protección Social. (2022a). *Decreto 335 de 2022, por el cual se establece el procedimiento para la obtención de los certificados de cumplimiento de las Buenas Prácticas de Elaboración, Laboratorio y Manufactura ante el INVIMA*.

Ministerio de Salud y Protección Social. (2022b). *Resolución 662 de 2022, por la cual se modifican las Resoluciones 3619 de 2013 y 1124 de 2016 en relación con las actividades de los laboratorios de control de calidad de productos farmacéuticos y la presentación de estudios de biodisponibilidad y bioequivalencia*.

Ministerio de Salud y Protección Social. (2023). *Informe de desabastecimiento de medicamentos en Colombia*. MinSalud.

Mischek, F., & Musliu, N. (2021). A local search framework for industrial test laboratory scheduling. *Annals of Operations Research, 302*, 533–562. https://doi.org/10.1007/s10479-021-04007-1

Mischek, F., & Musliu, N. (2024). Preference explanation and decision support for multi-objective real-world test laboratory scheduling. *Proceedings of the International Conference on Automated Planning and Scheduling, 34*(1), 378–386. https://doi.org/10.1609/icaps.v34i1.31497

Muñoz-Pinzón, D. S., Valencia-Rivero, K. T., Caviativa-Castro, Y. P., & Castillo-Bustos, J. S. (2024). Industria 4.0 en pymes colombianas. *Revista Politécnica, 20*(39), 99–118. https://doi.org/10.33571/rpolitec.v20n39a7

Organización Panamericana de la Salud. (2020). *Fortalecimiento de las autoridades reguladoras nacionales de medicamentos y productos biológicos* (Documento CD58/INF/14). OPS.

Patki, N., Wedge, R., & Veeramachaneni, K. (2016). The Synthetic Data Vault. In *2016 IEEE International Conference on Data Science and Advanced Analytics (DSAA)* (pp. 399–410). IEEE. https://doi.org/10.1109/DSAA.2016.49

Ruiz-Torres, A. J., Ablanedo-Rosas, J. H., & Otero, L. D. (2012). Scheduling with multiple tasks per job—The case of quality control laboratories in the pharmaceutical industry. *International Journal of Production Research, 50*(3), 691–705. https://doi.org/10.1080/00207543.2010.543173

Ruiz-Torres, A. J., Mahmoodi, F., & Kuula, M. (2017). Quality assurance laboratory planning system to maximize worker preference subject to certification and preference

balance constraints. *Computers & Operations Research, 83*, 140–149. https://doi.org/10.1016/j.cor.2017.02.002

Schäfer, R. (2004). Concepts for dynamic scheduling in the laboratory. *JALA: Journal of the Association for Laboratory Automation, 9*(6), 382–397. https://doi.org/10.1016/j.jala.2004.10.001

Superintendencia de Industria y Comercio. (2024). *Circular Externa 002 de 2024: Lineamientos sobre el tratamiento de datos personales en sistemas de inteligencia artificial*.

Vallevik, V. B., Babic, A., Marshall, S. E., Elvatun, S., Brøgger, H. M. B., Alagaratnam, S., Edwin, B., Veeraragavan, N. R., Befring, A. K., & Nygård, J. F. (2024). Can I trust my fake data—A comprehensive quality assessment framework for synthetic tabular data in healthcare. *International Journal of Medical Informatics, 185*, Article 105413. https://doi.org/10.1016/j.ijmedinf.2024.105413

World Health Organization. (2024). WHO good practices for pharmaceutical quality control laboratories. In *WHO Expert Committee on Specifications for Pharmaceutical Preparations: Fifty-seventh report* (WHO Technical Report Series No. 1052, Annex 4). World Health Organization.

Xu, L., Skoularidou, M., Cuesta-Infante, A., & Veeramachaneni, K. (2019). Modeling tabular data using conditional GAN. In *Advances in Neural Information Processing Systems 32 (NeurIPS 2019)*. https://arxiv.org/abs/1907.00503