

Minería de datos en aprendizaje automático

Preparando los datos


 UNIVERSIDAD
SIMÓN BOLÍVAR

CIENCIAS BÁSICAS
Y BIOMÉDICAS



Minería de datos en aprendizaje automático

- La minería de datos (DM) es el conjunto de técnicas que permiten la preparación adecuada de la información presente en bases de datos (DB) [1].
- La DM muchas veces es un proceso desafiante ya que las DB no siguen un patrón ya, usualmente, ellas se generan para dar respuesta a condiciones particulares.



Minería de datos en aprendizaje automático

- Una DB muy popular en ML, es la base de datos denominada Iris.
- Esa DB está reportada en la literatura y se puede descargar de la Internet.

Iris Data Set

Download [Data Folder](#) [Data Set Description](#)

Abstract: Famous database, from Fisher, 1936




Data Set Characteristics:	Multivariate	Number of Instances:	150	Area:	Life
Attribute Characteristics:	Real	Number of Attributes:	4	Date Donated	1988-07-01
Associated Tasks:	Classification	Missing Values?	No	Number of Web Hits:	4260947

<https://archive.ics.uci.edu/ml/datasets/iris>

Minería de datos en aprendizaje automático

- En la figura, presentada a la derecha, se puede apreciar la estructura pictográfica de DB Iris.
- Como se aprecia, está conformada por 150 vectores fila de 5 componentes (4 atributos+ 1 etiqueta nominal).



Minería de datos en aprendizaje automático

- Aquí, se observa, una parte de la DB Iris considerando solo 15 vectores fila con 4 componentes cada una.
- En esa DB existen 3 clases, de esta planta, identificadas con sus respectivas etiquetas (Etq).

Atributos	Etiquetas
4.6, 3.2, 1.4, 0.2	Iris-setosa
5.3, 3.7, 1.5, 0.2	Iris-setosa
5.0, 3.3, 1.4, 0.2	Iris-setosa
7.0, 3.2, 4.7, 1.4	Iris-versicolor
6.4, 3.2, 4.5, 1.5	Iris-versicolor
6.9, 3.1, 4.9, 1.5	Iris-versicolor
5.5, 2.3, 4.0, 1.3	Iris-versicolor
6.5, 2.8, 4.6, 1.5	Iris-versicolor
5.7, 2.8, 4.5, 1.3	Iris-versicolor
5.1, 2.5, 3.0, 1.1	Iris-versicolor
5.7, 2.8, 4.1, 1.3	Iris-versicolor
6.3, 3.3, 6.0, 2.5	Iris-virginica
5.8, 2.7, 5.1, 1.9	Iris-virginica
7.1, 3.0, 5.9, 2.1	Iris-virginica
6.3, 2.9, 5.6, 1.8	Iris-virginica

Minería de datos en aprendizaje automático

- 
1. Convertir **Etq** nominales en numéricas
 2. Separar las **Etq** de los Atributos
 3. Adaptar los datos al protocolo **ML**
 4. Fusionar datos adaptados y **Etq** numéricas
 5. Crear sets aleatorios de **ENT** y **Pru**

Minería de datos en aprendizaje automático

- Transformación preliminar de la DB

4.6,3.2,1.4,0.2,Iris-setosa
5.3,3.7,1.5,0.2,Iris-setosa
5.0,3.3,1.4,0.2,Iris-setosa
7.0,3.2,4.7,1.4,Iris-versicolor
6.4,3.2,4.5,1.5,Iris-versicolor
6.9,3.1,4.9,1.5,Iris-versicolor
5.5,2.3,4.0,1.3,Iris-versicolor
6.5,2.8,4.6,1.5,Iris-versicolor
5.7,2.8,4.5,1.3,Iris-versicolor
5.1,2.5,3.0,1.1,Iris-versicolor
5.7,2.8,4.1,1.3,Iris-versicolor
6.3,3.3,6.0,2.5,Iris-virginica
5.8,2.7,5.1,1.9,Iris-virginica
7.1,3.0,5.9,2.1,Iris-virginica
6.3,2.9,5.6,1.8,Iris-virginica

DB original

1	2	3	4	5
0.8734	0.3924	0.6203	0.1899	1
0.7975	0.4177	0.5949	0.2025	1
0.8481	0.3798	0.6329	0.2152	1
0.8228	0.3798	0.7342	0.2785	2
0.5823	0.4557	0.1266	0.0253	0
0.8608	0.3544	0.6076	0.1772	1
0.7975	0.3165	0.6203	0.1899	1
0.8987	0.3798	0.7468	0.2658	2
0.7468	0.4051	0.6076	0.2279	1
0.7595	0.2785	0.6329	0.1899	2
0.6582	0.5190	0.1899	0.0127	0
0.8101	0.3418	0.6709	0.2405	2
0.7089	0.3798	0.5696	0.1899	1
0.6962	0.3038	0.4684	0.1266	1
0.7722	0.3544	0.5063	0.1646	1

DB normalizada y aleatorizada



Minería de datos en aprendizaje automático

- Conjuntos aleatorizados de ENT y PRU

	1	2	3
1	0.8734	0.7975	0.8481
2	0.3924	0.4177	0.3798
3	0.6203	0.5949	0.6329
4	0.1899	0.2025	0.2152



Tres ejemplos del conjunto de ENT

	1	2
1	0.5570	0.8734
2	0.4051	0.3924
3	0.1646	0.6456
4	0.0253	0.2911



Dos ejemplos del conjunto de Prueba



Minería de datos en aprendizaje automático

- Conjuntos aleatorizados de ENT y Etq

Atributos

$$X = \begin{bmatrix} 0.8734 & 0.7975 & 0.8481 & 0.8228 & 0.5823 \\ 0.3924 & 0.4177 & 0.3797 & 0.3797 & 0.4557 \\ 0.6202 & 0.5949 & 0.6329 & 0.7342 & 0.1266 \\ 0.1899 & 0.2025 & 0.2152 & 0.2785 & 0.0253 \end{bmatrix}$$

Etq = $\begin{bmatrix} 1 & 1 & 1 & 2 & 0 \end{bmatrix}$



Ent y Prueba para aprendizaje supervisado

