

Capítulo 3

Preparación de los datos

Las tareas o técnicas de preparación de datos en un proyecto de minería de datos se orientan a la adecuación del juego de datos para que pueda ser usado, posteriormente, por algoritmos de clasificación, segmentación o regresión.

Estas tareas las podemos agrupar en los siguientes bloques temáticos:

- Tareas de limpieza de datos, que permiten corregir o eliminar ruido o datos no válidos.
- Tareas de normalización de datos, que facilita la presentación de los datos en el mismo rango.
- Tareas de discretización, entendidas como procesos de conversión de variables continuas a categóricas.
- Tareas de reducción de la dimensionalidad, que nos ayudará a desarrollar modelos con juegos de datos reducidos.

3.1. Limpieza de datos

En el proceso de limpieza de datos (en inglés, *data cleansing* o *data scrubbing*) se llevan a cabo actividades de detección, eliminación o corrección de instancias corrompidas o inapropiadas en los juegos de datos.

A nivel de valores de atributos se gestionan los valores ausentes, los erróneos y los inconsistentes. Un ejemplo podrían ser los valores fuera de rango (*outliers*).

El proceso de integración de datos puede ser una de las principales fuentes de incoherencias en los datos. Fruto de la fusión de juegos de datos distintos, se pueden generar inconsistencias que deben ser detectadas y subsanadas.

3.2. Normalización de datos

La normalización de datos consiste en modificar los datos para lograr que estén en una escala de valores equivalentes que simplifique la comparación entre ellos. La normalización es útil para varios métodos de minería de datos, que tienden a quedar sesgados por la influencia de los atributos con valores más altos, distorsionando de esta forma el resultado del modelo.

Algunos de los principales métodos de normalización de atributos son:

- Normalización por el máximo, que consiste en encontrar el valor máximo del atributo a normalizar y dividir el resto de los valores por este valor máximo, asegurándonos, por tanto, que el máximo recibe el valor 1 y el resto valores en el rango $[0, 1]$.

$$z_i = \frac{x_i}{x_{\max}} \quad (3.1)$$

donde z_i es el valor normalizado, x_i el valor original del atributo y $x_{\max}$ el valor máximo para este atributo de todo el conjunto de datos.

- Normalización por la diferencia, que intenta compensar el efecto de la distancia del valor que tratamos con respecto al máximo de los valores observados. Su fórmula de cálculo es:

$$z_i = \frac{x_i - x_{\min}}{x_{\max} - x_{\min}} \quad (3.2)$$

donde $x_{\min}$ es el valor mínimo para este atributo en el conjunto de datos.

- Normalización basada en la desviación estándar, también llamada estandarización de valores, que asegura que se obtienen valores dentro del rango elegido que tienen como propiedad que su media es el 0 y su desviación estándar es 1.

$$z_i = \frac{x_i - \mu}{\sigma} \quad (3.3)$$

donde μ representa la media y σ la varianza.

3.3. Discretización de datos

La discretización es el proceso mediante el cual los valores de una variable continua se incluyen en contenedores, intervalos o grupos, con el objetivo de que haya un número limitado de estados posibles. Los contenedores se tratarán entonces como si fueran categorías.

La discretización es una tarea habitual en los procesos de minería de datos puesto que muchos algoritmos de clasificación requieren que sus atributos sean discretizados, bien porque solo aceptan valores nominales, bien porque trabajar con atributos nominales en lugar de continuos disminuye el coste computacional y acelera el proceso inductivo. Además, la discretización de atributos puede, en ocasiones, mejorar el rendimiento de un clasificador.

Los métodos de discretización se pueden clasificar según tres grandes categorías:

- Supervisados o no supervisados. Métodos que tienen en cuenta los valores del atributo clase o no.
- Locales o globales. Métodos limitados a un atributo o, en general, a un subconjunto horizontal (subconjunto de instancias) o vertical (subconjunto de atributos) del conjunto de datos; o bien actuando sobre todos los atributos y todos los datos a la vez.
- Parametrizados y no parametrizados. Los primeros empiezan conociendo el número máximo de intervalos que hay que generar para un atributo específico, mientras que los demás tienen que encontrar este número automáticamente.

3.3.1. Método de igual amplitud

El método de partición en intervalos de la misma amplitud es un método no supervisado que busca crear grupos con el mismo número de instancias en su interior.

El método consiste en los siguientes pasos:

1. Se parte de un atributo con n valores, el cual queremos discretizar en k intervalos de igual longitud.
2. La longitud de cada intervalo será:

$$\alpha = \frac{x_{\max} - x_{\min}}{k} \quad (3.4)$$

donde $x_{\min}$ y $x_{\max}$ representan el valor mínimo y máximo, respectivamente, que toman los atributos.

3. Entonces, los intervalos quedan definidos por la expresión:

$$\text{Intervalo}_i = x_{\min} + i\alpha, \quad \forall i \in \{1, \dots, k\} \quad (3.5)$$

Algunos de los principales problemas de este método son:

1. Da la misma importancia a todos los valores, independientemente de su frecuencia de aparición.
2. Puede generar intervalos poco homogéneos, donde se mezclen dentro de un mismo intervalo valores que corresponden a clases diferentes.
3. La elección del parámetro k no es trivial en la mayoría de casos.

3.3.2. Método de igual frecuencia

Este método es similar al método de igual amplitud, pero en este caso se requiere que cada grupo contenga el mismo número de instancias en su interior.

El método consiste en los pasos siguientes:

- Ordenar los valores del atributo X de menor a mayor:
 $x_1 \leq \dots \leq x_n$.
- Fijar un número de intervalos k .
- Calcular el valor de la frecuencia de cada intervalo:
 $f = \frac{n}{k}$.
- Asignar a cada intervalo los f valores ordenados, de tal forma que cada intervalo o grupo contendrá f elementos ordenados, donde el valor máximo del intervalo i será menor o igual que el valor mínimo del intervalo $i+1$.

El principal inconveniente de este método es que valores muy dispares pueden ir a parar al mismo intervalo, dado que el criterio es mantener la misma frecuencia en todos los intervalos. Por el contrario, el método funciona correctamente cuando se da una distribución uniforme de los valores del atributo a discretizar.

3.3.3. Método *chi merge*

Chi merge es un algoritmo simple que utiliza el estadístico chi-cuadrado para discretizar los atributos numéricos. Se trata de un método de discretización de datos supervisado.

Este método intenta que dentro de cada intervalo aparezcan representadas todas las clases de forma parecida, y muy diferente respecto de otros intervalos. En términos de frecuencias, eso quiere decir que dentro de un intervalo hay que esperar que la frecuencia de aparición de valores de cada clase sea parecida, y muy diferente de la de otros intervalos.

Si la primera condición no se cumple, quiere decir que tenemos un intervalo demasiado heterogéneo y que sería preciso

subdividirlo. Si no se cumple la segunda, entonces quiere decir que el intervalo es muy parecido a algún otro intervalo adyacente, de manera que, en tal caso, sería necesario unirlos.

Una manera de medir estas propiedades es recurriendo al estadístico chi-cuadrado χ^2 para averiguar si las frecuencias correspondientes a dos intervalos son significativamente diferentes (y, por lo tanto, ya es correcto que los intervalos estén separados), o bien que no lo son (y hay que unirlos).

3.3.4. Métodos basados en entropía

Los métodos basados en medidas de entropía parten de la idea de encontrar particiones del conjunto original de datos que sean internamente tan homogéneas como sea posible, y tan diferentes como sea posible con respecto al resto de las particiones.

Estos métodos trabajan sobre variables continuas con el objetivo de crear un punto de decisión (llamado límite o umbral) sobre un atributo determinado tal que permita alcanzar la mejor separación de los datos en dos subconjuntos disjuntos.

Se pueden definir distintos criterios para escoger la partición «óptima» en cada iteración del algoritmo, pero una de las métricas más empleadas para tal fin es la entropía de la información asociada a cada posible partición. Es decir, se toma como criterio de discretización el valor que minimice la entropía de los subconjuntos generados utilizando ese punto de corte.

3.4. Reducción de la dimensionalidad

En algunos procesos de minería de datos podemos encontrarnos con el problema de que el método de construcción

del modelo elegido no puede tratar la cantidad de datos de que disponemos, o simplemente que el tiempo requerido para construir el modelo no es adecuado para nuestras necesidades.

En estos casos, es posible aplicar una serie de operaciones con el fin de facilitar dos objetivos, y asegurando, además, que se mantiene la calidad del modelo resultante, es decir:

- la reducción del número de atributos a considerar
- y la reducción del número de casos que hay que tratar.

Si denotamos como $D_{n,m}$ a nuestro conjunto de datos, en el primer caso el objetivo será reducir el valor de m (reducción de columnas), mientras que en el segundo caso el objetivo será reducir el valor de n (reducción de filas).

3.4.1. Reducción del número de atributos

La reducción del número de atributos consiste en encontrar un subconjunto de los atributos originales que permita obtener modelos de la misma calidad que los que se obtendrían utilizando todos los atributos, pero con una reducción en la complejidad temporal y/o de cálculo del método de minería de datos.

Existen dos grandes grupos:

- Los métodos de selección de atributos, que consisten en saber qué subconjunto de atributos puede generar un modelo con la misma, o similar, calidad que el modelo obtenido con el conjunto de atributos original. En esencia, se trata de encontrar métricas que indiquen los atributos que pueden ignorarse en la creación del modelo sin sufrir una considerable pérdida de información.

Algunos métodos realizan este tipo de pruebas a cada atributo de forma individual, como por ejemplo la prueba de significación, que compara si un atributo es relevante o no a partir de sus valores. Otros métodos, en cambio, parten de que la suposición de independencia entre los atributos puede ser un poco excesiva, y analizan las dependencias y correlaciones entre atributos para determinar grupos de atributos.

- La fusión y creación de nuevos atributos, que consiste en crear nuevos atributos «híbridos» a partir de la integración o fusión de los atributos existentes. En general, podemos crear un atributo nuevo a_{n+1} mediante la aplicación de una combinación lineal de pesos a los atributos $a_1, \dots, a_n$:

$$a_{n+1} = \sum_{i=1}^n a_i w_i \quad (3.6)$$

donde w_i es el peso que indica en qué grado contribuye el atributo a_i a la creación del nuevo atributo.

El método de análisis de componentes principales (*Principal Component Analysis*, PCA) es uno de los métodos más conocidos para la fusión y creación de nuevos atributos.

3.4.2. Métodos de reducción de casos

En minería de datos no siempre es posible disponer de todos los datos de la población que se estudia. Es en esta circunstancia en la que el concepto de *muestra* se convierte en relevante para el analista. A una muestra de una población se le exige

que sus propiedades sean extrapolables a las propiedades de la población.

Llamaremos espacio muestral al conjunto de muestras que se extrae de una población. La variable que asocia a cada muestra su probabilidad de extracción, sigue lo que se llama una distribución muestral cuyo estudio nos permitirá calcular la probabilidad que se tiene, dada una sola muestra, de acercarse a las propiedades de la población.

Respecto de las técnicas de muestreo, podemos clasificarlas en dos grupos: muestreo probabilístico y muestreo no probabilístico o subjetivo.

Técnicas de muestreo probabilístico

Se trata del conjunto de técnicas más aconsejable, puesto que permiten calcular la probabilidad de extracción de cualquiera de las muestras posibles.

A continuación enumeramos algunas de las más importantes:

- Muestreo estratificado: consiste en dividir la población de estudio en grupos homogéneos respecto de alguna de las características que se quiere medir. Una vez determinados los grupos a estos se les aplicaría, por ejemplo, una técnica de muestreo sistemática. Casos de grupos pueden ser por sexo, por sector laboral, etc.
- Muestreo sistemático: si el número total de miembros de nuestra población es N y el número de miembros de la muestra que queremos tomar es n , entonces tendremos que el intervalo de selección será $\frac{N}{n}$. Escogemos al azar un miembro de la población q y, a partir de este, se

escogen los siguientes miembros siguiendo el orden del intervalo de selección. Esto es $\{q + i\frac{N}{n} \mid i = 0, \dots, n-1\}$.

- Muestreo por estadios múltiples: se divide la población en niveles estratificados, de modo que vamos tomando muestras de los distintos niveles considerados. Por ejemplo, si queremos realizar un estudio de intención de voto, empezaríamos por dividir la población total en regiones, localidades y barrios.
- Muestreo por conglomerado: esta técnica está indicada para poblaciones que ya de forma natural se encuentran divididas en grupos que contienen toda la variabilidad de la población total. Es decir, que el estudio de uno de los grupos es suficiente para extrapolar los resultados al resto de población.

Técnicas de muestreo no probabilístico o subjetivo

Se dan cuando no es posible determinar la probabilidad de extracción de una determinada muestra o incluso cuando ciertos elementos de la población no tienen posibilidades de ser seleccionados (individuos fuera de cobertura).

Como la selección de muestras no es aleatoria tampoco aplica el concepto de estimación de errores de la muestra. Esta circunstancia provoca lo que se conoce como sesgo de selección, que es la distorsión provocada por el hecho de que la muestra tiene muchas limitaciones a la hora de representar toda la variabilidad de la población total.

A continuación enumeramos algunas de las más importantes:

- Muestreo por cuotas: podemos pensarlo como el muestreo por estratos, pero ponderado por cuotas. Es decir,

se divide la población en estratos definidos por alguna variable de distribución conocida (por ejemplo, el sexo). Posteriormente calculamos la proporción de cada estrato respecto de la población total. Y finalmente se multiplica cada proporción por el tamaño de cada muestra. Esta técnica es habitual en sondeos de opinión y estudios de mercado.

- Muestreo de bola de nieve: En esta técnica se selecciona inicialmente un pequeño grupo de individuos que nos ayudarán a encontrar más miembros representativos de la población. Está indicada para los casos en que la población se encuentra muy dispersa o incluso escondida.