

Técnicas de minería de datos, en el contexto del aprendizaje automático

Carlos David Campo Urzola^a

^aFacultad de Ciencias Básicas y Biomédicas, Universidad Simón Bolívar, Maestría en Ciencia de Datos.

I. Introducción

Un gran algoritmo de aprendizaje automático no solo requiere datos de altísima calidad, sino también del procesamiento de los conjuntos de datos estructurados. Sin embargo, en la vida cotidiana nos enfrentamos a una gran variedad de retos, como por ejemplo datos incompletos, inconsistentes, ruidosos, lo que convierte esta fase en la más crítica, demandante y poco glamurosa de la industria. Es por ello que este informe analiza las técnicas esenciales de acondicionamiento de los datos tales como la limpieza, normalización, discretización, entre otras.

Finalmente, se presentan evidencias experimentales cuantitativas de que contrastan los métodos tradicionales de imputación frente a modelos adaptativos de aprendizaje en subespacios de características.

II. Metodología

A partir de las dos fuentes recomendadas, Modelos y Algoritmos de Minguillón y Casas y Sample-Based Extreme Learning Machine with Missing Data de Hang, Xin-Wang y Yu-Xing, además de las lecturas 3 y 7 del The Global Consumer Intelligence impartidas por Matsuo-Iwasawa lab de la Universidad de Tokio y por último un artículo de IBM titulado ¿Qué es la reducción de la dimensionalidad?, las metodologías clave para el acondicionamiento de los datos se pueden agrupar en cinco bloques fundamentales descritos a continuación:

A. Limpieza de datos

Tiene como objetivo identificar, corregir o remover registros que contengan anomalías, ruido, duplicados o errores tipográficos. En el ámbito práctico, estas técnicas se facilitan mediante el lenguaje de programación Python, específicamente a través de su librería Pandas.

Dentro de los procedimientos de limpieza y acondicionamiento de datos bajo este enfoque se puede resaltar el uso de:

- El tratamiento de datos faltantes: se lleva a cabo para asegurar la integridad de los dataframes, especialmente después de fusiones de datos.
- Extracción y selección de información: consiste en aislar subconjuntos de datos para su posterior análisis. Esto se logra mediante etiquetas utilizando los indexadores `at` y `loc` o a través de índices numéricos (`iat`, `iloc`).
- Fusion de datos: Combina los datos mediante `INNER JOIN`, `LEFT JOIN` y `full outer join`.
- Concatenación de datos: Se realiza de forma vertical, alineando las columnas comunes entre los conjuntos de datos, o de forma horizontal, uniendo las estructuras a partir de la coincidencia de sus índices e ignorando las columnas no deseadas.
- Data binning: Aquí se dividen los datos en intervalos `cut()` para intervalos de igual longitud y `qcut()`, esto garantiza que cada intervalo contenga la misma cantidad de registros.
- Indexación jerárquica: Organiza los índices y columnas en múltiples niveles para poder mejorar la interoperabilidad y facilitar el filtrado y la agregación.
- Otras operaciones complementarias: Incluyen la eliminación de datos, el ordenamiento de valores y las operaciones de agregación y grupos para estructurar la información.

B. Normalización de datos

Es el proceso que se ejecuta cuando las variables predictoras poseen características diferentes. Con esto se busca principalmente unificar el rango de las variables para igualar y poder trabajar con su peso matemático. Algunas de las técnicas que se suelen usar son:

- 1) Normalización por máximo: transforma los datos en un rango de 0, 1 dividiendo cada una de las variables por su valor límite superior.

$$Z_{norm} = \frac{x}{x_{max}} \quad (1)$$

- 2) Normalización por diferencia: escala las variables en un intervalo de 0, 1, compensando la distancia al mínimo.

$$Z_i = \frac{x_i - x_{min}}{x_{max} - x_{min}} \quad (2)$$

- 3) Estandarización: ajusta la distribución para obtener una media aritmética igual a cero y una desviación estándar de uno.

$$Z_i = \frac{x_i - \mu}{\sigma} \quad (3)$$

C. Discretización de datos

Consiste en la transformación de variables continuas en categóricas o discretas mediante segmentación en rangos o contenedores. La ventaja de esto es que disminuye considerablemente el gasto de cómputo y optimiza los algoritmos clasificadores de naturaleza nominal. Los principales clasificadores son:

- Igual amplitud: divide el rango total de la variable en k intervalos de idéntica longitud física.
- Igual frecuencia: distribuye los límites de forma que los intervalos tengan el mismo número de instancias.
- Métodos supervisados: varios algoritmos toman en cuenta la variable objetivo para lograr establecer de manera dinámica y matemática los puntos de corte óptimos basados en pruebas de significación estadística.

D. Reducción dimensional y de casos

Es un conjunto de técnicas que se suelen utilizar para mejorar los modelos de machine learning, conservando características esenciales de los conjuntos de datos conservando su complejidad pero reduciendo las variables predictoras de números para una mayor generalización.

E. Missing data

Ocurre en mayor frecuencia por fallos en los sensores de recopilación, errores de transmisión o por la naturaleza estructural del problema.

Este tipo de situaciones se puede manejar desde varios tipos de enfoques:

- Se puede llenar con promedios. Sin embargo, no es la mejor manera y mucho menos si se tienen grandes volúmenes de datos ya que va a afectar
- Se pueden agrupar los datos en columnas y después basado en la agrupación, se puede usar el promedio de los grupos para llenar los datos faltantes
- Usar certain rows sin los valores faltantes y hacer una simple regresión lineal en el estimado para crear un machine learning model para estimar esos valores faltantes.

III. Resultados

Para validar empíricamente la efectividad de las técnicas de acondicionamiento de datos faltantes, se analizaron los resultados obtenidos en el estudio Geo et al., utilizando los conjuntos de datos biomédicos Breast Cancer que contiene 286 muestras con 9 atributos y por el lado de diabetes tiene 768 muestras con 20 atributos que fueron obtenidos del repositorio estándar de la universidad de California.

Se compraro el algoritmo basado en muestras S-ELM, que proyectan matemáticamente los pesos únicamente en el subespacio de atributos existentes del vector de entrada de cada muestra—frente a los enfoques tradicionales de preprocesamiento e imputación con ceros e imputación por promedios

Conjunto de Datos (UCI)	Métrica	S-ELM	ZF-ELM	MF-ELM
Breast Cancer (286 muestras, 9 atributos)	Precisión Promedio	71.85%	65.70%	69.01%
	Desviación Estándar	± 0.015	± 0.0334	± 0.0183
	Tiempo de Cómputo (s)	0.3473 s	0.2776 s	0.2947 s
Diabetes (768 muestras, 20 atributos)	Precisión Promedio	73.75%	68.52%	69.57%
	Desviación Estándar	± 0.026	± 0.0467	± 0.0448
	Tiempo de Cómputo (s)	0.9315 s	0.7257 s	0.7112 s

El cuadro anterior demuestra que inventar los datos faltantes rellenándolos con ceros o con promedios, daña el rendimiento del modelo, además de volverlo inestable. Mientras que S-ELM es mejor ya que adapta la matemática dinámicamente al espacio que si tenemos. Esto genera mayor precisión y mayor estabilidad, pagando un costo computacional extra, milisegundos.

IV. Hallazgos globales.

Haber elaborado este informe permite estructurar los siguientes hallazgos:

- Interdependencia de las fases: ninguna de las fases de acondicionamiento de los datos esta separada una de la otra, sino que constituyen un proceso iterativo que le da el exito al machine learning, ya que una mala discretización o normalizacion de los datos puede influir de manera negativa la capacidad de generar un clasificador.
- El reemplazo automatico de los datos faltantes con ceros o valores promedios, nubla la probabilidad de las variables y eso se traduce en un subajuste o sobreajuste en los modelos de entrenamiento.
- La literatura muestra que las Extreme Learning Machines tienen un amplio potencial, ya que operan directamente con esos espacios vacíos, en lugar de forzar la alteración de los datos mediante imputaciones propensas al error.

V. Bibliografía

- [1] J. Minguillón y J. Casas, *Minería de datos: Modelos y algoritmos*. Barcelona, España: Editorial UOC, 2019, pp. 57-67.
- [2] H. Gao, X.-W. Liu, Y.-X. Peng, y S.-L. Jian, "Sample-Based Extreme Learning Machine with Missing Data," *Mathematical Problems in Engineering*, vol. 2015, art. ID 145156, pp. 1-11, 2015. doi: 10.1155/2015/145156.
- [3] GCI World, "Cleaning Data Using Pandas" [Clase magistral], en *Unidad de Aprendizaje de Acondicionamiento de Datos*, GCI World, 2026. [En línea]. Disponible: https://youtube.com/playlist?list=PLiEF5y87wtYxJ6Z_LtA9L2w57vAfGrZMa (fecha de consulta: 24 de mayo de 2024).
- [4] E. Kavlakoglu y J. Murel, "¿Qué es la reducción de la dimensionalidad?", *IBM Think*, Armonk, NY: IBM, 2024. [En línea]. Disponible: <https://www.ibm.com/es-es/think/topics/dimensionality-reduction> (fecha de consulta: 24 de mayo de 2024).
- [5] K. Nakano, "Competition & Final Assignment Tutorial" [Tutorial], *GCI World 2026*, Tokio, Japón: The University of Tokyo, 2026. [En línea]. Disponible: https://youtube.com/playlist?list=PLiEF5y87wtYwK-tQLcJ_ZHcYmoHnToAr2 (fecha de consulta: 24 de mayo de 2024).