

Preparando los datos

Pragmatismo



Preparando los datos.

- Se pretende identificar situaciones en las cuales la minería de datos y algunos constructos teórico-prácticos, del Álgebra Lineal, son utilizados en el contexto de la Inteligencia Artificial.
- Se considera una situación en la cual se identifican las matrices y los vectores que se generan, típicamente, cuando ciertos operadores inteligentes son entrenados para reconocer patrones



Preparando los datos.

- En machine learning, usualmente, se entrena un operador inteligente (SO) para que resuelva un problema de aprendizaje usando un algoritmo de entrenamiento supervisado.
- Existe un número importante de SO. Aquí será utilizado uno denominado máquina de aprendizaje extremo (ELM), que es un tipo especial de red neural artificial (RNA).

El algoritmo de un entrenamiento supervisado

Entrada: Dado un conjunto de entrenamiento
 $\mathcal{N} = \{(x_i, t_i) : x_i \in R^n, t_i \in R^m, i = 1, \dots, N\}$,
la función de activación $g(x)$
y el número de nodos ocultos L ;

Salida: Matriz de pesos de salida β .

Paso 1: Se asignan valores pseudoaleatorios a:

- a) Los pesos de entrada a la capa oculta (w_i);
- b) Los sesgos (bias) de la capa oculta (b_i);

Paso 2: Calcular la matriz de salida de la capa oculta H ;

Paso 3: Calcular la matriz de pesos de salida β

Preparando los datos.

Situación problemática:

Usando una ELM supervisada con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo de entrenamiento supervisado, se debe:

- Construir la matriz **tempH** = $W \cdot X + b$
- Calcular la matriz **H**, considerando **tempH** como argumento de una función de activación.
- Calcular la matriz de pesos de salida (**B**), lo cual implica resolver un sistema de ecuaciones lineales que involucra el cálculo de una matriz pseudoinversa de H^T denotada como $(H^T)^\dagger$


0,629447372786358
0,264718492450819
0,915013670868595
0,914333896485891
0,811583874151238
0,804919190001181

Preparando los datos.

- La DB *Iris*, está reportada en la literatura y se puede descargar de la Internet usando el siguiente enlace:

<https://archive.ics.uci.edu/ml/datasets/iris>

- Iris** está conformada por **150** vectores fila de **5** columnas o componentes (primeras **4** columnas de atributos + **la última columna** relativa a etiquetas nominales).



Preparando los datos.

Data Set Characteristics:	Multivariate
Attribute Characteristics:	Real
Associated Tasks:	Classification

Number of Instances:	150
Number of Attributes:	4
Missing Values?	No

Area:	Life
Date Donated	1988-07-01
Number of Web Hits:	4260947

Iris Data Set



Famous database; from Fisher, 1936

Preparando los datos.

- Originalmente, la DB *iris* está estructurada así:




Atributos	4.6, 3.2, 1.4, 0.2, Iris-setosa	Etiqueta
	5.3, 3.7, 1.5, 0.2, Iris-setosa	
	5.0, 3.3, 1.4, 0.2, Iris-setosa	
	7.0, 3.2, 4.7, 1.4, Iris-versicolor	
	6.4, 3.2, 4.5, 1.5, Iris-versicolor	
	6.9, 3.1, 4.9, 1.5, Iris-versicolor	
	5.5, 2.3, 4.0, 1.3, Iris-versicolor	
	6.5, 2.8, 4.6, 1.5, Iris-versicolor	
	5.7, 2.8, 4.5, 1.3, Iris-versicolor	
	5.1, 2.5, 3.0, 1.1, Iris-versicolor	
	5.7, 2.8, 4.1, 1.3, Iris-versicolor	
	6.3, 3.3, 6.0, 2.5, Iris-virginica	
	5.8, 2.7, 5.1, 1.9, Iris-virginica	
	7.1, 3.0, 5.9, 2.1, Iris-virginica	
	6.3, 2.9, 5.6, 1.8, Iris-virginica	

Preparando los datos.

1. Convertir las etiquetas nominales (**Iris-setosa**, **Iris-versicolor**, **Iris-virginica**), en etiquetas numéricas (**0,1,2**) y guardar la BD en una matriz **A**
2. Particionar la matriz **A** en una matriz de atributos (**X**) y en una matriz de etiquetas numéricas (**Y**).
3. Dividir la matriz **X** entre su máximo valor para generar la matriz normalizada
4. Fusionar, en un solo arreglo matricial, las matrices normalizada y la matriz **Y**
5. Usar una técnica estadística aleatoria para mezclar la posición de los vectores de la matriz fusionada, generando una matriz aleatorizada
6. Dividir la matriz aleatorizada en una matriz de entrenamiento (Me) y en otra de prueba (Mp).

Algoritmo
preliminar
para
aplicar
minería
de datos
básica



Preparando los datos.

```
4.6,3.2,1.4,0.2,Iris-setosa  
5.3,3.7,1.5,0.2,Iris-setosa  
5.0,3.3,1.4,0.2,Iris-setosa  
7.0,3.2,4.7,1.4,Iris-versicolor  
6.4,3.2,4.5,1.5,Iris-versicolor  
6.9,3.1,4.9,1.5,Iris-versicolor  
5.5,2.3,4.0,1.3,Iris-versicolor  
6.5,2.8,4.6,1.5,Iris-versicolor  
5.7,2.8,4.5,1.3,Iris-versicolor  
5.1,2.5,3.0,1.1,Iris-versicolor  
5.7,2.8,4.1,1.3,Iris-versicolor  
6.3,3.3,6.0,2.5,Iris-virginica  
5.8,2.7,5.1,1.9,Iris-virginica  
7.1,3.0,5.9,2.1,Iris-virginica  
6.3,2.9,5.6,1.8,Iris-virginica
```



Minería de datos
básica



1	2	3	4	5
0.8734	0.3924	0.6203	0.1899	1
0.7975	0.4177	0.5949	0.2025	1
0.8481	0.3798	0.6329	0.2152	1
0.8228	0.3798	0.7342	0.2785	2
0.5823	0.4557	0.1266	0.0253	0
0.8608	0.3544	0.6076	0.1772	1
0.7975	0.3165	0.6203	0.1899	1
0.8987	0.3798	0.7468	0.2658	2
0.7468	0.4051	0.6076	0.2279	1
0.7595	0.2785	0.6329	0.1899	2
0.6582	0.5190	0.1899	0.0127	0
0.8101	0.3418	0.6709	0.2405	2
0.7089	0.3798	0.5696	0.1899	1
0.6962	0.3038	0.4684	0.1266	1
0.7722	0.3544	0.5063	0.1646	1

Preparando los datos.

3 vectores de Me

	1	2	3
1	0.8734	0.7975	0.8481
2	0.3924	0.4177	0.3798
3	0.6203	0.5949	0.6329
4	0.1899	0.2025	0.2152

2 vectores de Mp

	1	2
1	0.5570	0.8734
2	0.4051	0.3924
3	0.1646	0.6456
4	0.0253	0.2911

Preparando los datos.

Situación problemática:

Usando una ELM supervisada, con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo, se debe:

- Construir la matriz $\text{tempH} = W \cdot X + b$
- Calcular H considerando tempH como argumento de una función de activación.
- Calcular la matriz de pesos de salida B , lo cual implica resolver un sistema de ecuaciones lineales que involucra el cálculo de la matriz pseudoinversa $(H^T)^\dagger$

0,629447372786358
0,264718492450819
0,915013670868595
0,914333896485891
0,811583874151238
0,804919190001181

Preparando los datos.

Situación problemática:

Usando una ELM supervisada con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo, se debe: **a) Construir la matriz** $\text{tempH} = W \cdot X + b$

0,629447372786358
0,264718492450819
0,915013670868595
0,914333896485891
0,811583874151238
0,804919190001181

Preparando los datos.

- La ecuación (1), genera la matriz **tempH** y es muy útil en el contexto de las ELM

$$\text{tempH} = W \cdot X + b \quad (1)$$


En ella:

W es una matriz de pesos de la capa de entrada(**InputWeight**)

X es la matriz de entrenamiento

b es la matriz de sesgos.

- En el contexto de las ELM los valores de **W** y **b** son asignados de manera pseudo-aleatoria.



Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe:
a) Construir la matriz **tempH** = **W**. **X** + **b**

Solución:

- Acerca de los pesos de la capa oculta (**W**).
- El tamaño de **W**, depende del número de neuronas (**L**) y del número de atributos (**a**) que tenga la base de datos.
- En este caso, **L** = 2 y **a** = 4. Es decir, el tamaño de **W** = **InputWeight**, es igual a **L** x **a** = 2x4.

Random generate input weights (**InputWeight**)



```
InputWeight=rand(NumberofHiddenNeurons,NumberofInputNeurons)*2-1;
```



$$\mathbf{W} = \begin{bmatrix} -0.4096 & -0.7889 & -0.4345 & -0.9987 \\ -0.3870 & 0.1877 & -0.6896 & -0.4328 \end{bmatrix}_{2 \times 4}$$

Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe: a) Construir la matriz $\text{tempH} = W \cdot X + b$

Solución:

- Acerca de los ejemplos de entrenamiento (**X**).
- En la DB **Iris** hay **150** vectores. Aquí, se puede seleccionar, para efectos didácticos, un número pequeño de ellos, por ejemplo, **5** para construir la matriz de entrenamiento **X**. Nótese, además, el vector de etiquetas **T**.

Atributos (a)

$$X = \begin{bmatrix} 0.8734 & 0.7975 & 0.8481 & 0.8228 & 0.5823 \\ 0.3924 & 0.4177 & 0.3797 & 0.3797 & 0.4557 \\ 0.6202 & 0.5949 & 0.6329 & 0.7342 & 0.1266 \\ 0.1899 & 0.2025 & 0.2152 & 0.2785 & 0.0253 \end{bmatrix}_{4 \times 5}$$

T = $\begin{bmatrix} 1 & 1 & 1 & 2 & 0 \end{bmatrix}$


Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe:
a) Construir la matriz $\text{tempH} = W \cdot X + b$

Solución:

- Acerca de los sesgos (b).
- Inicialmente, b es un vector columna con tantas filas como neuronas ocultas tenga la ELM. En este caso, $L = 2$, es decir, el tamaño de b es igual a $L \times 1 = 2 \times 1$.

Random generate biases (**BiasofHiddenNeurons**)



```
BiasofHiddenNeurons=rand(NumberOfHiddenNeurons,1);
```



$$b = \begin{bmatrix} 0.5508 \\ 0.8709 \end{bmatrix}_{2 \times 1}$$


Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe: a) Construir la matriz $\text{tempH} = W \cdot X + b$

Solución:

- Acerca de los sesgos (b).
- Inicialmente, b es un vector columna con tantas filas como neuronas ocultas tenga la ELM. Aquí, $L = 2$, es decir, el tamaño de b es igual a $L \times 1 = 2 \times 1$.
- Pero se producirá **incompatibilidad algebraica**, cuando se intente calcular tempH

Random generate biases (**BiasofHiddenNeurons**)



BiasofHiddenNeurons = rand (NumberOfHiddenNeurons, 1) ;



$$b = \begin{bmatrix} 0.5508 \\ 0.8709 \end{bmatrix}_{2 \times 1}$$


Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe:
a) Construir la matriz $\text{tempH} = W \cdot X + b$

Solución:

➤ Pero se producirá **incompatibilidad algebraica**, cuando se intente calcular tempH

$$\begin{matrix}
 \begin{bmatrix} -0.4096 & -0.7889 & -0.4345 & -0.9987 \\ -0.3870 & 0.1877 & -0.6896 & -0.4328 \end{bmatrix}_{2 \times 4} & * & \begin{bmatrix} 0.8734 & 0.7975 & 0.8481 & 0.8228 & 0.5823 \\ 0.3924 & 0.4177 & 0.3797 & 0.3797 & 0.4557 \\ 0.6202 & 0.5949 & 0.6329 & 0.7342 & 0.1266 \\ 0.1899 & 0.2025 & 0.2152 & 0.2785 & 0.0253 \end{bmatrix}_{4 \times 5} & + & \begin{bmatrix} 0.5508 \\ 0.8709 \end{bmatrix}_{2 \times 1} \\
 W & & X & & b
 \end{matrix}$$




Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe:
 a) Construir la matriz **tempH** = $W \cdot X + b$

Solución:

➤ Pero se producirá **incompatibilidad algebraica**, cuando se intente calcular **tempH**

$$\begin{array}{ccccc}
 W & & X & & b \\
 2 \times 4 & * & 4 \times 5 & + & 2 \times 1 \\
 \boxed{2 \times 5} & & & + & \boxed{2 \times 1} \\
 & & & \neq &
 \end{array}$$



Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe:
 a) Construir la matriz **tempH** = $W \cdot X + b$

Solución:

➤ Pero se producirá **incompatibilidad algebraica**, cuando se intente calcular **tempH**

$$\begin{matrix}
 \begin{bmatrix} -0.4096 & -0.7889 & -0.4345 & -0.9987 \\ -0.3870 & 0.1877 & -0.6896 & -0.4328 \end{bmatrix}_{2 \times 4} & * & \begin{bmatrix} 0.8734 & 0.7975 & 0.8481 & 0.8228 & 0.5823 \\ 0.3924 & 0.4177 & 0.3797 & 0.3797 & 0.4557 \\ 0.6202 & 0.5949 & 0.6329 & 0.7342 & 0.1266 \\ 0.1899 & 0.2025 & 0.2152 & 0.2785 & 0.0253 \end{bmatrix}_{4 \times 5} & + & \begin{bmatrix} 0.5508 & 0.5508 & 0.5508 & 0.5508 & 0.5508 \\ 0.8709 & 0.8709 & 0.8709 & 0.8709 & 0.8709 \end{bmatrix}_{2 \times 5} \\
 W & & X & & b
 \end{matrix}$$


Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe:
 a) Construir la matriz **tempH** = $W \cdot X + b$

Solución:

➤ Incompatibilidad algebraica resuelta!!!

$$\begin{array}{ccccc}
 W & & X & & b \\
 2 \times 4 & * & 4 \times 5 & + & 2 \times 5 \\
 & & & & \\
 \boxed{2 \times 5} & + & \boxed{2 \times 5}
 \end{array}$$



Preparando los datos.

Situación 1: Usando una ELM con 2 neuronas ocultas, se desea detectar los patrones presentes en la BD Iris, normalizada y aleatorizada. Para ello, de acuerdo al algoritmo, se debe: **a) Construir la matriz $\text{tempH} = W \cdot X + b$**

Solución:

- Acerca de la matriz **tempH**.
- Asigna capacidades lineales a la ELM ya que combina linealmente los ejemplos de entrada y tanto los pesos como los sesgos de la capa oculta.
- Es necesaria para dotar a la ELM de capacidades no-lineales, fungiendo como argumento de una función de activación no-lineal arbitraria.

$$\text{tempH} = W \cdot X + b$$



$$\text{tempH} = \begin{bmatrix} -0.5757 & -0.5662 & -0.5861 & -0.6830 & -0.1275 \\ 0.0966 & 0.1428 & 0.0844 & -0.0030 & 0.6328 \end{bmatrix}_{2 \times 5}$$

Preparando los datos.

Situación problemática:

Usando una ELM supervisada con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo, se debe:

- Construir la matriz $\text{tempH} = W \cdot X + b$
- Calcular H considerando tempH como argumento de una función de activación.
- Calcular la matriz de pesos de salida B , lo cual implica resolver un sistema de ecuaciones lineales (**SEL**) que involucra el cálculo de la matriz pseudoinversa $(H^T)^{\dagger}$

0,629447372786358
0,264718492450819
0,915013670868595
0,914333896485891
0,811583874151238
0,804919190001181

Preparando los datos.

Situación problemática:

Usando una ELM supervisada con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo, se debe b) **Calcular H considerando tempH como argumento de una función de activación.**

0,629447372786358
0,264718492450819
0,915013670868595
0,914333896485891
0,811583874151238
0,804919190001181

Preparando los datos.

- Los SO, en el contexto del machine learning, requieren de funciones para activar ó desactivar sus unidades operativas (neuronas artificiales).
- El rol de estas funciones es dotar los SO de capacidades no lineales lo que contribuye a elevar la calidad de su desempeño.



Preparando los datos.

- Las funciones de activación más utilizadas en ML son:

✓ Sigmoidea $\rightarrow H = \frac{1}{1+e^{-tempH}}$

✓ Seno $\rightarrow H = \sin(tempH)$

✓ Base radial $\rightarrow H = \text{radbas}(tempH)$

✓ Reluc $\rightarrow H = \max(\max(tempH(i), 0))$



Preparando los datos.

Situación 1: Usando una ELM supervisada con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo, se debe b) **Calcular H considerando tempH como argumento de una función de activación.**

Solución:

- Acerca de la matriz **H**.
- Para calcular **H** basta con evaluar tempH en una función de activación. Aquí, se considera la función sigmoide.
- H será la matriz de coeficientes del sistema de ecuaciones lineales que resuelve una ELM

$$H = \frac{1}{1 + e^{-tempH}}$$



$$H = \begin{bmatrix} 0.3599 & 0.3621 & 0.3575 & 0.3356 & 0.4682 \\ 0.5241 & 0.5356 & 0.5211 & 0.4992 & 0.6531 \end{bmatrix}$$

Preparando los datos.

Situación problemática:

Usando una ELM supervisada con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo, se debe:

- Construir la matriz **tempH** = $W \cdot X + b$
- Calcular H considerando **tempH** como argumento de una función de activación.
- Calcular la matriz de pesos de salida **B**, lo cual implica resolver un sistema de ecuaciones lineales (**SEL**) que involucra el cálculo de la matriz pseudoinversa $(H^T)^{\dagger}$

0,629447372786358
0,264718492450819
0,915013670868595
0,914333896485891
0,811583874151238
0,804919190001181

Preparando los datos.

Situación problemática:

Usando una ELM supervisada con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo, se debe:

c) Calcular la matriz de pesos de salida **B**, lo cual implica resolver un sistema de ecuaciones lineales (**SEL**) que involucra el cálculo de la matriz pseudoinversa $(H^T)^{\dagger}$

0,629447372786358
0,264718492450819
0,915013670868595
0,914333896485891
0,811583874151238
0,804919190001181

Preparando los datos.

- a) Situación 1:** Usando una ELM supervisada con 2 neuronas ocultas, se desea detectar los patrones presentes en una base de datos (DB) denominada **Iris**. Para ello, de acuerdo al algoritmo, se debe c)
- Calcular la matriz de pesos de salida **B**, lo cual implica resolver un **SEL** que involucra el cálculo de la matriz pseudoinversa de H^T , denotada por $(H^T)^\dagger$

Solución:

- Acerca de la matriz **B**.
- Para calcular **B** se plantea el SEL dado por: $H^T \cdot B = T^T$
- Una solución para ese SEL es: $B = (H^T)^\dagger \cdot T^T$

$$H = \begin{bmatrix} 0.3599 & 0.3621 & 0.3575 & 0.3356 & 0.4682 \\ 0.5241 & 0.5356 & 0.5211 & 0.4992 & 0.6531 \end{bmatrix}$$

$$T_0 = \begin{bmatrix} 1 & 1 & 1 & 2 & 0 \end{bmatrix}$$

$$T = \begin{bmatrix} -1 & -1 & -1 & -1 & 1 \\ 1 & 1 & 1 & -1 & -1 \\ -1 & -1 & -1 & 1 & -1 \end{bmatrix}$$

$$B = [\mathbf{Pseudoinv}(H^T)] \cdot T^T$$

$$B = \begin{bmatrix} 86.2512 & -45.0430 & -31.2006 \\ -60.5188 & 31.3949 & 20.4004 \end{bmatrix}$$

Preparando los datos.

¿Para qué es útil B?

Solución:

- Utilidad de la matriz de pesos de salida (B).
- **Recordaris:** El rol básico de un SO es generar, automáticamente, las etiquetas experimentales (Y) asociadas con cada objeto matemático que se coloque en su entrada.
- Usando la matriz B la **ELM** puede generar esas etiquetas automáticas. Especial atención merece la interpretación de los signos de Y.

$$H = \begin{bmatrix} 0.3599 & 0.3621 & 0.3575 & 0.3356 & 0.4682 \\ 0.5241 & 0.5356 & 0.5211 & 0.4992 & 0.6531 \end{bmatrix}$$

$$B = \begin{bmatrix} 86.2512 & -45.0430 & -31.2006 \\ -60.5188 & 31.3949 & 20.4004 \end{bmatrix}$$



$$Y = [(H^T) \cdot B]^T$$

$$Y = \begin{bmatrix} -0.6764 & -1.1826 & -0.6982 & -1.2673 & 0.8535 \\ 0.2432 & 0.5052 & 0.2552 & 0.5570 & -0.5828 \\ -0.5372 & -0.3712 & -0.5247 & -0.2863 & -1.2830 \end{bmatrix}$$

$$T = \begin{bmatrix} -1 & -1 & -1 & -1 & 1 \\ 1 & 1 & 1 & -1 & -1 \\ -1 & -1 & -1 & 1 & -1 \end{bmatrix}$$

Gracias

En resumen:

Sin matrices es imposible implementar estrategias inteligentes, basadas en máquinas de aprendizaje extremo.

Miguel Vera

Bibliografía

- [1] Fisher R. (1936) The use of multiple measurements in taxonomic problems. Annual Eugenics, 7, Part II, 179-188
- [2] Huang G., Zhu Q., Siew C. (2006) Extreme learning machine: Theory and applications, Neurocomputing, vol. 70, nos. 1_3, pp. 489_501
- [3] Minguillón J y Casas J. (2019.) Minería de datos: Modelos y algoritmos. Barcelona: Editorial UOC, Disponible en: <https://ezproxy.unisimon.edu.co:2258/es/ereader/unisimon/58656>